

การพัฒนาระบบรู้จำประเภทและสีของรถจากภาพ

Development of a System for Recognizing Vehicle Types and Colors from Images

นายธาดา มุมเสือ รหัส 63312025

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต
สาขาวิชาวิศวกรรมคอมพิวเตอร์ ภาควิชาวิศวกรรมไฟฟ้าและคอมพิวเตอร์
คณะวิศวกรรมศาสตร์ มหาวิทยาลัยนเรศวร
ปีการศึกษา 2568



ใบรับรองปริญญานิพนธ์

ชื่อหัวข้อโครงงาน การพัฒนาระบบรู้จำประเภทและสีของรถจากภาพ

ผู้ดำเนินโครงงาน นายธาดา มุมเสือ รหัส 63312025

ที่ปรึกษาโครงงาน รศ.ดร.พนมขวัญ ริยะมงคล

สาขาวิชา วิศวกรรมคอมพิวเตอร์

ภาควิชา วิศวกรรมไฟฟ้าและคอมพิวเตอร์

ปีการศึกษา 2568

.....

คณะวิศวกรรมศาสตร์ มหาวิทยาลัยนเรศวร อนุมัติให้ปริญญานิพนธ์ฉบับนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรวิศวกรรมศาสตรบัณฑิต สาขาวิชาวิศวกรรมคอมพิวเตอร์

.....ที่ปรึกษาโครงงาน
(รองศาสตราจารย์ ดร.พนมขวัญ ริยะมงคล)

.....กรรมการ
(ผู้ช่วยศาสตราจารย์ รัฐภูมิ วรานุสาสน์)

.....กรรมการ
(Mr.Yoseung KIM)

ชื่อหัวข้อโครงงาน การพัฒนาระบบรู้จำประเภทและสีของรถจากภาพ
ผู้ดำเนินโครงงาน นายธาดา มุมเสือ รหัส 63312025
ที่ปรึกษาโครงงาน รศ.ดร.พนมขวัญ ริยะมงคล
สาขาวิชา วิศวกรรมคอมพิวเตอร์
ภาควิชา วิศวกรรมไฟฟ้าและคอมพิวเตอร์
ปีการศึกษา 2568

.....

บทคัดย่อ

โครงงานนี้มีวัตถุประสงค์เพื่อพัฒนาโปรแกรมต้นแบบสำหรับระบบรู้จำประเภทและสีของยานพาหนะจากภาพ เพื่อสนับสนุนการวิเคราะห์ข้อมูลเกี่ยวกับยานพาหนะที่ปรากฏในวิดีโอจราจร ระบบสามารถประมวลผลวิดีโอเพื่อตรวจจับและระบุประเภทและสีของยานพาหนะ โดยนำเสนอผลลัพธ์ในรูปแบบตารางรายงาน

การพัฒนาระบบอาศัยภาษา Python เป็นหลัก โดยใช้ไลบรารี OpenCV ในการจัดการภาพ และนำโมเดล YOLO มาใช้สำหรับการตรวจจับและจำแนกประเภทของยานพาหนะ ในส่วนของการระบุสีของยานพาหนะ ระบบใช้วิธีการเปรียบเทียบแบบอิงกฎ (Rule-based) เพื่อให้ได้ผลลัพธ์ที่มีความแม่นยำ ข้อมูลที่ได้จากกระบวนการทั้งหมดจะถูกนำเสนอผ่านตารางรายงานผล โดยมีส่วนติดต่อผู้ใช้ (User Interface) ที่พัฒนาโดยใช้ Tkinter เพื่อให้สามารถใช้งานได้ง่าย

ผลลัพธ์ของโครงงานนี้คือระบบที่สามารถตรวจจับและระบุประเภทและสีของยานพาหนะในวิดีโอได้อย่างมีประสิทธิภาพและสะดวกต่อการใช้งาน ซึ่งสามารถนำไปประยุกต์ใช้ในการวิเคราะห์ข้อมูลด้านการจราจรและการบริหารจัดการข้อมูลยานพาหนะได้ต่อไป

Project title Development of a System for Recognizing Vehicle Types and Colors from Images

Name Mr. Thada Mumsua ID. 63312025

Project advisor Dr. Panomkhawn Riyamongkol

Major Electrical Engineering

Department Electrical and Computer Engineering

Academic year 2025

.....

Abstract

This project aims to develop a prototype system for vehicle type and color recognition from images to support the analysis of vehicles appearing in traffic videos. The system processes video footage to detect and classify vehicle types and colors, presenting the results in a tabular report format.

The system is developed using Python as the core programming language, with the OpenCV library for image processing. YOLO is utilized for vehicle detection and classification, while a rule-based approach is applied for vehicle color recognition to ensure accuracy. The extracted data is presented in a report table, and the system includes a user-friendly interface developed with Tkinter for ease of use.

The outcome of this project is a system capable of effectively detecting and recognizing vehicle types and colors in videos. This system can be applied in traffic data analysis and vehicle information management.

กิตติกรรมประกาศ

ปริญญานิพนธ์ฉบับนี้สำเร็จลุล่วงไปได้ด้วยความช่วยเหลือ คำแนะนำ และกำลังใจจากหลายฝ่าย ข้าพเจ้าขอกราบขอบพระคุณ รองศาสตราจารย์ ดร.พนมขวัญ ริยะมงคล อาจารย์ที่ปรึกษา ที่ได้ให้คำแนะนำและข้อเสนอแนะอันเป็นประโยชน์ตลอดระยะเวลาการทำปริญญานิพนธ์ฉบับนี้ ข้าพเจ้ารู้สึกซาบซึ้งในความเอาใจใส่และความกรุณาเป็นอย่างสูง

ขอขอบพระคุณ ผู้ช่วยศาสตราจารย์ รัฐภูมิ วรานุสาสน์ และ Mr. Yoseung KIM คณะกรรมการสอบที่ได้ให้คำแนะนำและข้อคิดเห็นอันมีคุณค่า ซึ่งช่วยให้ปริญญานิพนธ์ฉบับนี้มีความสมบูรณ์ยิ่งขึ้น

สุดท้ายนี้ ข้าพเจ้าขอขอบพระคุณ บิดามารดา ที่คอยให้กำลังใจ สนับสนุน และดูแลเอาใจใส่เสมอมา จนทำให้ข้าพเจ้าสามารถดำเนินการศึกษาและทำปริญญานิพนธ์ฉบับนี้จนสำเร็จลุล่วงไปได้ด้วยดี

คณะผู้ดำเนินโครงงานวิศวกรรม
นายธาดา มุมเสือ
มีนาคม 2568

สารบัญ

หน้า

ใบรับรองปริญญานิพนธ์ ..... ก
บทคัดย่อภาษาไทย ..... ข
บทคัดย่อภาษาอังกฤษ ..... ค
กิตติกรรมประกาศ ..... ง
สารบัญ ..... จ
สารบัญตาราง ..... ญ
สารบัญรูป ..... ฎ
สารบัญสัญลักษณ์และอักษรย่อ ..... ณ

บทที่ 1 บทนำ 1
1.1 ความเป็นมาและความสำคัญของโครงงาน 1
1.2 วัตถุประสงค์ของโครงงาน 2
1.3 ประโยชน์ที่คาดว่าจะได้รับ 2
1.4 ขอบเขตการทำโครงงาน 2
1.5 ขั้นตอนการดำเนินงาน 2
1.6 แผนการดำเนินงาน 3
1.7 รายละเอียดงบประมาณตลอดโครงงาน 3

บทที่ 2 หลักการและทฤษฎีเบื่องต้น 4
2.1 Digital Image Processing 4
2.1.1 หลักการพื้นฐานของภาพดิจิทัล 4
2.1.2 การปรับปรุงคุณภาพของภาพ 4
2.1.3 ปริภูมิสี 4
2.2 Deep Learning 6
2.2.1 Artificial Neural Networks 6
2.2.2 Convolutional Neural Networks 7
2.3 Object Recognition in Images 7
2.3.1 Object Detection 8
2.3.2 Image Segmentation 8
2.3.3 Object Classification 8

สารบัญ (ต่อ)

หน้า

2.4 งานวิจัยที่เกี่ยวข้องกับการรู้จำประเภทและสีของรถ..... 9
2.5 ประเภทของรถยนต์..... 10
2.6 เครื่องมือที่ใช้..... 14
2.6.1 Visual Studio Code..... 14
2.6.2 Python..... 14
2.6.3 YOLO..... 15
2.6.4 Roboflow..... 16
2.6.5 OpenCV..... 16
2.6.6 Tkinter..... 17
2.6.7 Scikit-learn..... 17
2.6.8 PyTorch..... 18
2.6.9 CUDA..... 18
2.6.10 Google Colab..... 19

บทที่ 3 วิธีดำเนินโครงงาน..... 20
3.1 วิเคราะห์งานวิจัยที่เกี่ยวข้อง..... 20
3.1.1 Large-scale Vehicle Re-identification in Urban Surveillance Videos..... 21
3.1.2 Vehicle Color Recognition Using Convolutional Neural Network and Color Histogram..... 21
3.1.3 Development of Feature Detector for Vehicle Make, Model and Color Recognition System used for Suspect Vehicle Detection..... 21
3.2 ภาพรวมของระบบ..... 22
3.3 การสร้างระบบ..... 23
3.3.1 วิเคราะห์การทำงานของระบบรู้จำประเภทและสีของรถจากภาพ..... 23
3.3.2 ออกแบบการทำงานของระบบรู้จำประเภทและสีของรถจากภาพ..... 23
3.3.3 การสร้างระบบรู้จำประเภทและสีของรถจากภาพ..... 24
3.4 การจัดเตรียมสภาพแวดล้อมสำหรับระบบรู้จำประเภทและสีของรถจากภาพ..... 26
3.4.1 ติดตั้งโปรแกรมคอมพิวเตอร์..... 26
3.4.2 ติดตั้งไลบรารี่ในภาษา Python..... 27

สารบัญ (ต่อ)

หน้า

3.5 วิเคราะห์และอกอแบบการจำแนกประเภทรถ..... 27
3.5.1 ประเภทของรถยนต์ที่ใช้ในการจำแนก.....28
3.5.2 แหล่งที่มาของข้อมูล..... 41
3.6 การจัดหารูปภาพและสร้าง Dataset สำหรับเทรนโมเดล..... 42
3.6.1 การจัดหารูปภาพ..... 42
3.6.2 การสร้าง Dataset..... 42
3.7 การเทรนโมเดลตรวจจับและจำแนกวัตถุสำหรับการตรวจจับและจำแนกรถ..... 43
3.7.1 โมเดล Object Detection..... 43
3.7.2 โมเดล Image Classification..... 44
3.8 การเทรนโมเดลตรวจจับล้อรถในภาพและการหาจุดที่สนใจในภาพเพื่อระบุสี..... 44
3.9 การปรับแสงภาพที่มีความสว่างมากหรือน้อยเกินไป..... 45
3.9.1 การคำนวณค่าความสว่างของภาพ..... 46
3.9.2 การเพิ่มความสว่างของภาพ..... 46
3.9.3 การลดความสว่างของภาพ..... 30
3.10 วิเคราะห์สีรถและการจำแนกสีรถ..... 45
3.10.1 กลุ่มสีที่มีสี..... 46
3.10.2 กลุ่มสีที่ไม่มีสี..... 54
3.11 การจำแนกสีของรถ..... 59
3.11.1 การเบลอภาพ..... 59
3.11.2 การแปลงภาพให้อยู่ในรูปแบบสี HSV..... 59
3.11.3 การระบุค่า HSV ของภาพด้วย K-Means Clustering.....59
3.11.4 การระบุชื่อของสีโดยการเปรียบเทียบค่า HSV.....59
3.11.5 การระบุชื่อสีโดยการเปรียบเทียบค่า HSV ร่วมกับ K-Means Clustering.....60
3.12 ทดสอบการระบุชื่อสีโดยการเปรียบเทียบค่า HSV ร่วมกับ K-Means Clustering.....61
3.13 การทำงานของโปรแกรมโดยรวม..... 62
3.13.1 การเริ่มต้นโปรแกรม..... 62
3.13.2 การกำหนดค่าเพื่อเริ่มต้นการประมวลผล..... 63
3.13.3 การประมวลผล.....66
3.13.4 การแสดงผลลัพธ์..... 67
3.13.5 การส่งออกและบันทึกผลลัพธ์..... 68

สารบัญ (ต่อ)

หน้า

3.14 การเตรียมวิดีโอเพื่อใช้ในการทดสอบ..... 72
3.15 การทดสอบการทำงานของโปรแกรม..... 72

บทที่ 4 ผลการทดลองและวิเคราะห์..... 73
4.1 ผลการทดสอบเพื่อหาวิธีในการปรับแสงภาพ..... 73
4.1.1 ผลการปรับค่า L ด้วยตัวเอง..... 73
4.1.2 ผลการทดสอบโดยสังเกตค่า มัธยฐานและค่าเฉลี่ยนที่ถูกตัดขอบ 5% ของค่า L จากรูปภาพในสถานที่จริง..... 74
4.2 ผลการทดสอบการแยะแยกประเภทของรถด้วยโมเดล Yolo..... 75
4.3 ผลการทดสอบโมเดลตรวจจับล้อรถและการวิเคราะพื้นที่ที่สนใจ..... 79
4.3.1 ผลการทดสอบโมเดลตรวจจับล้อรถ..... 79
4.3.2 ผลการวิเคราะห์พื้นที่ที่สนใจ..... 80
4.4 ผลการทดสอบการปรับแสงภาพ..... 80
4.5 ผลการทดสอบการจำแนกสีจากภาพ..... 82
4.6 ผลการทดสอบการทำงานของโปรแกรม..... 85

บทที่ 5 บทสรุปและข้อเสนอแนะ..... 96
5.1 สรุปผล..... 96
5.1.1 สรุปผลลการระบุประเภทของรถ..... 96
5.1.2 สรุปผลการระบุประสีของรถโดยใช้ค่า HSV..... 96
5.1.3 สรุปผลการทำงานของโปรแกรมโดยรวม..... 96
5.1.4 ปัญหาและอุปสรรค..... 97
5.1.5 สรุปผลลัพธ์ของโปรเจค..... 98
5.1.6 แนวทางการแก้ไขปัญหาในอนาคต..... 99
5.2 ข้อเสนอแนะ..... 101
5.2.1 การใช้ CUDA และการปรับแต่งการเทรนโมเดล YOLO..... 101
5.2.2 การใช้งาน Google Colab และข้อจำกัดของระบบ Cloud..... 101
5.2.3 การเพิ่มปริมาณและความหลากหลายของข้อมูลในการเทรน 101
5.2.4 การใช้และปรับแต่ง HSV color space สำหรับการจำแนกสีรถ 101
5.2.5 การใช้และปรับแต่ง HSV color space สำหรับการจำแนกสีรถ 101

สารบัญ (ต่อ)

หน้า

5.2.6 การทดสอบและปรับปรุงระบบให้เหมาะสมกับสภาพแวดล้อมจริง 101

เอกสารอ้างอิง..... 102

ภาคผนวก ก..... 104
ภาคผนวก ข..... 107
ภาคผนวก ค..... 115
ภาคผนวก ง..... 114
ภาคผนวก จ..... 117
ภาคผนวก ช..... 126

สารบัญตาราง

ตารางที่ หน้า

1.1 ตารางแสดงแผนการดำเนินงาน..... 3

4.1 ผลการทดสอบโดยสังเกตค่า มัธยฐานและค่าเฉลี่ยนที่ถูกตัดขอบ 5% ของค่า L จากรูปภาพในสถานที่จริง.....74

4.2 ผลการทดสอบการทำงานของโปรแกรมในเวลากลางวัน..... 85

4.3 ผลการทดสอบการทำงานของโปรแกรมในเวลากลางคืน..... 92

4.4 ผลการทดสอบการทำงานของโปรแกรม..... 93

4.5 ความถูกต้องในการระบุประเภทรถในสถานที่จริงจากผลการทดสอบการทำงานของโปรแกรม..... 94

4.6 ความถูกต้องในการระบุสีรถในสถานที่จริงจากผลการทดสอบการทำงานของโปรแกรม..... 95

5.1 ปัญหาและอุปสรรค..... 97

5.2 แนวทางการแก้ไขปัญหาในอนาคต..... 99

สารบัญรูป

รูปที่ หน้า
2.1 ปริภูมิสี RGB 5
2.2 ปริภูมิสี HSV 5
2.3 Sedan 10
2.4 Convertible 10
2.5 SUV 11
2.6 LC Coupe 11
2.7 Convertible 12
2.8 Van 12
2.9 Truck 13
2.10 Bus 14
2.11 Visual Studio Code 14
2.12 Python 15
2.13 YOLO 15
2.14 Roboflow 16
2.15 OpenCV 17
2.16 Tkinter 17
2.17 scikit-learn 18
2.18 pytorch 18
2.19 CUDA 19
2.20 Google Colab 19
3.1 ภาพรวมของระบบ 22
3.2 ขั้นตอนการดำเนินโครงงาน 23
3.3 การทำงานของระบบ 24
3.4 แนวทางการพัฒนาและออกแบบระบบ 25
3.5 ตัวอย่าง Convertible (1) 28
3.6 ตัวอย่าง Convertible (2) 28
3.7 ตัวอย่าง Convertible (3) 29
3.8 ตัวอย่าง Coupe (1) 29
3.9 ตัวอย่าง Coupe (2) 30
3.10 ตัวอย่าง Coupe (3) 30

สารบัญรูป(ต่อ)

รูปที่ หน้า
3.11 ตัวอย่าง Hatchback (1)..... 31
3.12 ตัวอย่าง Hatchback (2)..... 31
3.13 ตัวอย่าง Hatchback (3)..... 31
3.14 ตัวอย่าง Sedan (1)..... 32
3.15 ตัวอย่าง Sedan (2)..... 32
3.16 ตัวอย่าง Sedan (3)..... 33
3.17 ตัวอย่าง Pick-Up (1)..... 33
3.18 ตัวอย่าง Pick-Up (2)..... 34
3.19 ตัวอย่าง Pick-Up (3)..... 34
3.20 ตัวอย่าง SUV (1)..... 35
3.21 ตัวอย่าง SUV (2)..... 35
3.22 ตัวอย่าง SUV (3)..... 36
3.23 ตัวอย่าง Truck (1)..... 36
3.24 ตัวอย่าง Truck (2)..... 37
3.25 ตัวอย่าง Truck (3)..... 38
3.26 ตัวอย่าง Van (1)..... 39
3.27 ตัวอย่าง Van (2)..... 39
3.28 ตัวอย่าง Van (3)..... 40
3.29 ตัวอย่าง Bus..... 40
3.30 ตัวอย่าง Motorcycle..... 41
3.31 ตัวอย่างการระบุจุดที่สนใจ..... 45
3.32 ตัวอย่างเฉดสีแดง(1)..... 47
3.33 ตัวอย่างเฉดสีแดง(2)..... 48
3.34 ตัวอย่างรถสีแดง..... 48
3.35 ตัวอย่างเฉดสีน้ำตาล..... 49
3.36 ตัวอย่างรถสีน้ำตาล..... 49
3.37 ตัวอย่างเฉดสีเหลือง..... 50
3.38 ตัวอย่างรถสีเหลือง..... 50
3.39 ตัวอย่างเฉดสีเขียว..... 51
3.40 ตัวอย่างรถสีเขียว..... 51

สารบัญรูป(ต่อ)

รูปที่ หน้า
3.41 ตัวอย่างเฉดสีน้ำเงิน..... 52
3.42 ตัวอย่างรถสีน้ำเงิน..... 52
3.43 ตัวอย่างเฉดสีม่วง..... 53
3.44 ตัวอย่างรถสีม่วง..... 53
3.45 ตัวอย่างเฉดสีชมพู..... 54
3.46 ตัวอย่างรถสีชมพู..... 54
3.47 ตัวอย่างเฉดสีขาว..... 55
3.48 ตัวอย่างรถสีขาว..... 55
3.49 ตัวอย่างเฉดสีดำ..... 56
3.50 ตัวอย่างรถสีดำ..... 56
3.51 ตัวอย่างเฉดสีเทา..... 57
3.52 ตัวอย่างรถสีเทา..... 57
3.53 ตัวอย่างเฉดสีเงิน..... 58
3.54 ตัวอย่างรถสีเงิน..... 58
3.55 การเปรียบเทียบค่า HSV..... 60
3.56 การระบุชื่อสีโดยการเปรียบเทียบค่า HSV ร่วมกับ K-Means Clustering..... 60
3.57 ไฟล์ run.py.....62
3.58 หน้าตาของโปรแกรม.....63
3.59 การนำเข้าวิดีโอ.....64
3.60 ตัวอย่างการกำหนดค่าเพื่อเริ่มประมวลผล..... 65
3.61 หน้าต่างระหว่างประมวลผล..... 66
3.62 หน้าต่างแสดงผลลัพธ์..... 67
3.63 การบันทึกไฟล์ในรูปแบบ .plk 68
3.64 การบันทึกไฟล์เป็นตาราง Excel 69
3.65 ตัวอย่างของตาราง Excel ที่บันทึก..... 69
3.66 หน้าเริ่มต้นของโปรแกรม..... 70
3.67 การโหลดไฟล์ .plk 71
3.68 หน้าต่างแสดงผลลัพธ์..... 71
4.1 การปรับค่า L เพื่อสังเกตความเปลี่ยนแปลง..... 73
4.2 Confusion Matrix ในการแยกประเภทของรถในรูปแบบต่าง ๆ..... 76

สารบัญรูป(ต่อ)

รูปที่ หน้า
4.3 Confusion Matrix ในการตรวจจับล้อรถ 79
4.4 ผลการวิเคราะห์พื้นที่ที่สนใจในภาพ 80
4.5 ผลการปรับลดแสงในภาพสว่าง 80
4.6 ผลการปรับเพิ่มแสงในภาพมืด 81
4.7 Confusion Matrix ของระบบจำแนกสีของรถโดยใช้การแยกสีผ่านค่าสีในระบบ HSV 82
ก.1 ตัวอย่างรูปภาพที่ใช้ในการเทรนโมเดลตรวจจับล้อ 104
ก.2 ตัวอย่างรูปภาพที่ใช้ในการเทรนโมเดลแยกแยะประเภทรถ(1) 104
ก.3 ตัวอย่างรูปภาพที่ใช้ในการเทรนโมเดลแยกแยะประเภทรถ(2) 105
ก.4 ตัวอย่างรูปภาพที่ใช้ในการเทรนโมเดลแยกแยะประเภทรถ(3) 105
ก.5 ตัวอย่างรูปภาพที่ใช้ในการเทรนโมเดลแยกแยะประเภทรถ(4) 106
ก.6 ตัวอย่างรูปภาพที่ใช้ในการเทรนโมเดลแยกแยะประเภทรถ(5) 106
ข.1 ข้อมูลสำหรับทดสอบการระบุสีรถสีดำ 107
ข.2 ข้อมูลสำหรับทดสอบการแยกสีรถสีนำเงิน 107
ข.3 ข้อมูลสำหรับทดสอบการแยกสีรถสีน้ำตาล 108
ข.4 ข้อมูลสำหรับทดสอบการแยกสีรถสีเทา 109
ข.5 ข้อมูลสำหรับทดสอบการแยกสีรถสีเขียว 109
ข.6 ข้อมูลสำหรับทดสอบการแยกสีรถสีชมพู 110
ข.7 ข้อมูลสำหรับทดสอบการแยกสีรถสีม่วง 110
ข.8 ข้อมูลสำหรับทดสอบการแยกสีรถสีแดง 111
ข.9 ข้อมูลสำหรับทดสอบการแยกสีรถสีเงิน 111
ข.10 ข้อมูลสำหรับทดสอบการแยกสีรถสีขาว 112
ข.11 ข้อมูลสำหรับทดสอบการแยกสีรถสีเหลือง 112
ค.1 ตัวอย่างภาพวิดีโอในตอนกลางวัน 113
ค.2 ตัวอย่างภาพวิดีโอในตอนกลางคืน 113
ง.1 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(1) 114
ง.2 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(2) 114
ง.3 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(3) 114
ง.4 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(4) 114
ง.5 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(5) 115
ง.6 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(6) 115

สารบัญรูป(ต่อ)

รูปที่ หน้า
ง.7 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(7).....115
ง.8 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(8).....116
ง.9 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(9)..... 116
ง.10 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(10)..... 116
จ.1 ผลการทดลองการปรับแสงในภาพสว่าง(1).....117
จ.2 ผลการทดลองการปรับแสงในภาพสว่าง(2)..... 117
จ.3 ผลการทดลองการปรับแสงในภาพสว่าง(3).....118
จ.4 ผลการทดลองการปรับแสงในภาพสว่าง(4).....118
จ.5 ผลการทดลองการปรับแสงในภาพสว่าง(5)..... 118
จ.6 ผลการทดลองการปรับแสงในภาพสว่าง(6)..... 119
จ.7 ผลการทดลองการปรับแสงในภาพสว่าง(7)..... 119
จ.8 ผลการทดลองการปรับแสงในภาพสว่าง(8)..... 119
จ.9 ผลการทดลองการปรับแสงในภาพสว่าง(9)..... 120
จ.10 ผลการทดลองการปรับแสงในภาพสว่าง(10)..... 120
จ.11 ผลการทดลองการปรับแสงในภาพมืด(1).....121
จ.12 ผลการทดลองการปรับแสงในภาพมืด(2).....121
จ.13 ผลการทดลองการปรับแสงในภาพมืด(3)..... 121
จ.14 ผลการทดลองการปรับแสงในภาพมืด(4).....122
จ.15 ผลการทดลองการปรับแสงในภาพมืด(5)..... 122
จ.16 ผลการทดลองการปรับแสงในภาพมืด(6)..... 123
จ.17 ผลการทดลองการปรับแสงในภาพมืด(7)..... 123
จ.18 ผลการทดลองการปรับแสงในภาพมืด(8)..... 124
จ.19 ผลการทดลองการปรับแสงในภาพมืด(9).....124
จ.20 ผลการทดลองการปรับแสงในภาพมืด(10)..... 125
ช.1 โปรแกรมสำหรับตรวจสอบวิดีโอด้วยมือและตาเปล่า(1)..... 126
ช.2 โปรแกรมสำหรับตรวจสอบวิดีโอด้วยมือและตาเปล่า(2)..... 126

สารบัญสัญลักษณ์และอักษรย่อ

L_{median} = Median of Luminance

$L_{terimed\ mean}$ = Terimed Mean of Luminance

L_{new} = New Luminance

L = Luminance

K = Kernal

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของโครงงาน

ในปัจจุบันการใช้ยานพาหนะเป็นสิ่งจำเป็นอย่างยิ่งในชีวิตประจำวัน ทั้งในเรื่องการเดินทาง การขนส่งสินค้า และการปฏิบัติงานต่างๆ นอกจากการใช้งานแล้ว การติดตามและตรวจสอบยานพาหนะยังมีความสำคัญอย่างมากในด้านความปลอดภัย โดยเฉพาะอย่างยิ่งในกรณีที่ต้องการติดตามรถที่ต้องสงสัยหรือเกี่ยวข้องกับอาชญากรรม เพื่อเพิ่มประสิทธิภาพและลดความผิดพลาดในการตรวจสอบ การใช้เทคโนโลยีในการช่วยระบุประเภทและสีของรถจึงกลายเป็นเรื่องที่มีความสำคัญ

การพัฒนาระบบรู้จำประเภทและสีของรถจากภาพเป็นขั้นตอนสำคัญที่จะช่วยให้การตรวจสอบและติดตามยานพาหนะเป็นไปอย่างมีประสิทธิภาพมากขึ้น โดยโปรแกรมคอมพิวเตอร์ที่พัฒนาขึ้นนี้ใช้เทคนิคการประมวลผลภาพ (Image Processing) และการเรียนรู้เชิงลึก (Deep Learning) เพื่อตรวจจับและระบุยานพาหนะจากภาพถ่ายหรือวิดีโออย่างแม่นยำ ระบบนี้สามารถทำการวิเคราะห์ข้อมูลจากภาพและวิดีโอเพื่อระบุประเภทและสีของรถได้อย่างรวดเร็วและถูกต้อง ซึ่งเป็นการเพิ่มประสิทธิภาพในการตรวจสอบยานพาหนะ

ดังนั้นคณะผู้จัดทำจึงเลือกพัฒนาระบบนี้ร่วมกับเทคนิคการประมวลผลภาพ (Image Processing) และการเรียนรู้เชิงลึก (Deep Learning) เพื่อช่วยให้ผู้ใช้งานสามารถตรวจสอบรถที่ต้องสงสัยได้รวดเร็วยิ่งขึ้น โดยการระบุประเภทและสีของรถจากภาพหรือวิดีโอ และแสดงผลออกมาเป็นรายงานที่ชัดเจน ทำให้การตรวจสอบเป็นไปอย่างรวดเร็วและลดเวลาที่ต้องใช้ในการวิเคราะห์วิดีโอด้วยตนเอง นอกจากนี้ยังช่วยลดความเสี่ยงจากการผิดพลาดที่อาจเกิดขึ้นในการประมวลผลข้อมูลด้วยตาเปล่า

1.2 วัตถุประสงค์ของโครงงาน

1.2.1 เพื่อพัฒนาระบบรู้จำประเภทและสีของรถจากภาพ

1.3 ประโยชน์ที่คาดว่าจะได้รับ

1.3.1 ได้ระบบที่สามารถระบุได้ว่ารถเป็นรถประเภทอะไรและมีสีอะไรอย่างแม่นยำ

1.3.2 สามารถลดระยะเวลาในการตามหารถตามเงื่อนไขจากวิดีโอ

1.3.3 ข้อมูลที่ได้จากโครงงานสามารถนำปพัฒนาต่อยอดได้ในอนาคต

1.4 ขอบเขตการทำโครงงาน

1.4.1 ระบุประเภทและสีของรถที่พบในวดีโอได้อย่างแม่นยำ

1.4.2 ระบุประเภทรถที่ต้องการค้นหาเพื่อแสดงผลลัพธ์ได้

1.4.3 แสดงผลลัพธ์เป็นเป็นรายง่านผลเพื่อความรวดเร็วในการตรวจสอบ

1.4.4 มีการแสดงผลแบบ UI เพื่อง่ายต่อการใช้งาน

1.5 ขั้นตอนการดำเนินงาน

1.5.1 กำหนดหัวข้อโครงงาน

1.5.2 ศึกษาข้อมูลพื้นฐานและเตรียมข้อมูลที่เกี่ยวข้อง

1.5.3 วางแผนและออกแบบโครงสร้างของระบบ

1.5.4 ออกแบบและพัฒนาระบบรู้จำ

1.5.5 พัฒนาและทดสอบโปรแกรมคอมพิวเตอร์

1.5.6 ทดสอบและปรับปรุงโมเดลและโปรแกรมคอมพิวเตอร์

1.5.7 บันทึกผลและสรุปการทำงาน

1.5.8 จัดทำเอกสารปริญญานิพนธ์

1.6 แผนการดำเนินงาน

ตารางที่ 1.1 ตารางแสดงแผนการดำเนินงาน

รายละเอียดการดำเนินงาน	ช่วงเวลาการดำเนินงาน						
	พ.ศ. 2567			พ.ศ. 2568			
	ต.ค.	พ.ย.	ธ.ค.	ม.ค.	ก.พ.	มี.ค.	เม.ย.
1.กำหนดหัวข้อโครงงาน							
2.ศึกษาข้อมูลพื้นฐานและเตรียมข้อมูลที่เกี่ยวข้อง							
3.วางแผนและออกแบบระบบ							
4.ออกแบบและพัฒนาระบบรู้จำ							
5.พัฒนาและทดสอบโปรแกรมคอมพิวเตอร์							
6.ทดสอบและปรับปรุงโมเดลและโปรแกรมคอมพิวเตอร์							
7.บันทึกผลและสรุปการทำงาน							
8.จัดทำเอกสารปริญญานิพนธ์							

1.7 รายละเอียดงบประมาณตลอดโครงงาน

1. ค่าเอกสาร 500 บาท

2. ค่าเครื่องมือ 500 บาท

รวมเป็นเงิน 1000 บาท (หนึ่งพันบาทถ้วน)

บทที่ 2
หลักการและทฤษฎีเบื้องต้น

2.1 Digital Image Processing

การประมวลผลภาพดิจิทัล (Digital Image Processing) [1][2] เป็นสาขาหนึ่งของวิทยาการคอมพิวเตอร์และวิศวกรรมที่เกี่ยวข้องกับการจัดการและวิเคราะห์ข้อมูลภาพโดยใช้เทคนิคทางคณิตศาสตร์และอัลกอริทึม มีบทบาทสำคัญในการพัฒนาระบบรู้จำประเภทและสีของวัตถุจากภาพ รวมถึงการประยุกต์ใช้ในด้านต่างๆ เช่น การแพทย์ การสำรวจระยะไกล และระบบรักษาความปลอดภัย

2.1.1 หลักการพื้นฐานของภาพดิจิทัล

ภาพดิจิทัลเป็นการแทนค่าของฟังก์ชันความเข้มแสงสองมิติ f(x,y) โดยที่ x และ y เป็นพิกัดเชิงระนาบ และค่าของฟังก์ชัน f ณ จุดใดๆ (x,y) คือค่าความเข้มหรือระดับสีของภาพ ณ จุดนั้น [1] ในทางปฏิบัติ ภาพดิจิทัลถูกแทนด้วยเมทริกซ์ขนาด M x N โดยที่แต่ละองค์ประกอบของเมทริกซ์เรียกว่า พิกเซล (Pixel)

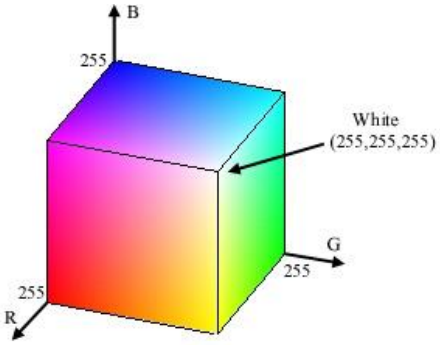
2.1.2 การปรับปรุงคุณภาพของภาพ

การปรับปรุงคุณภาพของภาพ คือกระบวนการปรับแต่งหรือเปลี่ยนแปลงลักษณะของภาพดิจิทัลเพื่อให้ดูชัดเจนและสวยงามยิ่งขึ้น หรือเพื่อให้ได้ข้อมูลที่สำคัญจากภาพมากขึ้น การปรับปรุงนี้สามารถทำได้หลายวิธีขึ้นอยู่กับจุดประสงค์ เช่น การเพิ่มความคมชัดของขอบภาพ (Sharpening) การลดเสียงรบกวน (Noise Reduction) หรือการปรับปรุงคอนทราสต์ (Contrast Enhancement) วิธีการเหล่านี้มีการใช้หลากหลายอัลกอริทึมและเทคนิคในการประมวลผลภาพ เช่น การใช้ฟิลเตอร์เชิงพื้นที่ (Spatial Filtering) และการปรับปรุงภาพในโดเมนความถี่ (Frequency Domain) โดยแต่ละเทคนิคจะมีข้อดีและข้อเสียต่างกัน การปรับแต่งภาพอาจทำได้แบบเรียลไทม์หรือหลังการบันทึกภาพ เช่น การปรับแสงสว่างให้เหมาะสม การใช้การแปลงภาพแบบฮิสโตแกรมเพื่อขยายคอนทราสต์ หรือการลดขอบที่เบลอโดยใช้ฟิลเตอร์ที่เน้นขอบเขต

2.1.3 ปริภูมิสี

ปริภูมิสี [2] คือระบบที่ใช้ในการแสดงและจำแนกสีต่าง ๆ ในเชิงคณิตศาสตร์ โดยการแสดงสีในแต่ละปริภูมิสีนั้นจะมีมิติหรือช่องทางที่แตกต่างกันออกไปตามลักษณะของการใช้งาน โดยทั่วไปปริภูมิสีจะมีการอ้างอิงถึงการแยกสีออกเป็นองค์ประกอบพื้นฐาน ซึ่งช่วยให้สามารถกำหนดสีในภาพดิจิทัลได้อย่างมีประสิทธิภาพ

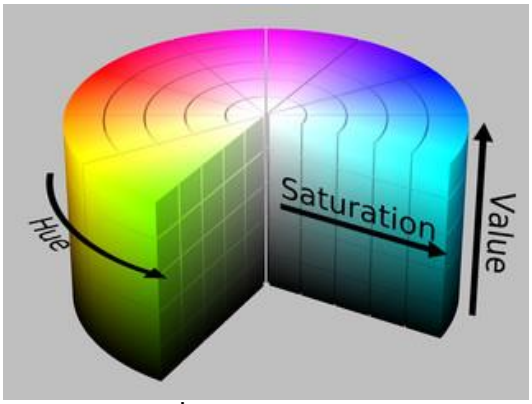
หนึ่งในปริภูมิสีที่พบมากที่สุดคือ RGB ซึ่งย่อมาจากสีแดง (Red), สีเขียว (Green), และสีน้ำเงิน (Blue) ในระบบนี้ สีทั้งหมดจะเกิดจากการผสมสีทั้งสามเข้าด้วยกันโดยมีค่าอยู่ระหว่าง 0 ถึง 255 ปริภูมิสีนี้ถูกใช้งานในอุปกรณ์แสดงผลเช่นจอคอมพิวเตอร์ กล้องดิจิทัล และโทรทัศน์



รูปที่ 2. 1 ปริภูมิสี RGB

นอกจาก RGB แล้วยังมีปริภูมิสีอื่น ๆ ที่ใช้งานกันอย่างแพร่หลาย เช่น CMYK ซึ่งย่อมาจาก Cyan, Magenta, Yellow, และ Key (Black) โดย ปริภูมิสีนี้จะเน้นการสร้างสีที่เหมาะสมสำหรับการทำงานกับสื่อสิ่งพิมพ์มากกว่า

อีกปริภูมิสีที่สำคัญคือ HSV (Hue, Saturation, Value) ซึ่งแบ่งสีออกเป็นสามองค์ประกอบ คือ Hue หมายถึงเฉดสี (เช่น แดง, เขียว, น้ำเงิน), Saturation คือความอิ่มตัวของสี แสดงถึงความเข้มหรืออ่อนของสี, และ Value แสดงความสว่างหรือมืดของสี ปริภูมิสีนี้ถูกใช้อย่างมากในการปรับแต่งและแก้ไขสีในการประมวลผลภาพ เพราะเข้าใจง่ายและสามารถควบคุมแยกแต่ละลักษณะของสีได้อย่างมีประสิทธิภาพ



รูปที่ 2. 2 ปริภูมิสี HSV

YUV เป็นอีกปริภูมิสีที่มักใช้ในงานวีดีโอและโทรทัศน์ โดยจะแบ่งสีออกเป็นส่วนสว่าง (Luma, Y) และส่วนของสีที่แตกต่างกันสองส่วน (U และ V) การแยกสีเช่นนี้ช่วยให้การบีบอัดข้อมูลในงานวิดีโอทำได้ดีขึ้น เพราะตาสามารถรับรู้การเปลี่ยนแปลงของความสว่างได้ดีกว่าการเปลี่ยนแปลงของสี

นอกจากนี้ยังมี Lab Color Space ที่ถูกออกแบบมาเพื่อให้สะท้อนการรับรู้ของสีของตามนุษย์ Lab Color จะแบ่งออกเป็นสามมิติ ได้แก่ L* ที่แสดงถึงความสว่าง, a* ที่แสดงถึงความต่างของสีระหว่างเขียวและแดง, และ b* ที่แสดงความต่างของสีระหว่างน้ำเงินและเหลือง ระบบนี้มีประโยชน์ในการใช้ปรับปรุงสีของภาพให้สอดคล้องกับการมองเห็นจริงของมนุษย์

การใช้ปริภูมิสีที่แตกต่างกันจะเหมาะสมกับงานที่แตกต่างกัน เช่น RGB จะเหมาะกับการทำงานดิจิทัลที่เกี่ยวกับหน้าจอ ในขณะที่ CMYK จะถูกใช้ในงานพิมพ์ การเลือกใช้ปริภูมิสีที่เหมาะสมจะช่วยให้การประมวลผลภาพ การพิมพ์ และการปรับแต่งสีมีความแม่นยำและประสิทธิภาพสูงขึ้น

2.2 Deep Learning

การเรียนรู้เชิงลึก (Deep Learning) [3][4] เป็นสาขาย่อยของการเรียนรู้ของเครื่อง (Machine Learning) ที่ใช้โครงข่ายประสาทเทียมหลายชั้น (Multi-layer Neural Networks) ในการเรียนรู้และสกัดคุณลักษณะ (Features) จากข้อมูลโดยอัตโนมัติ [14] เทคนิคนี้ได้รับความนิยมอย่างมากในการประมวลผลภาพและการรู้จำวัตถุ เนื่องจากสามารถเรียนรู้คุณลักษณะที่ซับซ้อนได้โดยไม่ต้องออกแบบคุณลักษณะด้วยมือ

2.2.1 Artificial Neural Networks

โครงข่ายประสาทเทียม (Artificial Neural Networks) คือระบบการคำนวณที่ได้รับแรงบันดาลใจจากการทำงานของสมองมนุษย์ ประกอบด้วยชุดของหน่วยประมวลผลเล็ก ๆ ที่เรียกว่า "โหนด" หรือ "นิวรอน" ซึ่งทำงานร่วมกันอย่างมีลำดับ โครงสร้างพื้นฐานของ ANN มีหลายชั้น (Layers) โดยแต่ละชั้นจะประกอบด้วยนิวรอนที่เชื่อมต่อกันผ่านน้ำหนัก (Weights) ที่ปรับเปลี่ยนได้ ชั้นหลัก ๆ ประกอบด้วยชั้นอินพุต (Input Layer) ซึ่งรับข้อมูลเข้ามา ชั้นซ่อน (Hidden Layer) ที่ทำการประมวลผล และชั้นเอาต์พุต (Output Layer) ที่ส่งผลลัพธ์ออกมา

การทำงานของ ANN เริ่มต้นจากการรับข้อมูลจากชั้นอินพุต จากนั้นข้อมูลจะถูกส่งผ่านแต่ละชั้นโดยคำนวณผ่านสมการเชิงเส้นที่ประกอบด้วยค่าของน้ำหนักที่เชื่อมต่อกันและค่าเอนเอียง (Bias) นิวรอนแต่ละตัวจะใช้ฟังก์ชันกระตุ้น (Activation Function) ในการตัดสินใจว่าจะส่งสัญญาณออกไปยังนิวรอนถัดไปหรือไม่ ฟังก์ชันกระตุ้นที่ใช้บ่อย เช่น ฟังก์ชัน Sigmoid, ReLU (Rectified Linear Unit) และ Tanh

ANN ถูกนำมาใช้ในหลายสาขา เช่น การรู้จำรูปภาพ การแยกแยะเสียง การวิเคราะห์ข้อมูลเชิงตัวเลข และการประมวลผลภาษาธรรมชาติ ความสามารถในการเรียนรู้จากข้อมูลจำนวนมากและ

สามารถจับความสัมพันธ์เชิงซับซ้อนได้ ทำให้ ANN เป็นพื้นฐานของการพัฒนาในด้านปัญญาประดิษฐ์ โดยเฉพาะใน Deep Learning ซึ่งใช้โครงข่ายที่มีชั้นซ่อนหลายชั้น (Deep Neural Networks)

2.2.2 Convolutional Neural Networks

Convolutional Neural Networks (CNNs) หรือโครงข่ายประสาทเชิงคอนโวลูชัน เป็นประเภทหนึ่งของ Artificial Neural Networks ที่ออกแบบมาโดยเฉพาะสำหรับการประมวลผลข้อมูลที่มีรูปแบบเชิงพื้นที่ เช่น ภาพและวิดีโอ โครงสร้างของ CNNs ประกอบด้วยหลายชั้นที่ทำงานร่วมกัน ได้แก่ ชั้นคอนโวลูชัน (Convolutional Layer), ชั้นการรวมข้อมูล (Pooling Layer), และชั้น Fully Connected Layer การออกแบบนี้ช่วยให้ CNNs สามารถตรวจจับคุณลักษณะเฉพาะของข้อมูล เช่น ขอบ, รูปร่าง, และพื้นผิว โดยไม่ต้องอาศัยการคัดเลือกคุณลักษณะด้วยมือ

ในชั้นคอนโวลูชัน กระบวนการสำคัญคือการใช้ฟิลเตอร์ (หรือที่เรียกว่า Kernel) ทำการคอนโวลฟังก์ชันผ่านข้อมูลอินพุต ฟิลเตอร์นี้ทำหน้าที่ตรวจจับคุณสมบัติที่เฉพาะเจาะจง เช่น รูปแบบที่ซ้ำกันหรือโครงสร้างเชิงลึกในภาพ โดยในระหว่างการฝึกโมเดล น้ำหนักของฟิลเตอร์เหล่านี้จะถูกเรียนรู้เพื่อให้เหมาะสมกับปัญหาที่กำลังแก้ไข ข้อมูลที่ผ่านชั้นนี้จะได้รับการแปลงให้อยู่ในรูปแบบของแผนที่คุณลักษณะ (Feature Maps)

จากนั้น ข้อมูลจะถูกส่งผ่านชั้นการรวมข้อมูล (Pooling) ซึ่งจะลดขนาดของแผนที่คุณลักษณะโดยการรวมข้อมูลจากหลายพิกเซลที่อยู่ใกล้เคียงกัน วิธีที่ใช้กันบ่อยคือ Max Pooling ซึ่งจะเลือกค่าสูงสุดจากชุดพิกเซลนั้นเพื่อลดความซับซ้อนของข้อมูลและลดจำนวนพารามิเตอร์ ทำให้โมเดลมีความเร็วมากขึ้นและลดการเกิดการเรียนรู้ที่เกินพอดี (Overfitting)

หลังจากผ่านชั้นคอนโวลูชันและการรวมข้อมูลแล้ว ข้อมูลจะถูกส่งไปยังชั้น Fully Connected ซึ่งทำหน้าที่รวมข้อมูลคุณลักษณะที่ได้จากขั้นตอนก่อนหน้าเพื่อทำการคาดการณ์ผลลัพธ์สุดท้าย เช่น การจัดหมวดหมู่ภาพในประเภทต่าง ๆ

CNNs ได้รับการพิสูจน์แล้วว่ามีประสิทธิภาพสูงในงานประมวลผลภาพและวิดีโอ เช่น การรู้จำวัตถุ (Object Recognition), การจำแนกภาพ (Image Classification), และการตรวจจับวัตถุ (Object Detection) ด้วยความสามารถในการเรียนรู้และจับคุณลักษณะจากข้อมูลภาพที่ซับซ้อน CNNs จึงเป็นหนึ่งในเทคนิคที่สำคัญในด้าน Deep Learning และการประมวลผลภาพ

2.3 Object Recognition in Images

การรู้จำวัตถุในภาพ (Object Recognition in Images) [5][6] เป็นหนึ่งในงานสำคัญของการประมวลผลภาพและการมองเห็นของคอมพิวเตอร์ โดยมีเป้าหมายเพื่อระบุและจำแนกวัตถุที่ปรากฏในภาพดิจิทัล กระบวนการนี้ประกอบด้วยหลายขั้นตอนย่อย ได้แก่ การตรวจจับวัตถุ การแบ่งส่วนภาพ และการจำแนกประเภทวัตถุ ซึ่งแต่ละขั้นตอนมีความสำคัญในการสร้างระบบรู้จำวัตถุที่มีประสิทธิภาพ

2.3.1 Object Detection

การตรวจจับวัตถุ (Object Detection) เป็นขั้นตอนแรกในการระบุตำแหน่งและขอบเขตของวัตถุที่สนใจในภาพ วิธีการนี้มักใช้เทคนิคการประมวลผลภาพเบื้องต้น เช่น การตรวจจับขอบ (Edge Detection) การแยกพื้นหน้าและพื้นหลัง (Foreground-Background Separation) และการหาความแตกต่างของสี (Color Difference) เพื่อระบุบริเวณที่น่าสนใจ (Region of Interest: ROI)

ในปัจจุบัน วิธีการตรวจจับวัตถุที่ได้รับความนิยมอย่างมากคือการใช้โครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Networks: CNNs) ซึ่งสามารถเรียนรู้คุณลักษณะของวัตถุได้โดยอัตโนมัติจากข้อมูลภาพจำนวนมาก ตัวอย่างของอัลกอริทึมที่มีประสิทธิภาพสูง ได้แก่ YOLO (You Only Look Once), SSD (Single Shot Detector) และ Faster R-CNN ซึ่งสามารถตรวจจับวัตถุหลายชนิดในภาพได้อย่างรวดเร็วและแม่นยำ

2.3.2 Image Segmentation

การแบ่งส่วนภาพ (Image Segmentation) เป็นกระบวนการแยกภาพออกเป็นส่วนย่อยๆ ที่มีความหมาย โดยมีเป้าหมายเพื่อแยกวัตถุที่สนใจออกจากพื้นหลังหรือวัตถุอื่นๆ ในภาพ วิธีการแบ่งส่วนภาพสามารถแบ่งได้เป็นสองประเภทหลัก คือ การแบ่งส่วนภาพแบบความหมาย (Semantic Segmentation) และการแบ่งส่วนภาพแบบอินสแตนซ์ (Instance Segmentation)

การแบ่งส่วนภาพแบบความหมายจะกำหนดป้ายกำกับ (Label) ให้กับแต่ละพิกเซลในภาพตามประเภทของวัตถุที่พิกเซลนั้นเป็นส่วนหนึ่ง โดยไม่แยกแยะระหว่างวัตถุที่เป็นประเภทเดียวกัน [26] ในขณะที่การแบ่งส่วนภาพแบบอินสแตนซ์จะแยกแยะวัตถุแต่ละชิ้นออกจากกัน แม้จะเป็นประเภทเดียวกันก็ตาม

เทคนิคการแบ่งส่วนภาพที่ใช้กันอย่างแพร่หลายในปัจจุบันมักอาศัยโครงข่ายประสาทเทียมแบบคอนโวลูชัน เช่น U-Net, Mask R-CNN และ DeepLab ซึ่งสามารถให้ผลลัพธ์ที่มีความละเอียดสูงและมีความแม่นยำในการแบ่งส่วนภาพ

2.3.3 Object Classification

การจำแนกประเภทวัตถุ (Object Classification) เป็นขั้นตอนสุดท้ายของการรู้จำวัตถุ โดยมีจุดมุ่งหมายเพื่อระบุว่าวัตถุที่ตรวจพบในภาพนั้นเป็นวัตถุประเภทใด กระบวนการนี้มักประกอบด้วยสองขั้นตอนหลัก คือ การสกัดคุณลักษณะ (Feature Extraction) และการจำแนกประเภท (Classification)

การสกัดคุณลักษณะเป็นการดึงข้อมูลสำคัญที่ใช้ในการจำแนกประเภทวัตถุออกมาจากภาพ เช่น รูปร่าง สี พื้นผิว หรือโครงสร้างของวัตถุ ในอดีต การสกัดคุณลักษณะมักใช้วิธีการที่ออกแบบด้วยมือ เช่น SIFT (Scale-Invariant Feature Transform), HOG (Histogram of Oriented

Gradients) หรือ LBP (Local Binary Patterns) แต่ในปัจจุบัน การใช้โครงข่ายประสาทเทียมแบบคอนโวลูชันสามารถเรียนรู้การสกัดคุณลักษณะที่เหมาะสมได้โดยอัตโนมัติจากข้อมูลภาพจำนวนมาก

ขั้นตอนการจำแนกประเภทจะนำคุณลักษณะที่สกัดได้มาใช้ในการตัดสินใจว่าวัตถุนั้นเป็นประเภทใด โดยอาศัยอัลกอริทึมการเรียนรู้ของเครื่อง (Machine Learning) เช่น Support Vector Machines (SVM), Random Forests หรือ Neural Networks ในกรณีที่ใช้โครงข่ายประสาทเทียมแบบคอนโวลูชัน การจำแนกประเภทมักทำโดยใช้ชั้น Fully Connected Layer ที่ต่อท้ายชั้น Convolutional Layers

2.4 งานวิจัยที่เกี่ยวข้องกับการรู้จำประเภทและสีของรถ

2.4.1 Large-scale Vehicle Re-identification in Urban Surveillance Videos [8]

Liu และคณะ นำเสนอวิธีการจำแนกประเภทรถโดยใช้เทคนิคการเรียนรู้เชิงลึกแบบหลายมุมมอง (Multi-view Deep Learning) โดยใช้ภาพรถจากหลายมุมมองเพื่อสร้างโมเดลที่มีความทนทานต่อการเปลี่ยนแปลงของมุมมอง วิธีการนี้สามารถจำแนกประเภทรถได้ถึง 196 รุ่น โดยมีความแม่นยำ 93.1% บนชุดข้อมูล Stanford Cars Dataset

2.4.2 Vehicle Color Recognition Using Convolutional Neural Network and Color Histogram [9]

Chen และคณะ นำเสนอวิธีการรู้จำสีรถโดยใช้เทคนิคการเรียนรู้เชิงลึกร่วมกับการวิเคราะห์ฮิสโตแกรมสี โดยใช้โมเดล CNN ในการสกัดคุณลักษณะสีจากภาพรถ และใช้การวิเคราะห์ฮิสโตแกรมในปริภูมิสี HSV เพื่อปรับปรุงความแม่นยำในการจำแนกสี วิธีการนี้สามารถจำแนกสีรถได้ 10 สีหลัก โดยมีความแม่นยำ 94.5% บนชุดข้อมูลที่สร้างขึ้นเอง

2.4.3 Development of Feature Detector for Vehicle Make, Model and Color Recognition System used for Suspect Vehicle Detection [10]

ผกา เก ษ และ วั ตุ ยา ได้นำเสนอการพัฒนาตัวตรวจจับคุณลักษณะเฉพาะสำหรับระบบการรู้จำยี่ห้อ รุ่น และสีของรถยนต์ เพื่อใช้ในการตรวจจับรถต้องสงสัย งานวิจัยนี้มุ่งเน้นการพัฒนาระบบที่สามารถระบุคุณลักษณะเฉพาะของยานพาหนะได้อย่างละเอียด โดยใช้เทคนิคการเรียนรู้เชิงลึกร่วมกับการวิเคราะห์คุณลักษณะเฉพาะของยานพาหนะ เช่น รูปทรงของไฟหน้า ลักษณะของกระจังหน้า และรูปแบบของล้อ ระบบที่พัฒนาขึ้นสามารถระบุยี่ห้อ รุ่น และสีของรถยนต์ได้อย่างแม่นยำ โดยมีความแม่นยำในการระบุยี่ห้อและรุ่นร้อยละ 95.3 และความแม่นยำในการระบุสีร้อยละ 97.1 นอกจากนี้ ระบบยังสามารถทำงานได้ในเวลาจริง ทำให้มีศักยภาพในการนำไปประยุกต์ใช้ในระบบรักษาความปลอดภัยและการตรวจจับยานพาหนะต้องสงสัย

2.5 ประเภทของรถยนต์ [11]

การใช้ Convolutional Neural Networks (CNNs) ในการจำแนกรถยนต์สามารถจัดแยกประเภทของรถยนต์ออกเป็นหลายกลุ่มตามลักษณะทางกายภาพ ดังนี้

Sedan รถยนต์ที่มีลักษณะเป็นรถนั่งส่วนบุคคลขนาดกลางหรือใหญ่ มีที่นั่งเรียงสองแถว รองรับผู้โดยสารได้ 4-5 คน CNN สามารถแยกแยะได้จากโครงสร้างยาวและเรียบของรถ พร้อมกับส่วนท้ายที่ยื่นออกมา



รูปที่ 2. 3 Sedan

Hatchback รถยนต์ที่มีพื้นที่เก็บของที่รวมอยู่กับห้องโดยสาร โดยส่วนท้ายของรถจะเปิดออกมาทั้งบานประตู CNN สามารถแยกแยะได้จากขนาดที่เล็กกว่าและท้ายรถที่สั้นกว่าเมื่อเทียบกับ Sedan



รูปที่ 2. 4 Hatchback

SUV (Sport Utility Vehicle) รถยนต์ที่มีขนาดใหญ่และตัวถังที่สูง เหมาะสำหรับการขับในเส้นทางที่ไม่ราบเรียบ CNN สามารถแยกแยะจากโครงสร้างขนาดใหญ่และหลังคาที่สูง



รูปที่ 2. 5 SUV

Coupe รถยนต์ที่มีที่นั่งเพียง 2 ประตูและมีขนาดเล็กและกะทัดรัดกว่า Sedan CNN สามารถแยกแยะได้จากรูปร่างที่เตี้ยและส่วนท้ายที่โค้งมน



รูปที่ 2. 6 Coupe

Convertible รถยนต์ที่สามารถเปิดหลังคาได้ โดย CNN สามารถแยกแยะได้จากโครงสร้างที่ส่วนบนสามารถเปิด-ปิดได้และลักษณะเปิดโล่งเมื่อเปิดหลังคา



รูปที่ 2. 7 Convertible

Van/Minivan รถยนต์ที่มีขนาดใหญ่และมีที่นั่งหลายแถว เหมาะสำหรับการขนส่งผู้โดยสารหลายคน CNN สามารถแยกแยะได้จากรูปร่างที่ยาวและมีหลายประตู



รูปที่ 2. 8 Van

Truck รถยนต์บรรทุกที่มีขนาดใหญ่กว่ารถ Pickup Truck และใช้สำหรับการขนส่งสินค้าหนัก CNN สามารถแยกแยะได้จากขนาดที่ใหญ่ขึ้นและลักษณะของท้ายรถที่ออกแบบมาเพื่อการบรรทุก



รูปที่ 2. 9 Truck

Bus รถยนต์ที่มีขนาดใหญ่มากสำหรับการขนส่งผู้โดยสารจำนวนมาก CNN สามารถแยกแยะได้จากขนาดและจำนวนที่นั่งภายในรถ



รูปที่ 2. 10 Bus

2.6 เครื่องมือที่ใช้

2.6.1 Visual Studio Code

Visual Studio Code (VS Code) [12] คือโปรแกรมแก้ไขโค้ดที่พัฒนาโดย Microsoft ซึ่งเป็นที่นิยมอย่างมากในกลุ่มนักพัฒนาซอฟต์แวร์ เนื่องจากเป็นโปรแกรมที่มีน้ำหนักเบา ใช้งานง่าย และมีประสิทธิภาพสูง VS Code รองรับหลากหลายภาษาโปรแกรม โดยมาพร้อมกับฟีเจอร์หลักที่ช่วยในการเขียนโค้ด นอกจากนี้ยังรองรับ Git ทำให้สามารถควบคุมเวอร์ชันของโค้ดได้อย่างสะดวก

หนึ่งในคุณสมบัติที่ทำให้ VS Code โดดเด่นคือความสามารถในการปรับแต่งและขยายฟังก์ชันได้ง่ายผ่านส่วนขยาย (Extensions) ซึ่งช่วยเพิ่มความสามารถใหม่ ๆ

VS Code ยังมีการบูรณาการกับเครื่องมือและแพลตฟอร์มต่าง ๆ เช่น Docker, Kubernetes, และบริการคลาวด์ ทำให้เหมาะสำหรับการพัฒนาแอปพลิเคชันทั้งในระดับท้องถิ่นและบนคลาวด์ โดย VS Code นั้นยังเปิดให้ใช้งานได้ฟรีและเป็นโอเพนซอร์ส ทำให้นักพัฒนาจากทั่วโลกสามารถมีส่วนร่วมในการพัฒนาและปรับปรุงโปรแกรมได้



รูปที่ 2. 11 Visual Studio Code

2.6.2 Python

Python [15] เป็นภาษาการเขียนโปรแกรมที่ถูกออกแบบมาให้ใช้งานง่ายและเป็นมิตรกับผู้เริ่มต้น โดยมีการจัดโครงสร้างโค้ดที่ชัดเจนและอ่านง่าย ทำให้เป็นที่นิยมอย่างมากในหมู่นักพัฒนา Python รองรับทั้งการเขียนโปรแกรมแบบเชิงวัตถุ (Object-Oriented Programming) และเชิงฟังก์ชัน (Functional Programming) ซึ่งเพิ่มความยืดหยุ่นในการพัฒนาโปรแกรมหลากหลายประเภท ตั้งแต่แอปพลิเคชันเว็บ, การประมวลผลข้อมูลขนาดใหญ่, ปัญญาประดิษฐ์, จนถึงการสร้างโมเดลทางวิทยาศาสตร์

Python มีไลบรารีและเฟรมเวิร์คที่หลากหลายและมีประสิทธิภาพสูง เช่น NumPy และ Pandas สำหรับการประมวลผลข้อมูล, TensorFlow และ PyTorch สำหรับ Machine Learning

และปัญญาประดิษฐ์, รวมถึง Django และ Flask สำหรับการพัฒนาเว็บ นอกจากนี้ Python ยังมีชุมชนขนาดใหญ่ที่ทำให้สามารถหาแหล่งข้อมูลและคำแนะนำได้ง่าย

อีกหนึ่งความสำเร็จของ Python คือการที่สามารถใช้งานได้ข้ามแพลตฟอร์ม ทำให้โค้ดสามารถรันได้ทั้งบน Windows, macOS และ Linux โดยไม่จำเป็นต้องแก้ไขมาก ทำให้ Python เหมาะสำหรับการพัฒนาโปรเจกต์ที่ต้องการความยืดหยุ่นและการขยายตัวในระยะยาว



รูปที่ 2. 12 Python

2.6.3 YOLO

YOLO (You Only Look Once) [16] เป็นอัลกอริทึมสำหรับการตรวจจับวัตถุ (Object Detection) ที่มีความเร็วและประสิทธิภาพสูง โดยทำงานด้วยการประมวลผลภาพทั้งหมดในครั้งเดียว แทนที่จะสแกนเป็นส่วน ๆ เหมือนอัลกอริทึมอื่น ๆ YOLO จะแบ่งภาพออกเป็นกริดและทำนาย Bounding Boxes พร้อมกับค่าความน่าจะเป็นของการมีวัตถุในแต่ละกริด จุดเด่นของ YOLO คือความสามารถในการตรวจจับวัตถุหลายชนิดในภาพเดียวได้อย่างรวดเร็ว ซึ่งทำให้เป็นที่นิยมในงานที่ต้องการการตรวจจับแบบเรียลไทม์ เช่น ยานพาหนะขับเคลื่อนอัตโนมัติและการรักษาความปลอดภัย



รูปที่ 2. 13 YOLO

2.6.4 Roboflow

Roboflow [13] เป็นแพลตฟอร์มที่ช่วยให้นักพัฒนาและนักวิจัยสามารถสร้างและจัดการชุดข้อมูลสำหรับการเรียนรู้ของเครื่อง (Machine Learning) โดยเฉพาะงานที่เกี่ยวกับการตรวจจับวัตถุ (Object Detection), การแบ่งแยกภาพ (Image Segmentation), และการจำแนกประเภทภาพ (Image Classification) Roboflow ช่วยในการเตรียมชุดข้อมูล เช่น การจัดการขนาดภาพ การปรับแต่งข้อมูล และการเพิ่มข้อมูล (Data Augmentation) นอกจากนี้ยังรองรับการสร้างโมเดลปัญญาประดิษฐ์ที่ใช้การเรียนรู้เชิงลึก (Deep Learning) และสามารถนำชุดข้อมูลไปฝึกโมเดลบนแพลตฟอร์มอื่น ๆ เช่น TensorFlow และ PyTorch ได้อย่างง่ายดาย



รูปที่ 2. 14 Roboflow

2.6.5 OpenCV

OpenCV (Open Source Computer Vision Library) [14] เป็นไลบรารีโอเพนซอร์สที่ถูกพัฒนาเพื่อรองรับการประมวลผลภาพและการประมวลผลวิดีโอ รวมถึงการวิเคราะห์ภาพต่าง ๆ เช่น การตรวจจับวัตถุ, การรู้จำใบหน้า, การติดตามวัตถุ, และการประมวลผลภาพแบบเรียลไทม์ OpenCV ถูกพัฒนาขึ้นด้วยภาษา C++ แต่ยังรองรับภาษาอื่น ๆ เช่น Python และ Java ด้วยความสามารถและประสิทธิภาพสูง ทำให้ OpenCV เป็นเครื่องมือยอดนิยมในงานวิจัยด้านปัญญาประดิษฐ์ (AI), การเรียนรู้ของเครื่อง (Machine Learning), และการพัฒนาระบบที่เกี่ยวข้องกับคอมพิวเตอร์วิทัศน์ (Computer Vision)



รูปที่ 2. 15 OpenCV

2.6.6 Tkinter

Tkinter [17] เป็นไลบรารีมาตรฐานสำหรับการสร้าง Graphical User Interface (GUI) บนภาษา Python ซึ่งมาพร้อมกับ Python โดยไม่ต้องติดตั้งเพิ่มเติม ทำให้สามารถพัฒนาแอปพลิเคชันเดสก์ท็อปได้อย่างง่ายดาย Tkinter มีเครื่องมือสำหรับสร้างองค์ประกอบของ GUI เช่น ปุ่ม (Button), ป้ายข้อความ (Label), กล่องข้อความ (Entry), และเฟรม (Frame) รวมถึงรองรับการจัดวางเลย์เอาต์แบบ pack, grid, และ place ทำให้เหมาะสำหรับการพัฒนาโปรแกรมที่ต้องการอินเทอร์เฟซแบบกราฟิก



รูปที่ 2. 16 Tkinter

2.6.7 Scikit-learn

Scikit-learn [18] เป็นไลบรารีสำหรับการเรียนรู้ของเครื่อง (Machine Learning) บนภาษา Python ที่พัฒนาบนพื้นฐานของ NumPy, SciPy, และ Matplotlib โดยรองรับอัลกอริทึมต่างๆ เช่น การจำแนกประเภท (Classification), การถดถอย (Regression), และการจัดกลุ่มข้อมูล (Clustering) นอกจากนี้ยังมีเครื่องมือสำหรับการปรับแต่งพารามิเตอร์ของโมเดลและการประเมินผล เช่น Cross-validation และ Confusion Matrix ทำให้ Scikit-learn เป็นไลบรารียอดนิยมสำหรับการสร้างและทดสอบโมเดล Machine Learning



รูปที่ 2. 17 scikit-learn

2.6.8 PyTorch

PyTorch [19] เป็นไลบรารีสำหรับการคำนวณทางคณิตศาสตร์และการเรียนรู้เชิงลึก (Deep Learning) บนภาษา Python ที่พัฒนาโดย Facebook's AI Research Lab (FAIR) โดยมีจุดเด่นที่ Dynamic Computation Graph ซึ่งช่วยให้การพัฒนาโมเดลมีความยืดหยุ่น รองรับการประมวลผลบน GPU ผ่าน CUDA ทำให้สามารถฝึกโมเดลขนาดใหญ่ได้อย่างมีประสิทธิภาพ PyTorch ได้รับความนิยมทั้งในงานวิจัยและอุตสาหกรรม โดยเฉพาะในด้าน Computer Vision, Natural Language Processing (NLP), และ Reinforcement Learning



รูปที่ 2. 18 pytorch

2.6.9 CUDA

CUDA [20] (Compute Unified Device Architecture) เป็นสถาปัตยกรรมการประมวลผลแบบขนานที่พัฒนาโดย NVIDIA เพื่อให้สามารถใช้ GPU (Graphics Processing Unit) ในการเร่งความเร็วการคำนวณ CUDA ช่วยให้นักพัฒนาสามารถใช้ C, C++, และ Python ผ่านไลบรารีต่างๆ เช่น cuDNN และ PyCUDA เพื่อทำการประมวลผลข้อมูลขนาดใหญ่และงานด้าน Machine Learning, Deep Learning, และ High-Performance Computing (HPC) ได้อย่างมีประสิทธิภาพ



รูปที่ 2. 19 CUDA

2.6.10 Google Colab

Google Colab [21] เป็นแพลตฟอร์ม Jupyter Notebook บนระบบคลาวด์ ที่พัฒนาโดย Google ซึ่งช่วยให้นักพัฒนาสามารถเขียนและรันโค้ด Python ได้โดยไม่ต้องติดตั้งซอฟต์แวร์เพิ่มเติม จุดเด่นของ Google Colab คือการรองรับ GPU และ TPU ฟรี สำหรับการประมวลผลที่ต้องใช้ทรัพยากรสูง เช่น Machine Learning และ Deep Learning นอกจากนี้ยังสามารถเข้าถึง Google Drive เพื่อจัดเก็บและเรียกใช้ข้อมูลได้อย่างสะดวก ทำให้เป็นเครื่องมือยอดนิยมสำหรับการเรียนรู้และพัฒนาโมเดล AI



รูปที่ 2. 20 Google Colab

บทที่ 3
วิธีดำเนินโครงงาน

ในวิธีการดำเนินโครงงานการพัฒนาระบบรู้จำประเภทและสีของรถจากภาพ (Development of a System for Recognizing Vehicle Types and Colors from Images) จะนำหลักการและทฤษฎีที่เกี่ยวข้องมาใช้ในการออกแบบ ภาพรวมของระบบและดำเนินโครงงาน ดังนี้

3.1 วิเคราะห์งานวิจัยที่เกี่ยวข้อง

เพื่อสนับสนุนการพัฒนาระบบในโครงการนี้ ผู้จัดทำได้ศึกษางานวิจัยที่เกี่ยวข้องหลายฉบับซึ่งมีเนื้อหาเกี่ยวกับการตรวจจับยานพาหนะ การจำแนกสี และการประมวลผลภาพ เพื่อนำแนวคิดและเทคนิคที่เหมาะสมมาประยุกต์ใช้ในการพัฒนาระบบของตนเอง

3.1.1 Large-scale Vehicle Re-identification in Urban Surveillance Videos

งานวิจัยเรื่องนี้มีวัตถุประสงค์เพื่อพัฒนาระบบระบุตัวตนรถยนต์ซ้ำ (Vehicle Re-identification) จากวิดีโอกล้องวงจรปิดในเมืองขนาดใหญ่ ซึ่งเป็นสภาพแวดล้อมที่มีความซับซ้อน ทั้งในแง่ของแสง มุมกล้อง และการเคลื่อนไหวของยานพาหนะ ระบบที่นำเสนอใช้เทคนิค deep learning ร่วมกับการออกแบบฟีเจอร์เฉพาะทางในการระบุรถคันเดียวกันจากหลายมุมมอง และมีการประเมินผลด้วยชุดข้อมูลขนาดใหญ่ระดับหลายหมื่นภาพ ทำให้ระบบสามารถเรียนรู้และจับความแตกต่างของรูปรถ สี และลักษณะเฉพาะได้อย่างมีประสิทธิภาพ ผลการทดลองแสดงให้เห็นว่าระบบสามารถระบุรถซ้ำได้แม่นยำในระดับสูงแม้ในสภาพแสงและมุมกล้องที่เปลี่ยนแปลงไป

ในโครงการนี้ ผู้จัดทำได้นำแนวคิดเรื่องการตรวจจับรถยนต์จากภาพในสภาพแวดล้อมจริงมาประยุกต์ใช้ โดยเลือกใช้โมเดล YOLOv8 ในการตรวจจับรถยนต์จากภาพนิ่ง ซึ่งสามารถทำงานได้รวดเร็วและแม่นยำบน dataset ขนาดประมาณ 8,000 รูปที่มีการจัดเตรียมไว้ล่วงหน้า แม้ว่างานวิจัยต้นฉบับจะเน้นไปที่การ “ระบุตัวตนรถซ้ำ” จากหลายกล้อง ขณะที่ระบบของผู้จัดทำเน้นการตรวจจับรถจากกล้องเดียวและจำแนกสีโดยใช้โมเดลสี HSV แต่ทั้งสองงานต่างมีเป้าหมายร่วมกันคือการประมวลผลข้อมูลภาพที่มีความซับซ้อน เพื่อใช้ในการวิเคราะห์และติดตามยานพาหนะ ความแตกต่างสำคัญคือ ระบบในงานวิจัยนี้มีความซับซ้อนสูงและใช้ deep learning ขั้นสูงร่วมกับข้อมูลหลายแหล่ง ในขณะที่ระบบของผู้จัดทำออกแบบให้เรียบง่าย ต้นทุนต่ำ และเหมาะสมกับการใช้งานในระบบที่ต้องการประมวลผลแบบเรียลไทม์

3.1.2 Vehicle Color Recognition Using Convolutional Neural Network and Color Histogram

Chen, Yang และ Yang (2019) ได้ศึกษาการจำแนกสีของรถยนต์จากภาพถ่ายโดยใช้เทคนิค Convolutional Neural Network (CNN) ร่วมกับการวิเคราะห์ Color Histogram เพื่อปรับปรุงความแม่นยำในการจำแนกสีในสภาพแวดล้อมจริง โดย CNN ถูกใช้เพื่อเรียนรู้คุณลักษณะเชิงลึกจากภาพรถยนต์ ขณะที่ Color Histogram ทำหน้าที่ช่วยสกัดข้อมูลสีแบบพิกเซลอย่างละเอียดจากภาพต้นฉบับ ผลการทดลองในงานวิจัยนี้แสดงให้เห็นว่าระบบสามารถจำแนกสีรถยนต์ได้อย่างแม่นยำถึง 90.2% บนชุดข้อมูลที่เก็บจากสภาพแวดล้อมที่มีแสงหลากหลาย อย่างไรก็ตาม งานวิจัยยังคงมีข้อจำกัดในด้านความต้องการใช้ชุดข้อมูลขนาดใหญ่เพื่อฝึกสอนโมเดล CNN รวมถึงทรัพยากรในการประมวลผลที่สูง ซึ่งอาจเป็นอุปสรรคต่อการนำไปใช้งานในระบบเรียลไทม์หรือระบบฝังตัวที่มีข้อจำกัดด้านฮาร์ดแวร์

สำหรับโครงการนี้ ผู้จัดทำได้นำแนวคิดเรื่องการพิจารณาสีของรถจากคุณลักษณะในภาพมาใช้เช่นเดียวกัน แต่เลือกใช้การแปลงค่าสีเป็นโมเดล HSV และกำหนดเงื่อนไขช่วงสีด้วยวิธีการประมวลผลภาพพื้นฐานแทนการใช้โมเดล deep learning ความเหมือนของสองงานนี้คือมีเป้าหมายในการจำแนกสีรถจากภาพถ่ายในโลกจริงที่มีปัจจัยรบกวนหลายรูปแบบ ส่วนความแตกต่างคือ งานของ Chen et al. ใช้ CNN ซึ่งมีความแม่นยำสูงแต่ต้องการทรัพยากรมาก ขณะที่ระบบของผู้จัดทำมีความเรียบง่ายและสามารถนำไปใช้งานในระบบที่ต้องการความเร็วและความเบา เช่น งานฝังตัวหรือการประมวลผลแบบเรียลไทม์บนอุปกรณ์ทั่วไป

3.1.3 Development of Feature Detector for Vehicle Make, Model and Color Recognition System used for Suspect Vehicle Detection

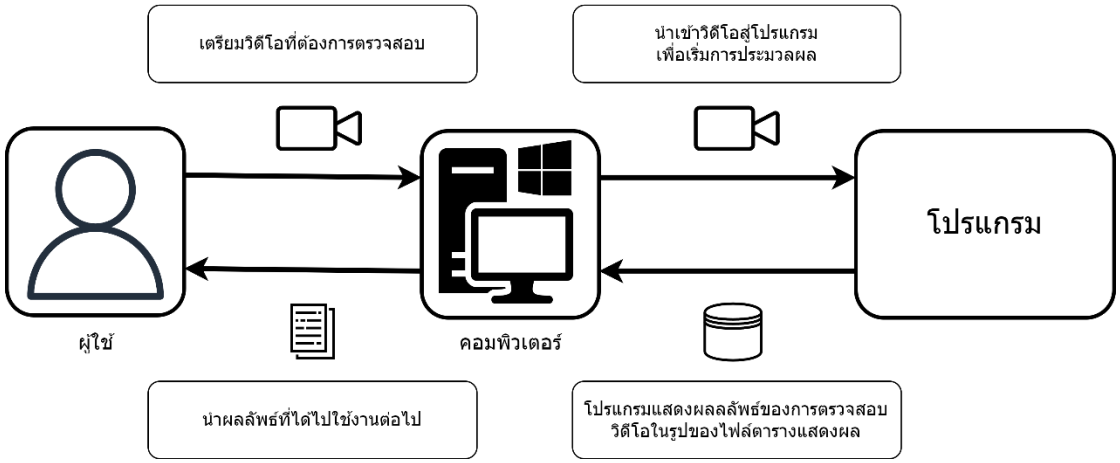
โครงการวิจัยเรื่องนี้ได้ทำการศึกษาและพัฒนา การพัฒนาตัวตรวจจับคุณลักษณะเฉพาะสำหรับระบบการรู้จำยี่ห้อรุ่นและสีของรถยนต์เพื่อใช้ในการตรวจจับรถต้องสงสัย โดยมุ่งเน้นการใช้เทคนิคการแยกส่วนของภาพ (Image Segmentation) และการใช้ตัวตรวจจับคุณลักษณะเฉพาะ (Feature Detector) รวมถึงการใช้ โมเดล HSV เพื่อจำแนกสีของรถ เพื่อระบุลักษณะเฉพาะของรถยนต์ เพื่อช่วยในการตรวจจับรถยนต์ต้องสงสัยในระบบความปลอดภัยและการตรวจสอบแบบอัตโนมัติโดยใช้ข้อมูลจากภาพถ่ายหรือวิดีโอที่เก็บจากกล้องวงจรปิด ผลการทดลองแสดงให้เห็นว่าระบบสามารถตรวจจับคุณลักษณะเหล่านี้ได้อย่างแม่นยำในระดับที่สูง เมื่อมีการใช้ชุดข้อมูลล่วงหน้าเพื่อช่วยในการฝึกโมเดล แม้ว่าเทคนิคนี้จะมีความแม่นยำสูง แต่ก็มีข้อจำกัดในด้านของคุณภาพภาพจากกล้องที่แตกต่างกัน เช่น ภาพที่มีแสงน้อยหรือมีความละเอียดต่ำ ซึ่งอาจส่งผลต่อความถูกต้องในการจำแนกคุณลักษณะ

สำหรับโครงการนี้ ผู้จัดทำได้ใช้แนวคิดเกี่ยวกับการแยกส่วนของภาพและการตรวจจับคุณลักษณะเฉพาะจากงานวิจัยนี้เพื่อพัฒนาโมเดลที่สามารถประมวลผลได้รวดเร็ว โดยใช้โมเดล HSV

ที่มีความละเอียดของของช่วงสีที่มากกว่า ในการจำแนกสีของรถยนต์ และระบบตรวจจับที่มีความซับซ้อนน้อยกว่า แต่ยังคงสามารถให้ผลลัพธ์ที่แม่นยำในเวลาอันรวดเร็ว โครงการนี้มีความเหมือนกันในแง่ที่ทั้งสองระบบมุ่งเน้นไปที่การตรวจจับลักษณะของรถยนต์จากภาพ เพื่อใช้ในการระบุรถต้องสงสัย ความแตกต่างที่ชัดเจนคือ ระบบของผู้จัดทำไม่ใช้การฝึกโมเดลที่ซับซ้อน แต่เลือกใช้ระบบรู้จำภาพแทนการใช้ตัวตรวจจับคุณลักษณะเฉพาะที่มีใช้งานได้ง่ายกว่า และยังใช้ โมเดล HSV ที่มีความละเอียดของของช่วงสีที่มากกว่าทำให้สามารถระบุสีได้ละเอียดยิ่งขึ้น

3.2 ภาพรวมของระบบ

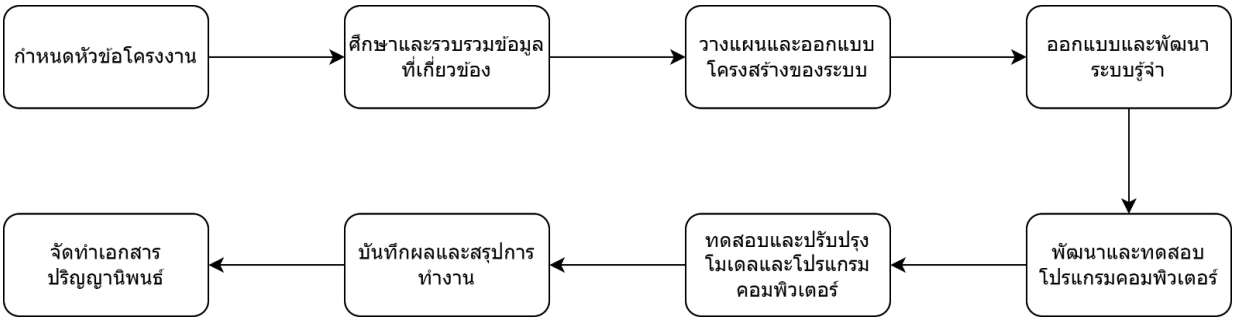
ในส่วนนี้จะเป็นภาพรวมการทำงานของระบบรู้จำประเภทและสีของรถจากภาพ โดย ผู้ใช้จะใช้โปรแกรมเพื่อเพื่อประมวลผลวิดีโอด้วยโมเดลตรวจจับวัตถุและแสดงผลลัพธ์กลับไปยังผู้ใช้ ดังรูปที่ 3.1



รูปที่ 3. 1 ภาพรวมของระบบ

3.3 การสร้างระบบ

ในส่วนนี้จะเป็นขั้นตอนการดำเนินโครงงานการพัฒนาระบบรู้จำประเภทและสีของรถจากภาพ ซึ่งมี รายละเอียด ดังรูปที่ 3.2



รูปที่ 3. 2 ขั้นตอนการดำเนินโครงงาน

3.3.1 วิเคราะห์การทำงานของระบบรู้จำประเภทและสีของรถจากภาพ

ระบบจะทำงานโดยแบ่งเป็น 2 ขั้นตอนหลักคือ ขั้นตอนการตรวจหารถในวิดีโอ และขั้นตอนการตรวจหาสีของรถ โดยทั้งสองขั้นตอนจะทำงานตามลำดับเพื่อให้ได้ผลลัพธ์ของวิดีโอที่สามารถนำไปใช้ประมวลผลต่อไป การทำงานของระบบรู้จำประเภทและสีของรถจากภาพจะทำหน้าที่ดังต่อไปนี้

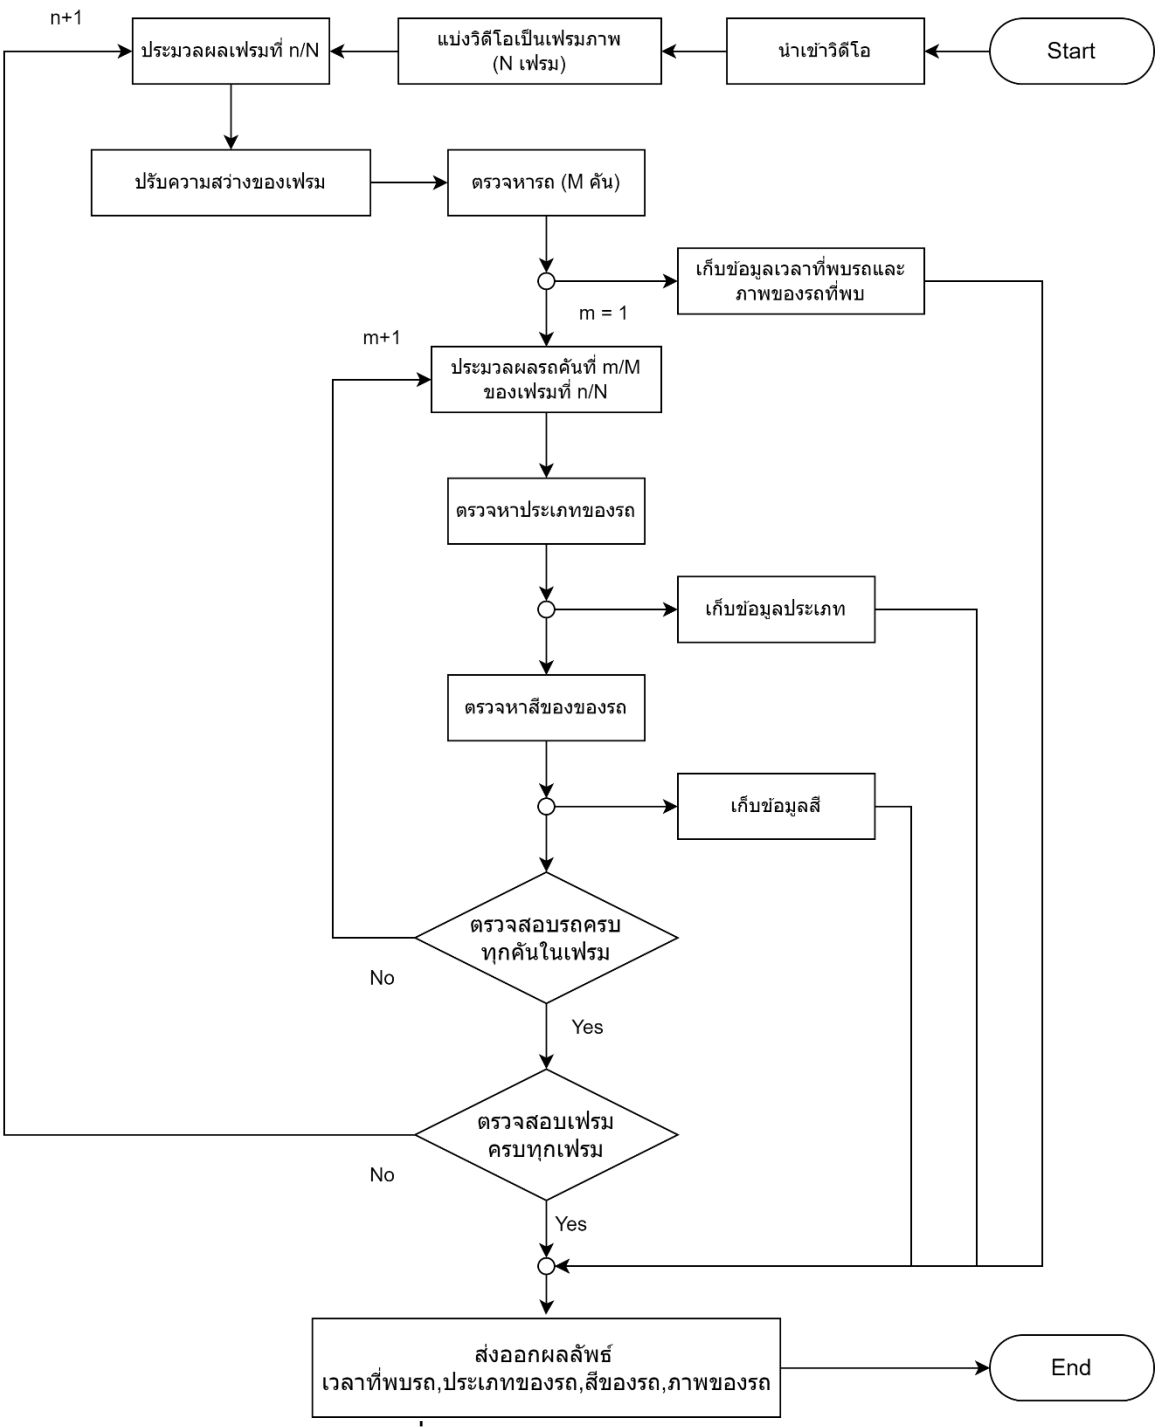
ก. ตรวจจับและระบุตำแหน่งของรถที่ปรากฏในวิดีโอในทุกวินาทีของการประมวลผล

ข. วิเคราะห์และระบุสีของรถที่ตรวจพบภายในวิดีโอ

ค. จัดทำและนำเสนอรายงานผลลัพธ์ในรูปแบบสรุปผล

3.3.2 วิเคราะห์การทำงานของระบบรู้จำประเภทและสีของรถจากภาพ

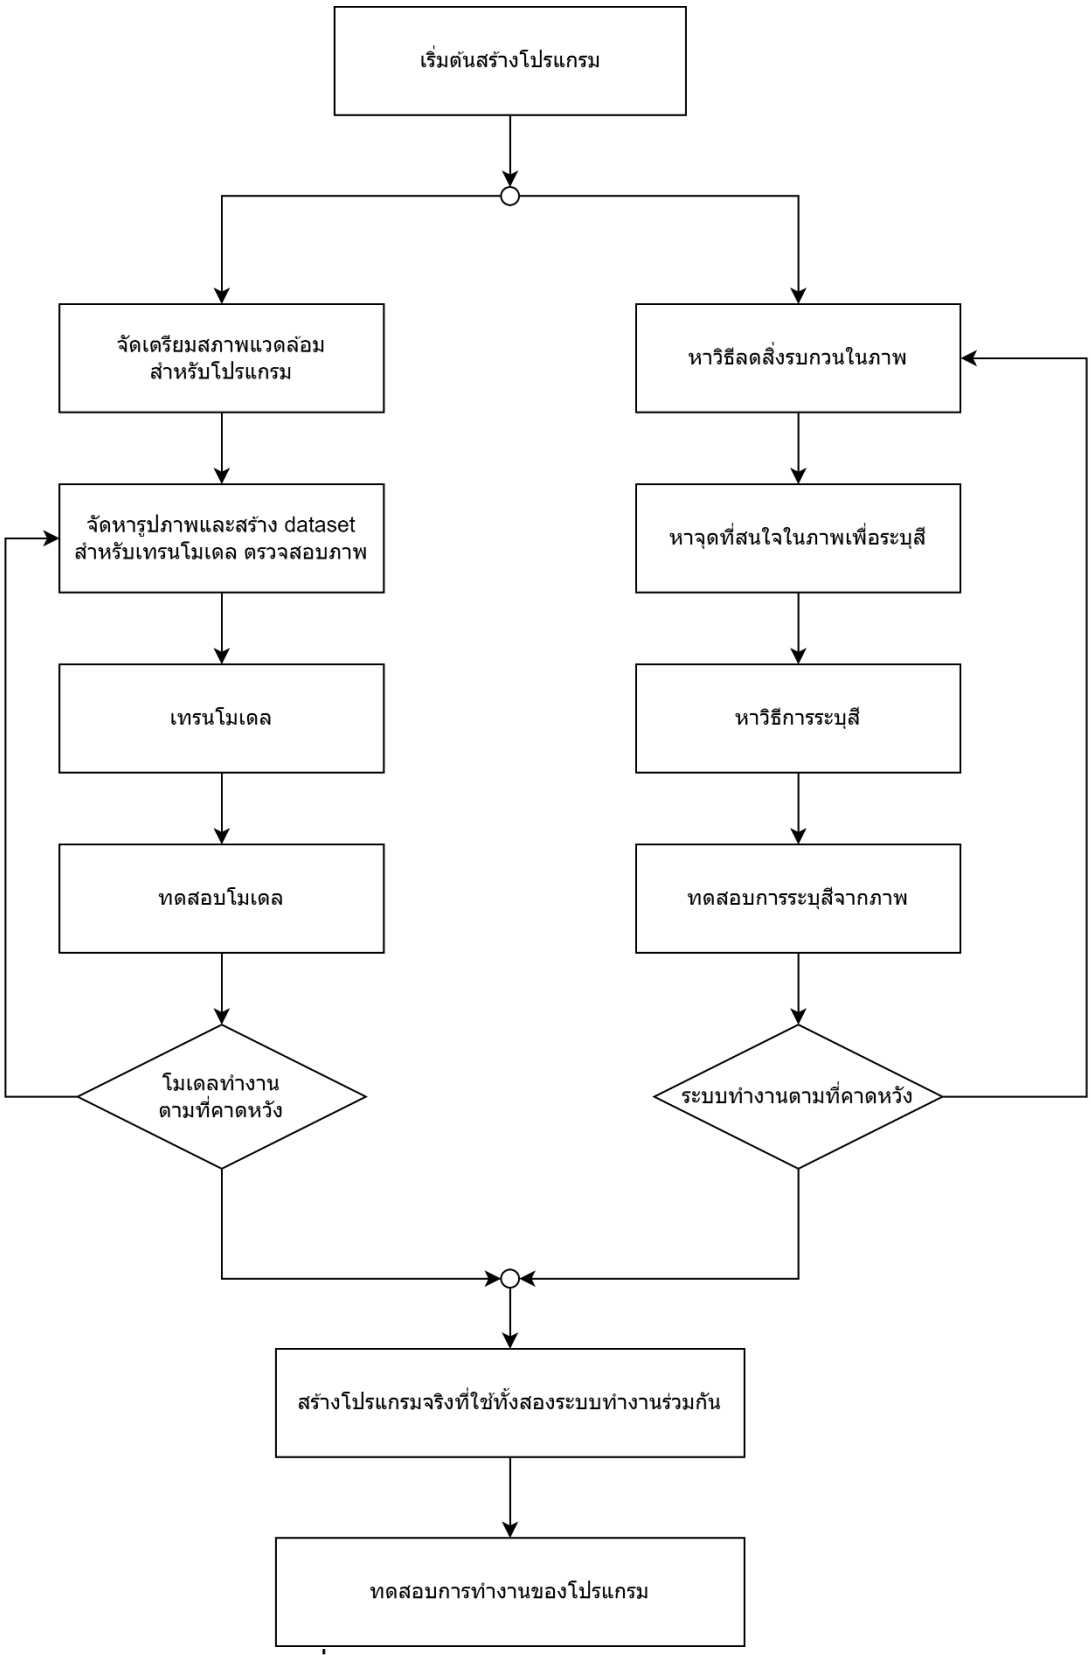
จากการศึกษาและรวบรวมข้อมูลที่เกี่ยวข้องกับความต้องการในระบบ สามารถวิเคราะห์และออกแบบการทำงานของระบบรู้จำประเภทและสีของรถจากภาพได้ ดังรูปที่ 3.3



รูปที่ 3. 3 การทำงานของระบบ

3.3.3 การสร้างระบบรู้จำประเภทและสีของรถจากภาพ

จากการศึกษาและรวบรวมข้อมูลที่เกี่ยวข้อง ร่วมกับการวิเคราะห์และออกแบบการทำงานของระบบ สามารถกำหนดแนวทางการพัฒนาและออกแบบระบบรู้จำประเภทและสีของรถจากภาพได้ ดังรูปที่ 3.4



รูปที่ 3. 4 แนวทางการพัฒนาและออกแบบระบบ

หลังจากวิเคราะห์การทำงานของโปรแกรมและออกแบบโปรแกรมแล้ว ขั้นตอนต่อไปของการสร้างโปรแกรมแบ่งเป็นขั้นตอนดังนี้

ก. จัดเตรียมสภาพแวดล้อมสำหรับโปรแกรมโดยติดตั้งโปรแกรมและไลบรารี

ข. จัดหารูปภาพและสร้าง dataset สำหรับเทรนโมเดล ตรวจสอบภาพ

ค. เทรนโมเดล จาก dataset ที่สร้างไว้ด้วย Ultralytics YOLO เพื่อสร้างโมเดลสำหรับตรวจจับวัตถุและแยกแยะวัตถุ

ง. ทดสอบโมเดล ที่สร้างไว้เพื่อทำการแก้ไขปรับปรุงให้โมเดลสำหรับตรวจจับวัตถุและแยกแยะวัตถุทำงานได้แม่นยำตามที่คาดหวังไว้

จ. หาวิธีลดสิ่งรบกวนในภาพ เพื่อเพิ่มประสิทธิภาพของข้อมูลข้อมูลนำเข้าทำให้โมเดลและอัลกอริทึมต่างๆข้องระบบทำงานได้ดียิ่งขึ้น และไม่ถูกรบกวนจากสิ่งรบกวนต่างๆภายในภาพเช่น แส่งสว่างที่มากหรือน้อยเกินไป เป็นต้น

ฉ. หาจุดที่สนใจในภาพเพื่อระบุสีของรถคันนั้นๆ ทำให้สามารถระบุสีของรถได้อย่างเป็นระบบและแม่นยำขึ้น

ช. หาวิธีการระบุสี โดยใช้ภาพจากจุดที่สนใจกับอัลกอริทึม เพื่อให้ได้ชื่อสีของรถคันนั้น

ซ. ทดสอบการระบุสีจากภาพ เพื่อปรับปรุงแก้ไข วิธีการระบุสี และ อัลกอริทึมต่างๆให้แม่นยำมากขึ้น

ฌ. สร้างโปรแกรมจริงที่ใช้ทั้งสองระบบทำงานร่วมกัน ทั้ง ระบบตรวจหารถ และระบุสีของรถ เพื่อให้ได้ ระบบรู้จำประเภทและสีของรถจากภาพ ตามที่ตั้งโจทย์ไว้

ญ. ทดสอบการทำงานของโปรแกรมเพื่อทำการแก้ไข ระบบ และ อัลกอริทึมต่างๆให้แม่นยำมากขึ้นตามที่คาดหวังไว้

3.4 การจัดเตรียมสภาพแวดล้อมสำหรับระบบรู้จำประเภทและสีของรถจากภาพ

การพัฒนาระบบรู้จำประเภทและสีของรถจากภาพต้องอาศัยสภาพแวดล้อมที่เหมาะสมเพื่อให้สามารถประมวลผลภาพได้อย่างมีประสิทธิภาพ โดยในส่วนนี้จะกล่าวถึงการติดตั้งโปรแกรมคอมพิวเตอร์และไลบรารี่ที่จำเป็นสำหรับการดำเนินงานของระบบ

3.4.1 ติดตั้งโปรแกรมคอมพิวเตอร์

เพื่อให้สามารถใช้งานไลบรารี่สำหรับการประมวลผลภาพและการเรียนรู้ของเครื่องได้อย่างมีประสิทธิภาพ จำเป็นต้องติดตั้งซอฟต์แวร์พื้นฐานดังต่อไปนี้:

ก. Python: ใช้เป็นภาษาหลักในการพัฒนาโค้ดสำหรับระบบ

ข. CUDA Driver: ใช้สำหรับเร่งความเร็วในการประมวลผลโดยใช้ GPU ของ NVIDIA ซึ่งช่วยเพิ่มประสิทธิภาพในการฝึกและทดสอบโมเดล

3.4.2 ติดตั้งไลบรารี่ในภาษา Python

หลังจากติดตั้งโปรแกรมคอมพิวเตอร์พื้นฐานแล้ว จำเป็นต้องติดตั้งไลบรารี่ที่เกี่ยวข้องเพื่อใช้ในการประมวลผลภาพและพัฒนาโมเดลการเรียนรู้เชิงลึก โดยสามารถติดตั้งผ่าน pip คำสั่งดังต่อไปนี้:

```
pip install opencv-python
pip install torch==1.13.1+cu117 torchvision==0.14.1+cu117 --index-url https://download.pytorch.org/whl/cu117
pip install ultralytics
pip install scikit-learn
```

ไลบรารี่ที่ใช้มีรายละเอียดดังนี้:

ก. OpenCV: ใช้สำหรับการประมวลผลภาพ เช่น การอ่านภาพ การปรับแต่งภาพ และการตรวจจับขอบเขตของวัตถุ

ข. PyTorch (เวอร์ชัน 1.13.1+cu117): เป็นเฟรมเวิร์กสำหรับการพัฒนาโมเดลการเรียนรู้เชิงลึกที่รองรับการใช้ GPU

ค. Torchvision (เวอร์ชัน 0.14.1+cu117): เป็นไลบรารี่ที่รองรับการจัดการภาพและโมเดลสำเร็จรูปสำหรับงานคอมพิวเตอร์วิทัศน์

ง. Ultralytics: ใช้สำหรับการพัฒนาโมเดลวัตถุที่ใช้ YOLO (You Only Look Once) ซึ่งเป็นโมเดลยอดนิยมสำหรับการตรวจจับวัตถุ

จ. Scikit-learn: ใช้สำหรับการประมวลผลข้อมูลเชิงสถิติ การจัดการข้อมูล และการสร้างโมเดลเรียนรู้ของเครื่องเพิ่มเติม

3.5 วิเคราะห์และอกอแบบการจำแนกประเภทรถ

การออกแบบการจำแนกประเภทของรถยนต์มีหลายประเภทที่สามารถจำแนกได้ตามลักษณะต่างๆ เช่น Convertible, Coupe, Hatchback, Sedan, Pick-Up, SUV, Truck, และ Van ซึ่งแต่ละประเภทมีลักษณะเด่นที่แตกต่างกันไป การจำแนกประเภทเหล่านี้มักจะใช้ข้อมูลจากภาพถ่ายหรือคลิปวิดีโอของรถยนต์ที่ได้จากแหล่งต่างๆ ซึ่งภาพที่ใช้เพื่อจำแนกประเภทของรถยนต์จะใช้รูปภาพที่มีมุมมองต่างๆ ของรถยนต์ โดยเฉพาะการจับภาพจากมุมที่สามารถเห็นลักษณะเด่น เช่น ด้านข้าง, ด้านหน้า, และด้านหลัง เพื่อช่วยให้โมเดลสามารถจำแนกรูปร่างและลักษณะเฉพาะของแต่ละประเภทได้

3.5.1 ประเภทของรถยนต์ที่ใช้ในการจำแนก

ก. Convertible รถยนต์ที่สามารถเปิดหลังคาได้ มีตัวอย่างรูปภาพบางส่วนจากชุดข้อมูลทั้งหมด 1277 ภาพ ที่ใช้ในการฝึกฝนโมเดลดังนี้



รูปที่ 3. 5 ตัวอย่าง Convertible (1)



รูปที่ 3. 6 ตัวอย่าง Convertible (2)



รูปที่ 3. 7 ตัวอย่าง Convertible (3)

ข. Coupe รถยนต์ที่มีขนาดเล็ก ส่วนใหญ่เป็นสองประตูและมีรูปร่างค่อนข้างคล่องตัว มีตัวอย่างรูปภาพบางส่วนจากชุดข้อมูลทั้งหมด 906 ภาพ ที่ใช้ในการฝึกฝนโมเดลดังนี้



รูปที่ 3. 8 ตัวอย่าง Coupe (1)



รูปที่ 3. 9 ตัวอย่าง Coupe (2)



รูปที่ 3. 10 ตัวอย่าง Coupe (3)

ค. Hatchback รถยนต์ที่มีประตูท้ายที่เปิดขึ้นไปข้างบนเพื่อให้สะดวกในการเก็บสัมภาระ มีตัวอย่างรูปภาพบางส่วนจากชุดทั้งหมด 976 ภาพ ข้อมูลที่ใช้ในการฝึกฝนโมเดลดังนี้



รูปที่ 3. 11 ตัวอย่าง Hatchback (1)



รูปที่ 3. 12 ตัวอย่าง Hatchback (2)



รูปที่ 3. 13 ตัวอย่าง Hatchback (3)

ง. Sedan รถยนต์ที่มีตัวถังแบบ 4 ประตู ที่ให้ความสะดวกสบายในการขนส่งและเดินทาง มีตัวอย่างรูปภาพบางส่วนจากชุดทั้งหมด 1,008 ภาพ ข้อมูลที่ใช้ในการฝึกฝนโมเดลดังนี้



รูปที่ 3. 14 ตัวอย่าง Sedan (1)



รูปที่ 3. 15 ตัวอย่าง Sedan (2)



รูปที่ 3. 16 ตัวอย่าง Sedan (3)

จ. Pick-Up รถที่มีตัวถังแยกออกจากส่วนของห้องโดยสาร มักใช้ในการขนส่งของ มีตัวอย่างรูปภาพบางส่วนจากชุดข้อมูลทั้งหมด 1,086 ภาพ ที่ใช้ในการฝึกฝนโมเดลดังนี้



รูปที่ 3. 17 ตัวอย่าง Pick-Up (1)



รูปที่ 3. 18 ตัวอย่าง Pick-Up (2)



รูปที่ 3. 19 ตัวอย่าง Pick-Up (3)

ฉ. SUV รถที่ออกแบบมาสำหรับการขับขี่ในพื้นที่หลากหลาย ใช้ทั้งในเมืองและนอกเมือง มีตัวอย่างรูปภาพบางส่วนจากชุดทั้งหมด 1,246 ภาพ ข้อมูลที่ใช้ในการฝึกฝนโมเดลดังนี้



รูปที่ 3. 20 ตัวอย่าง SUV (1)



รูปที่ 3. 21 ตัวอย่าง SUV (2)



รูปที่ 3. 22 ตัวอย่าง SUV (3)

ช. uck รถที่มีขนาดใหญ่และมักใช้สำหรับขนส่งสินค้า มีตัวอย่างรูปภาพบางส่วนจากชุดข้อมูลทั้งหมด 1,403 ภาพ ที่ใช้ในการฝึกฝนโมเดลดังนี้



รูปที่ 3. 23 ตัวอย่าง Truck (1)



รูปที่ 3. 24 ตัวอย่าง Truck (2)



รูปที่ 3. 25 ตัวอย่าง Truck (3)

ซ. Van รถที่ออกแบบมาเพื่อขนส่งผู้โดยสารหรือสินค้าหลายๆ คน มีตัวอย่างรูปภาพบางส่วนจากชุดข้อมูลทั้งหมด 1277 ภาพ ที่ใช้ในการฝึกฝนโมเดลดังนี้



รูปที่ 3. 26 ตัวอย่าง Van (1)



รูปที่ 3. 27 ตัวอย่าง Van (2)



รูปที่ 3. 28 ตัวอย่าง Van (3)

ฌ. Bus รถโดยสารขนาดใหญ่ที่บรรทุกผู้โดยสารจำนวนมาก ใช้ในการขนส่งในระยะทางไกลหรือเส้นทางประจำ มีตัวอย่างรูปภาพดังนี้



รูปที่ 3. 29 ตัวอย่าง Bus

ญ. Motorcycle ยานพาหนะสองล้อที่เหมาะสำหรับการขับขี่ในเมืองหรือเส้นทางแออัด มีตัวอย่างรูปภาพดังนี้



รูปที่ 3. 30 ตัวอย่าง Motorcycle

3.5.2 แหล่งที่มาของข้อมูล

ข้อมูลเหล่านี้รวบรวมมาจากแหล่งข้อมูลออนไลน์ต่างๆดังนี้

ก. www.google.com

ข. www.facebook.com

ค. www.kaggle.com

ในขั้นตอนจริงของการจำแนกประเภทของรถยนต์ เราจะรวมประเภท Sedan เข้าไปในกลุ่มของ Convertible, Coupe, Hatchback, และ Sedan เนื่องจากลักษณะภายนอกของรถในกลุ่มนี้มีความคล้ายคลึงกัน ทั้งในแง่ของรูปร่างและขนาด ทำให้สามารถจำแนกได้ร่วมกันในขั้นตอนการประมวลผล

สำหรับโมเดลที่ใช้ในการจำแนกรถยนต์ เราจะใช้ Bus และ Motorcycle จากโมเดลพื้นฐานของ YOLOv8 ที่มีอยู่แล้ว ซึ่งเป็นโมเดลที่ได้รับการฝึกฝนมาเพื่อตรวจจับประเภทต่างๆ ของยานพาหนะ โดยในขั้นตอนจริงจะมีการจำแนกประเภทของรถยนต์ทั้งหมดเป็น Sedan, SUV, Pick-Up, Van, Bus, Truck และ Motorcycle ตามลำดับ ซึ่งจะช่วยให้การจำแนกประเภทของยานพาหนะในระบบมีความแม่นยำและครอบคลุมมากยิ่งขึ้น

3.6 การจัดหารูปภาพและสร้าง Dataset สำหรับเทรนโมเดล

ในการพัฒนาโมเดลให้มีประสิทธิภาพสูง การจัดหารูปภาพและสร้าง Dataset ที่มีคุณภาพเป็นขั้นตอนสำคัญ เนื่องจากข้อมูลที่ดีจะช่วยให้โมเดลเรียนรู้และจำแนกประเภทได้อย่างแม่นยำ

3.6.1 การจัดหารูปภาพ

ในการพัฒนาโมเดลรู้จำประเภทและสีของรถจากภาพ จำเป็นต้องมีชุดข้อมูลที่ครอบคลุมประเภทของยานพาหนะที่แตกต่างกัน การจัดหารูปภาพสามารถทำได้หลายวิธี ได้แก่

3.6.1.1 รวบรวมจากแหล่งข้อมูลสาธารณะ

Kaggle, Open Images Dataset และ ImageNet ซึ่งมีภาพยานพาหนะที่มีการติดป้ายกำกับไว้ล่วงหน้า

3.6.1.2 การถ่ายภาพเอง

ใช้กล้องถ่ายภาพหรือวิดีโอจากกล้องวงจรปิด (CCTV) และอุปกรณ์อื่น ๆ

3.6.1.3 การใช้ชุดข้อมูลที่มีอยู่แล้ว

COCO (Common Objects in Context) หรือชุดข้อมูลเฉพาะทางที่เกี่ยวข้องกับยานพาหนะ

3.6.2 การสร้าง Dataset

ในการสร้าง dataset สำหรับการฝึกโมเดล YOLO เราจะใช้แพลตฟอร์ม Roboflow ซึ่งเป็นเครื่องมือที่ช่วยจัดการชุดข้อมูลและสร้าง annotation ในรูปแบบที่เหมาะสมกับ YOLO โดยกระบวนการสร้าง dataset มีดังนี้

3.6.2.1 การสร้าง Dataset สำหรับโมเดล Object Detection

การสร้าง Dataset สำหรับโมเดล Object Detection เป็นกระบวนการสำคัญที่ต้องมีการรวบรวม จัดทำ และติดป้ายกำกับข้อมูลอย่างเป็นระบบ เพื่อให้โมเดลสามารถเรียนรู้และตรวจจับวัตถุได้อย่างแม่นยำ ซึ่งมีขั้นตอนดังนี้

ก. อัปโหลดรูปภาพ ไปยัง Roboflow และกำหนดโปรเจ็กต์เป็น Object Detection

ข. ทำ Annotation โดยใช้เครื่องมือใน Roboflow เพื่อกำหนด bounding box รอบยานพาหนะและระบุประเภท (เช่น รถยนต์, มอเตอร์ไซค์, รถบรรทุก)

ค. เพิ่มข้อมูลเสริม (Augmentation) เช่น การหมุนภาพ, การเปลี่ยนความสว่าง, การปรับขนาด เพื่อลดปัญหา Overfitting

ง. แปลงข้อมูลเป็นรูปแบบ YOLO เช่น YOLOv5 หรือ YOLOv8 และดาวน์โหลดไฟล์พร้อมใช้สำหรับการฝึกโมเดล

3.6.2.2 การสร้าง Dataset สำหรับโมเดล Image Classification

การสร้าง Dataset สำหรับโมเดล Image Classification ต้องให้ความสำคัญกับการรวบรวมข้อมูลที่หลากหลายและการจัดกลุ่มภาพให้ชัดเจน เพื่อให้โมเดลสามารถเรียนรู้และจำแนกประเภทของภาพได้อย่างมีประสิทธิภาพ โดยมีขั้นตอนดังนี้

ก. จัดกลุ่มรูปภาพ โดยแยกภาพเป็นโฟลเดอร์ตามประเภทของยานพาหนะ

ข. อัปโหลดไปยัง Roboflow และเลือกประเภทของโปรเจ็กต์เป็น Image Classification

ค. เพิ่ม Augmentation เพื่อปรับปรุงความหลากหลายของชุดข้อมูล

ง. แปลงเป็นไฟล์ที่รองรับการฝึกโมเดล เช่น YOLO Classification, TensorFlow, หรือ PyTorch Dataset

3.7 การเทรนโมเดลตรวจจับและจำแนกวัตถุสำหรับการตรวจจับและจำแนกรถ

การพัฒนาโมเดลสำหรับระบบรู้จำประเภทและสีของรถจากภาพประกอบไปด้วยสองส่วนหลัก ได้แก่ โมเดลสำหรับตรวจจับวัตถุ (Object Detection) และโมเดลสำหรับจำแนกประเภทของรถ (Image Classification) โดยกระบวนการเทรนโมเดลดำเนินการบนแพลตฟอร์ม Google Colab เพื่อใช้ประโยชน์จากทรัพยากรการประมวลผลของ GPU

3.7.1 โมเดล Object Detection

โมเดล Object Detection มีหน้าที่ระบุตำแหน่งของยานพาหนะในภาพและแยกแยะขอบเขตของวัตถุออกจากพื้นหลัง โมเดลนี้ได้รับการพัฒนาโดยใช้ YOLO (You Only Look Once) ซึ่งเป็นสถาปัตยกรรมที่สามารถตรวจจับวัตถุได้แบบเรียลไทม์ ซึ่งมีขั้นตอนการเทรนโมเดลดังนี้

ก. เตรียมชุดข้อมูล โดยใช้ชุดข้อมูลที่มีการติดป้ายกำกับ (Annotation) เพื่อกำหนดขอบเขตของรถยนต์ในแต่ละภาพ ที่ได้เตรียมไว้ในขั้นตอนก่อนหน้า

ข. ฝึกโมเดล โดยใช้คำสั่ง yolo train โดยใช้ yolov8 เป็นเบสโมเดล พร้อมระบุค่าต่าง ๆ เช่น ขนาดภาพ จำนวน epochs และค่า learning rate เพื่อทำการสร้างโมเดล

ค. ประเมินผลการเทรน โดยวิเคราะห์ค่า Mean Average Precision (mAP) และค่า loss เพื่อตรวจสอบประสิทธิภาพของโมเดล

ง. ทดสอบโมเดลกับชุดข้อมูลที่ไม่เคยเห็นมาก่อนเพื่อดูความแม่นยำ

3.7.2 โมเดล Image Classification

หลังจากที่โมเดล Object Detection สามารถระบุยานพาหนะในภาพได้แล้ว ขั้นตอนต่อไปคือการจำแนกประเภทของรถยนต์โดยใช้ Image Classification โดยใช้ YOLO Classification (YOLO CLS) ซึ่งมีขั้นตอนการเทรนโมเดลดังนี้

ก. เตรียมชุดข้อมูล โดยการแบ่งหมวดหมู่ของยานพาหนะ ซึ่งในที่นี้จะแบ่งเป็น Convertible, Coupe, Hatchback, Pick-Up, SUV, Sedan, Truck, VAN หลังจากนั้นจะจัดเตรียมโครงสร้างโฟลเดอร์ข้อมูลให้เหมาะสมกับ Image Classification

ข. ฝึกโมเดล โดยใช้คำสั่ง yolo classify train และใช้โมเดล yolo cls เป็นเบสโมเดล พร้อมระบุค่าต่าง ๆ เช่น ขนาดภาพ จำนวน epochs และค่า learning rate เพื่อทำการสร้างโมเดล

ค. ประเมินผลการเทรน โดยการวิเคราะห์ค่าความแม่นยำ (Accuracy) และค่าความสูญเสีย (Loss)

ง. ทดสอบโมเดลกับภาพใหม่เพื่อตรวจสอบประสิทธิภาพในการจำแนกประเภทของรถยนต์

3.8 การเทรนโมเดลตรวจจับล้อรถในภาพและการหาจุดที่สนใจในภาพเพื่อระบุสี

การพัฒนาโมเดลสำหรับการตรวจจับล้อรถในภาพและการหาจุดที่สนใจเพื่อระบุสีของรถยนต์นั้นสามารถแบ่งออกเป็นสองขั้นตอนหลัก คือ การฝึกโมเดลตรวจจับล้อรถ และการหาจุดที่สนใจในภาพเพื่อใช้ในการระบุสีของรถยนต์ ขั้นตอนเหล่านี้จะช่วยให้ระบบสามารถวิเคราะห์และระบุสีของรถยนต์ได้อย่างแม่นยำจากการตรวจจับล้อรถ

ในการเทรนโมเดลตรวจจับล้อรถในภาพนั้นจะใช้วิธีการเดียวกับการฝึกโมเดลตรวจจับวัตถุที่กล่าวถึงในหัวข้อ 3.7 ซึ่งมีขั้นตอนการเตรียมข้อมูลและการฝึกโมเดลดังนี้

ก. เตรียมชุดข้อมูล การเตรียมชุดข้อมูลสำหรับการตรวจจับล้อรถจะต้องมีการติดป้ายกำกับตำแหน่งของล้อหน้าและล้อหลังในภาพรถยนต์แต่ละภาพ โดยใช้ข้อมูลจากการถ่ายภาพด้านข้างของรถที่สามารถมองเห็นตำแหน่งล้อได้ชัดเจน ข้อมูลนี้จะต้องมีการระบุขอบเขตที่ชัดเจนของล้อแต่ละล้อเพื่อให้โมเดลสามารถเรียนรู้ได้อย่างถูกต้อง

ข. ฝึกโมเดล โดยจะใช้คำสั่ง yolo train พร้อมกับการตั้งค่าต่างๆ เช่น ขนาดของภาพ จำนวน epochs และ learning rate ที่เหมาะสม เพื่อให้โมเดลสามารถเรียนรู้การตรวจจับล้อรถได้อย่างแม่นยำ

ค. ประเมินผลการเทรน โดยการตรวจสอบค่าความแม่นยำและค่า loss รวมถึงการวิเคราะห์ค่า Mean Average Precision (mAP) เพื่อประเมินความสามารถในการตรวจจับตำแหน่งของล้อในภาพได้ถูกต้อง

ง. ทดสอบโมเดล กับชุดข้อมูลที่ไม่เคยเห็นมาก่อน เพื่อดูว่าความสามารถในการตรวจจับล้อรถและตำแหน่งที่สนใจมีความแม่นยำหรือไม่

เมื่อโมเดลสามารถตรวจจับล้อได้อย่างถูกต้องแล้ว ขั้นตอนต่อไปคือการหาจุดที่สนใจในภาพเพื่อใช้ในการระบุสีของรถยนต์ จุดที่สนใจจะถูกเลือกจากตำแหน่งระหว่างล้อที่ตรวจจับได้ ซึ่งจะได้ตำแหน่งที่เป็นตัวถังของรถที่มีสีชัดเจน จะช่วยให้สามารถระบุจุดที่เป็นจุดสำคัญในการวิเคราะห์สีของรถได้ดีขึ้น



รูปที่ 3. 31 ตัวอย่างการระบุจุดที่สนใจ

3.9 การปรับแสงภาพที่มีความสว่างมากหรือน้อยเกินไป

การปรับแสงของภาพที่มีความสว่างมากหรือน้อยเกินไปเป็นขั้นตอนสำคัญในการปรับปรุงคุณภาพของภาพ เพื่อให้ภาพมีความสมดุลและเหมาะสมต่อการประมวลผลในขั้นตอนต่อไป ภาพที่มีคุณภาพและแสงที่สมดุลจะส่งผลต่อความแม่นยำในการประมวลผลด้วย

ในการปรับแสงของภาพที่มีความสว่างมากหรือน้อยเกินไปในโปรเจกต์นี้ จะใช้การพิจารณา LAB color space โดยพิจารณาแชนแนล L ซึ่งเป็นแชนแนลที่ระบุค่าความสว่างของพิกเซลในรูปภาพ เพื่อตรวจสอบว่าภาพนั้นสว่างเกินไปหรือมืดเกินไป ค่า L จะอยู่ในช่วง 0 ถึง 255 โดยค่าต่ำหมายถึงมืด และค่าสูงหมายถึงสว่าง

3.9.1 การคำนวณค่าความสว่างของภาพ

ในการพิจารณาความสว่างของภาพ จะใช้ค่ามัธยฐานและใช้ค่าเฉลี่ยที่ตัดค่าหัวท้าย 5% ออกไปมาพิจารณาร่วมกัน โดยนิยามสมการดังนี้

ก. ค่ามัธยฐาน (Median)

$$L_{median} = median(L) \quad (1)$$

ข. ค่าเฉลี่ยที่ถูกตัดขอบ (Trimmed Mean)

$$L_{trimmed\ mean} = \frac{1}{N}\sum_{i=k}^{N-k} L_i \quad (2)$$

โดย kคือค่าที่กำหนดให้ตัดขอบ 5% ของข้อมูลออกไปก่อนคำนวณค่าเฉลี่ย หากค่ามัธยฐานหรือค่าเฉลี่ยที่ถูกตัดขอบของ L ต่ำกว่า 80 จะพิจารณาว่าภาพนั้นมืดเกินไป และต้องทำการปรับแสงเพิ่มขึ้น

3.9.2 การเพิ่มความสว่างของภาพ

หากภาพถูกวิเคราะห์ว่าเป็นภาพมืด จะทำการเพิ่มแสงโดยการปรับค่าในแชนแนล L ให้สูงขึ้น และแทนที่ค่าเดิม โดยใช้สมการดังนี้

$$L_{new} = L + (100 - L_{meduim}) \times 0.5 \quad (3)$$

เมื่อทำการปรับปรุงแสงในภาพโดยใช้สมการที่ 3 แล้ว อาจต้องเพิ่มความคมชัดของภาพเพิ่มเติมด้วยวิธี CLAHE (Contrast Limited Adaptive Histogram Equalization) ซึ่งเป็นเทคนิคที่ช่วยปรับ contrast ให้เหมาะสมโดยแบ่งภาพออกเป็น grid (เช่น 8×8) แล้วทำ Histogram Equalization ให้แต่ละส่วนของภาพ และจำกัดการเพิ่ม contrast เพื่อป้องกันไม่ให้เกิด noise ที่มากเกินไป

3.9.3 การลดความสว่างของภาพ

หากภาพไม่ถูกวิเคราะห์ว่าเป็นภาพมืด จะทำการลดแสงลงเพื่อเพิ่มความคมชัดของสีและลดแสงสว่างที่อาจรบกวน โดยใช้สมการดังนี้

$$L_{new} = L - (L_{median} - 80) \times 0.5 \quad (4)$$

การใช้สมการนี้ช่วยให้ภาพมีความสมดุลของแสงมากขึ้น ลดแสงที่มากเกินไป และช่วยเพิ่มความคมชัดของภาพเพื่อให้เหมาะสมกับการประมวลผลในขั้นตอนต่อไป

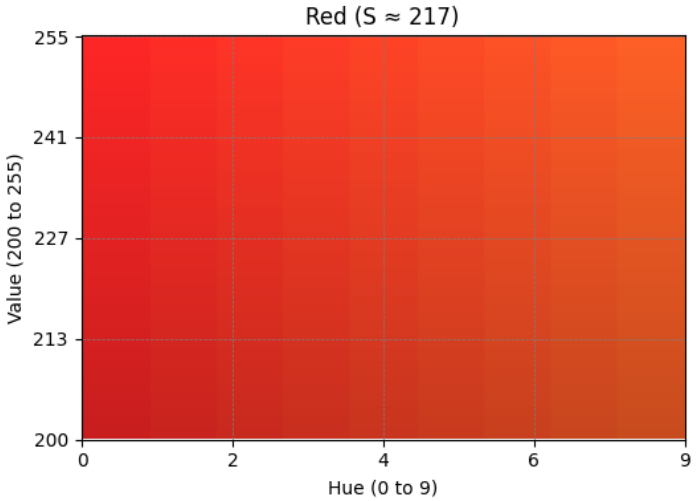
3.10 วิเคราะห์สีรถและการจำแนกสีรถ

การวิเคราะห์สีรถในระบบนี้ใช้การจำแนกสีในรูปแบบ HSV: Hue, Saturation, Value โดยจะแบ่งสีออกเป็นทั้งหมด 11 สี ได้แก่ สีแดง สีน้ำตาล สีเหลือง สีเขียว สีน้ำเงิน สีม่วง สีชมพู สีขาว สีเทา สีเงิน และสีดำ ซึ่งสีทั้งหมดจะแบ่งออกเป็น 2 กลุ่มหลัก ได้แก่ กลุ่มสีที่มีสี (Chromatic Colors) และกลุ่มสีที่ไม่มีสี (Achromatic Colors) โดยพิจารณาจากค่าความอิ่มตัวของสี (Saturation) และความสว่าง (Value) เป็นเกณฑ์ในการแยกประเภท

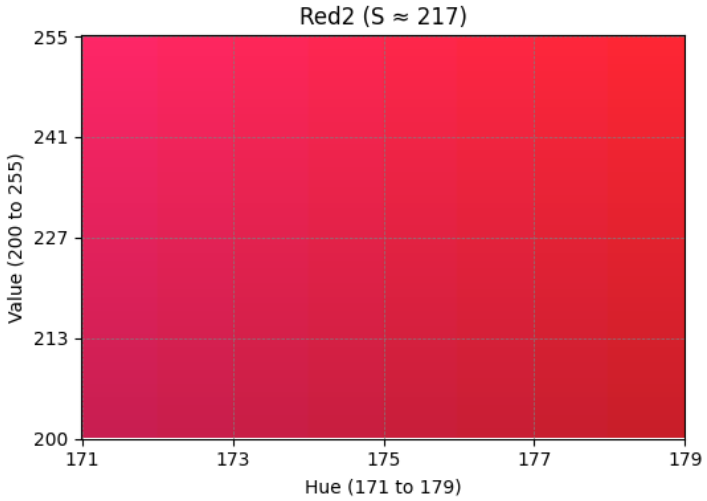
3.10.1 กลุ่มสีที่มีสี

ในการแยกแยะสีของพิกเซลในระบบนี้ กลุ่มนี้ใช้ค่า Saturation ≥ 64 และ Value ≥ 32 เพื่อระบุว่าพิกเซลนั้นมีความอิ่มตัวของสีเพียงพอและไม่มืดเกินไป ซึ่งจะทำให้สามารถแยกแยะเป็นสีในกลุ่ม Chromatic Colors หรือสีที่มีสี จากนั้นใช้ค่า Hue (0–180) เพื่อจำแนกประเภทของสีให้ละเอียดยิ่งขึ้น

ก. สีแดง (Red) เป็นสีที่มีลักษณะเฉพาะในระบบ HSV เพราะ Hue ของมันอยู่บริเวณขอบของวงล้อสี ซึ่งเริ่มที่ค่าต่ำสุดและต่อเนื่องไปยังค่าที่สูงสุด กล่าวคือ สีแดงในที่นี้ครอบคลุมช่วง Hue ตั้งแต่ 0–9 และ 171–180 ซึ่งรวมกันกลายเป็นช่วงสีแดงต่อเนื่องระหว่างจุดเริ่มต้นและปลายของวงล้อ มีตัวอย่างช่วงเฉดสีดังนี้

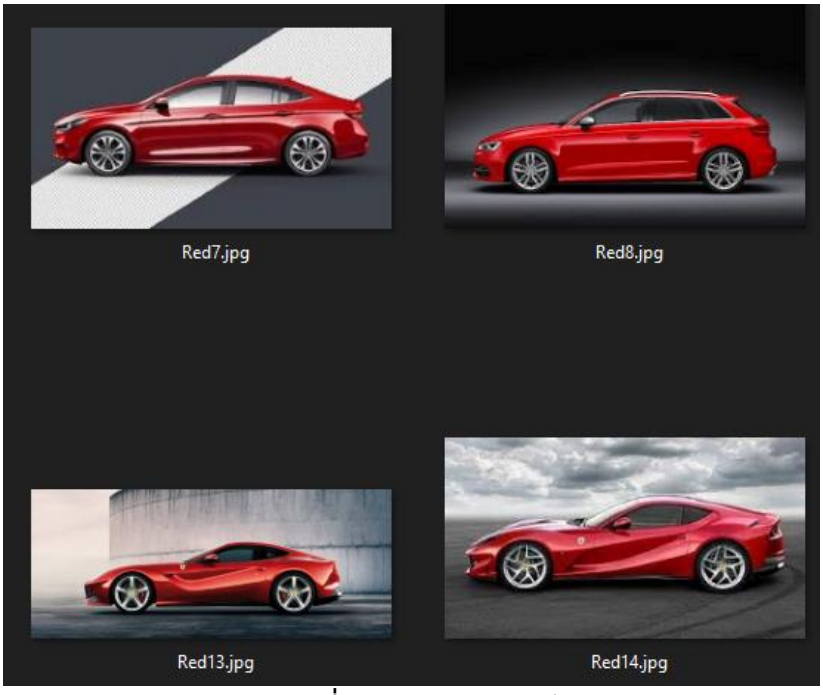


รูปที่ 3. 32 ตัวอย่างเฉดสีแดง(1)



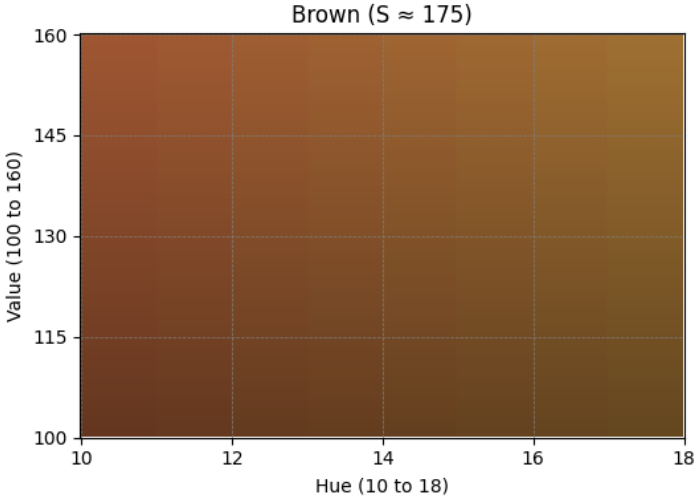
รูปที่ 3. 33 ตัวอย่างเฉดสีแดง(2)

ตัวอย่างของรถที่มีสีแดงมีดังนี้



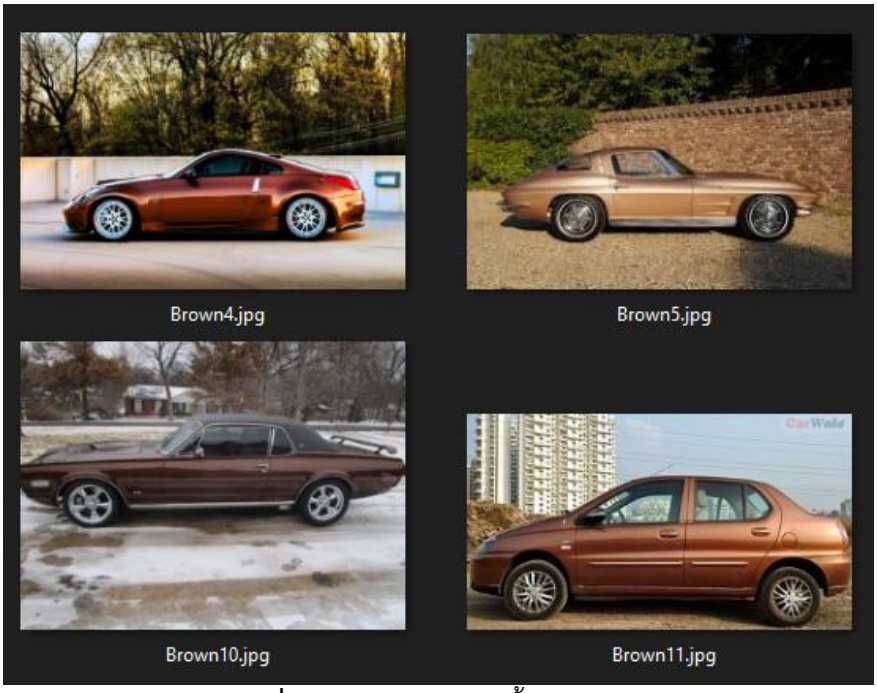
รูปที่ 3. 34 ตัวอย่างรถสีแดง

ข. สีน้ำตาล (Brown) เป็นผลของการผสมสีแดงกับความสว่างต่ำและความอิ่มตัวระดับกลาง โดยใช้ค่า Hue อยู่ระหว่าง 10–21 ซึ่งเป็นต่อเนื่องจากสีแดง แต่มีความสว่างน้อยกว่า มีตัวอย่างช่วงเฉดสีดังนี้



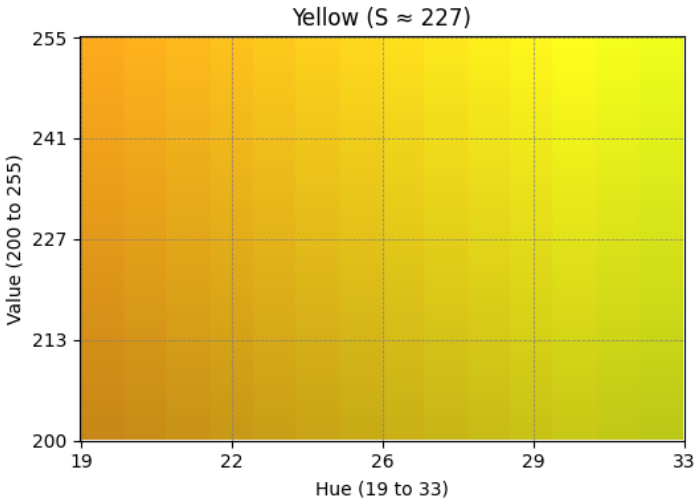
รูปที่ 3. 35 ตัวอย่างเฉดสีน้ำตาล

ตัวอย่างของรถที่มีสีน้ำตาลมีดังนี้



รูปที่ 3. 36 ตัวอย่างรถสีน้ำตาล

ค. สีเหลือง (Yellow) มี Hue อยู่ในช่วงกลางระหว่างแดงกับเขียว โดยอยู่ระหว่าง 22–33 ซึ่งให้สีเหลืองสดใส เมื่อรวมกับความอิ่มตัวสูงและค่าสว่างที่เหมาะสม สีเหลืองจะเด่นชัดมาก มีตัวอย่างช่วงเฉดสีดังนี้



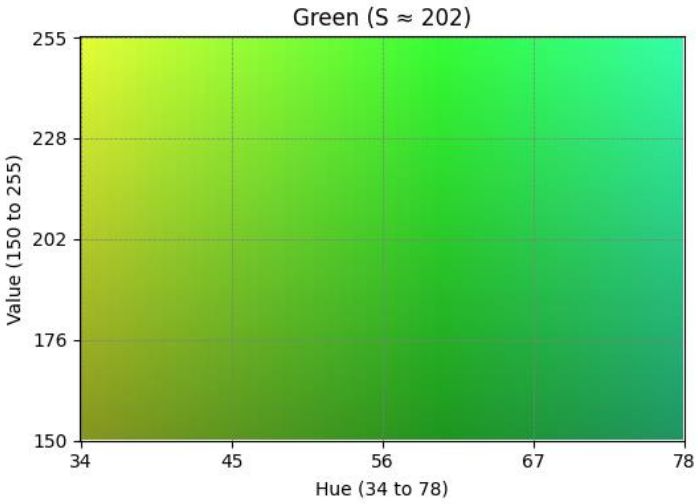
รูปที่ 3. 37 ตัวอย่างเฉดสีเหลือง

ตัวอย่างของรถที่มีสีเหลืองมีดังนี้



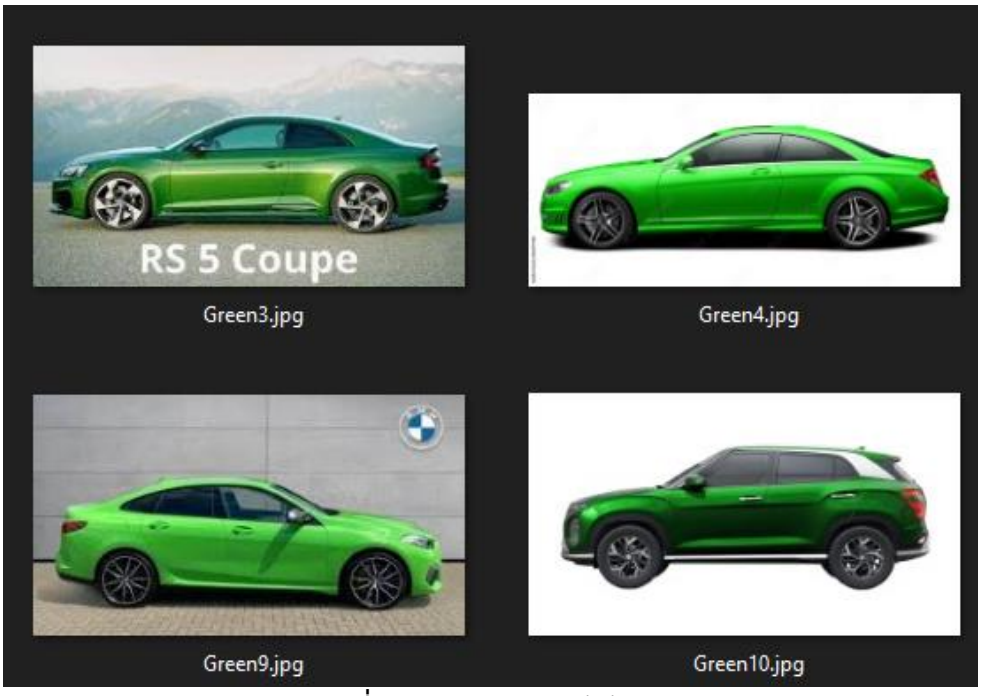
รูปที่ 3. 38 ตัวอย่างรถสีเหลือง

ง. สีเขียว (Green) มี Hue อยู่ในช่วง 34–66 ซึ่งถือเป็นช่วงกว้าง ครอบคลุมทั้งเขียวเข้มและเขียวอ่อน เงื่อนไขของ Saturation และ Value ทำให้สามารถจับสีเขียวได้หลากหลายเฉด มีตัวอย่างช่วงเฉดสีดังนี้



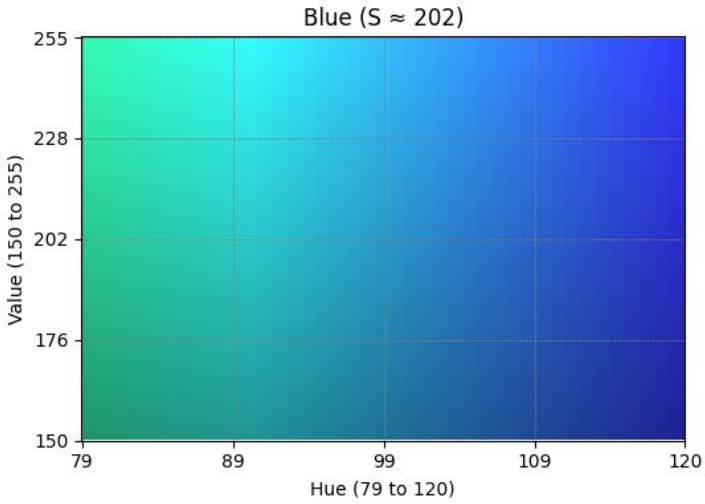
รูปที่ 3. 39 ตัวอย่างเฉดสีเขียว

ตัวอย่างของรถที่มีสีเขียวมีดังนี้



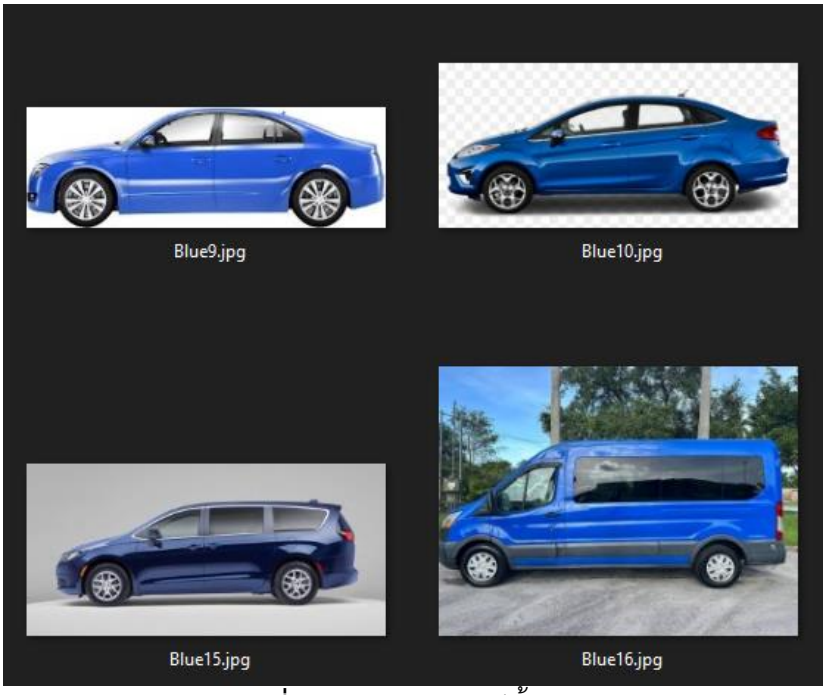
รูปที่ 3. 40 ตัวอย่างรถสีเขียว

จ. สีน้ำเงิน (Blue) มีค่า Hue อยู่ในช่วง 67–120 ซึ่งครอบคลุมสีน้ำเงินเข้มและฟ้า มีตัวอย่างช่วงเฉดสีดังนี้



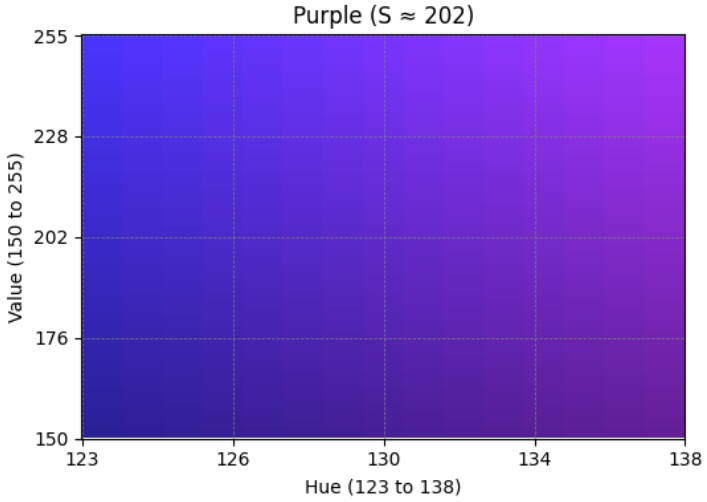
รูปที่ 3. 41 ตัวอย่างเฉดสีน้ำเงิน

ตัวอย่างของรถที่มีสีน้ำเงินมีดังนี้



รูปที่ 3. 42 ตัวอย่างรถสีน้ำเงิน

ฉ. สีม่วง (Purple) อยู่ในช่วง Hue 121–135 ซึ่งเป็นช่วงเฉพาะของสีม่วงในระบบ HSV ค่าสีนี้จะให้โทนเย็น แต่ไม่ถึงกับฟ้า มีตัวอย่างช่วงเฉดสีดังนี้



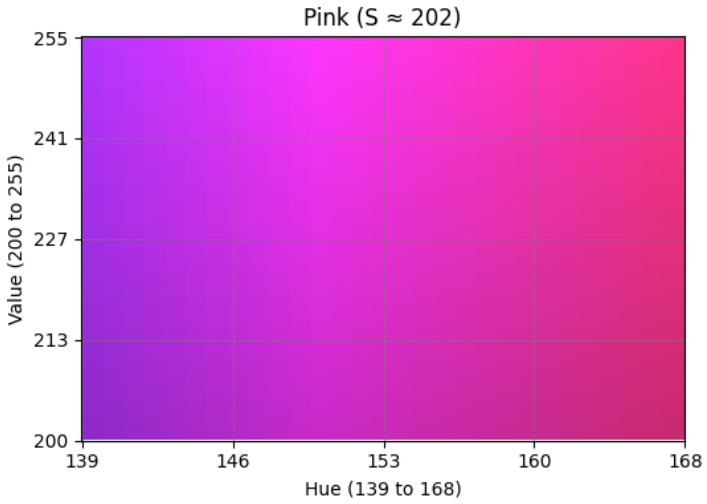
รูปที่ 3. 43 ตัวอย่างเฉดสีม่วง

ตัวอย่างของรถที่มีสีม่วงมีดังนี้



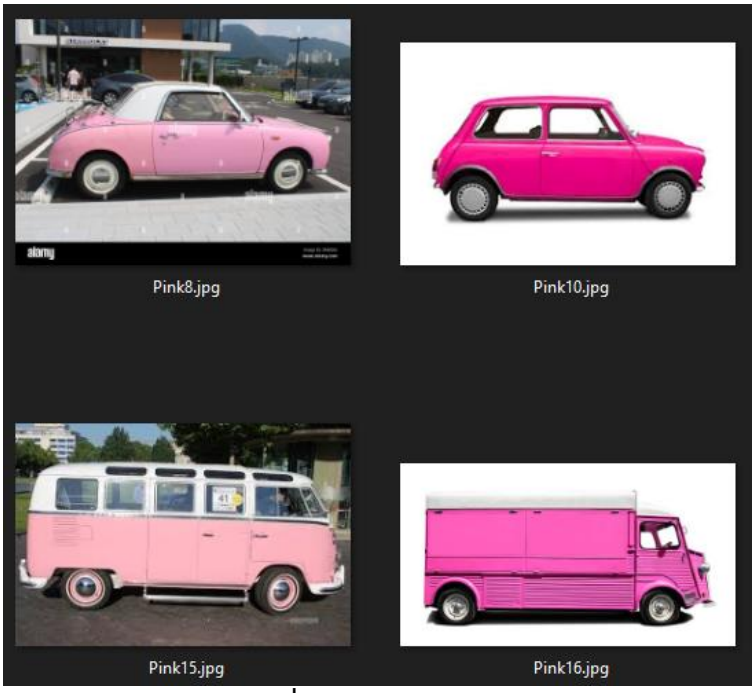
รูปที่ 3. 44 ตัวอย่างรถสีม่วง

ช. สีชมพู (Pink) อยู่ในช่วง Hue 136–160 ค่าสีนี้อยู่ระหว่างม่วงกับแดงช่วงท้าย และใช้ค่า S และ V ที่ค่อนข้างสูง เพื่อให้สีชมพูดูสว่างและสดใส มีตัวอย่างช่วงเฉดสีดังนี้



รูปที่ 3. 45 ตัวอย่างเฉดสีชมพู

ตัวอย่างของรถที่มีสีชมพูมีดังนี้

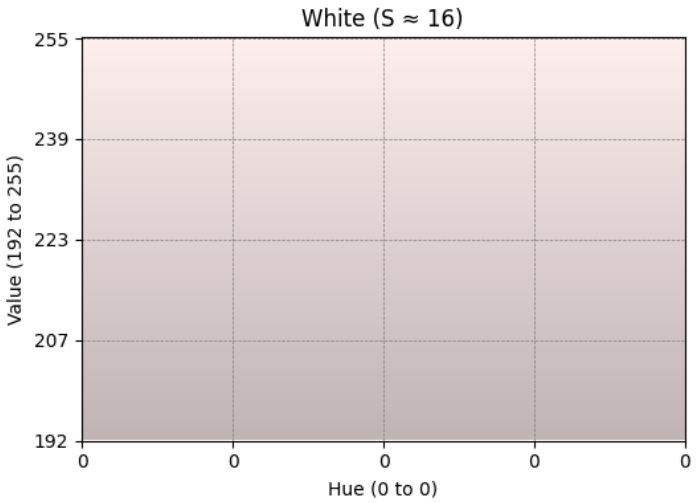


รูปที่ 3. 46 ตัวอย่างรถสีชมพู

3.10.2 กลุ่มสีที่ไม่มีสี

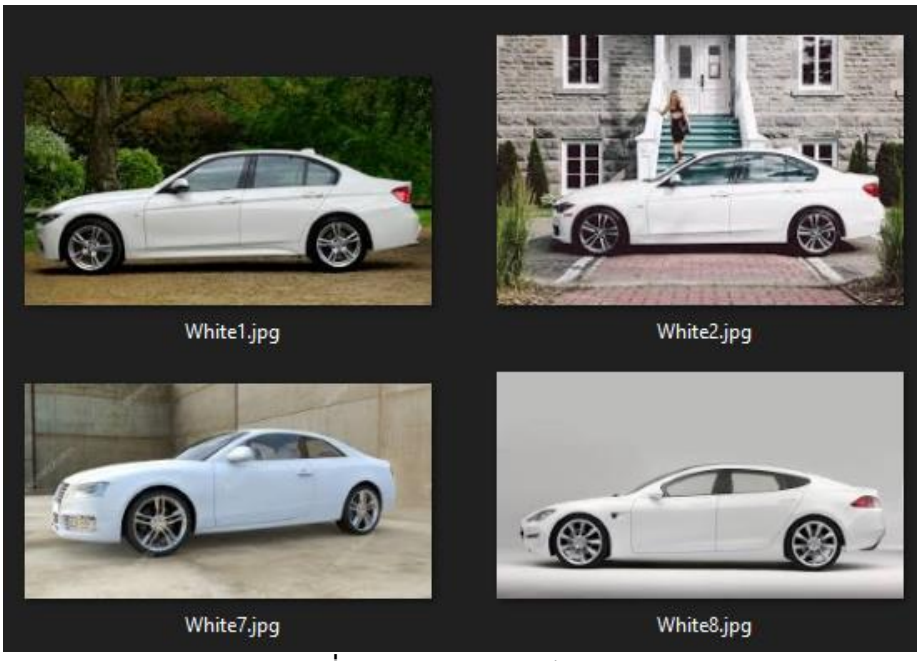
กลุ่มนี้ประกอบด้วยสีที่ไม่สามารถจัดเป็นสีเฉพาะได้ เพราะมีค่า Saturation ต่ำมาก (ไม่เกิน 63) ซึ่งหมายถึงความอิ่มตัวของสีต่ำ และใช้ค่า Value เพื่อแยกความสว่างระหว่าง สีขาว เทา เงิน และดำ โดยไม่สนใจค่า Hue

ก. สีขาว (White) สีขาวเกิดจากค่า Saturation ต่ำ และค่า Value สูงมาก ซึ่งจะอยู่ที่ Value ≥ 192 มีตัวอย่างช่วงเฉดสีดังนี้



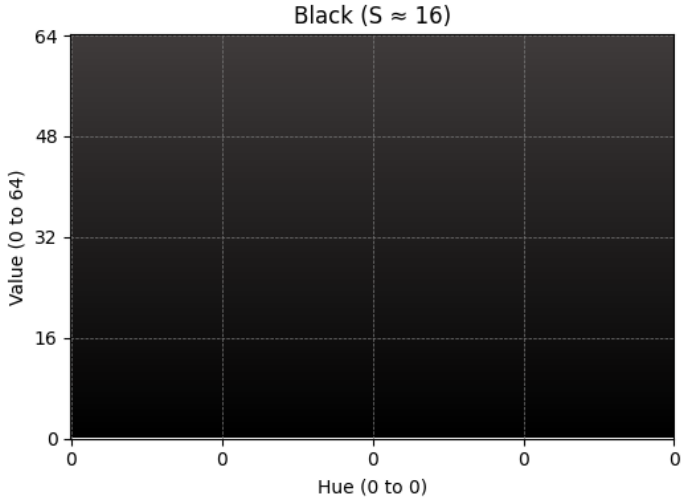
รูปที่ 3. 47 ตัวอย่างเฉดสีขาว

ตัวอย่างของรถที่มีสีขาวมีดังนี้



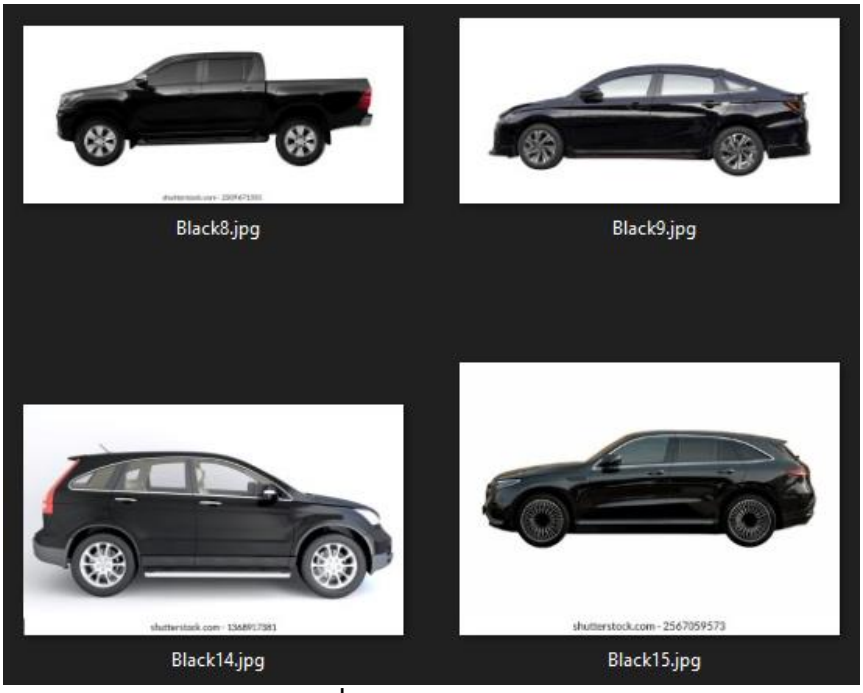
รูปที่ 3. 48 ตัวอย่างรถสีขาว

ข. สีดำ (Black) เป็นสีที่มีค่า Value และ Saturation ต่ำมาก โดยจะมีค่าน้อยกว่า 63 มีตัวอย่างช่วงเฉดสีดังนี้



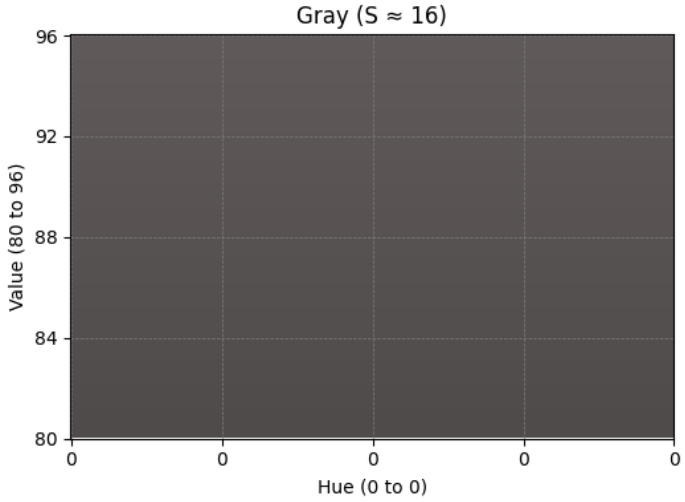
รูปที่ 3. 49 ตัวอย่างเฉดสีดำ

ตัวอย่างของรถที่มีสีดำมีดังนี้



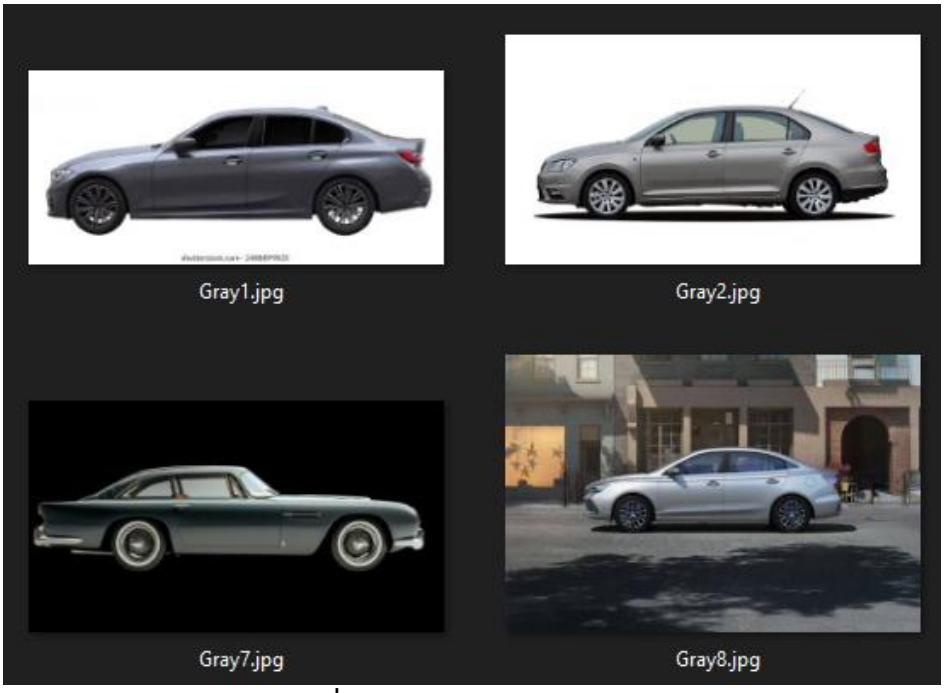
รูปที่ 3. 50 ตัวอย่างรถสีดำ

ค. สีเทา (Gray) จะอยู่ระหว่างขาวกับดำ มีค่า Saturation ต่ำ และ Value อยู่ระดับกลาง ประมาณ 100–140 มีตัวอย่างช่วงเฉดสีดังนี้



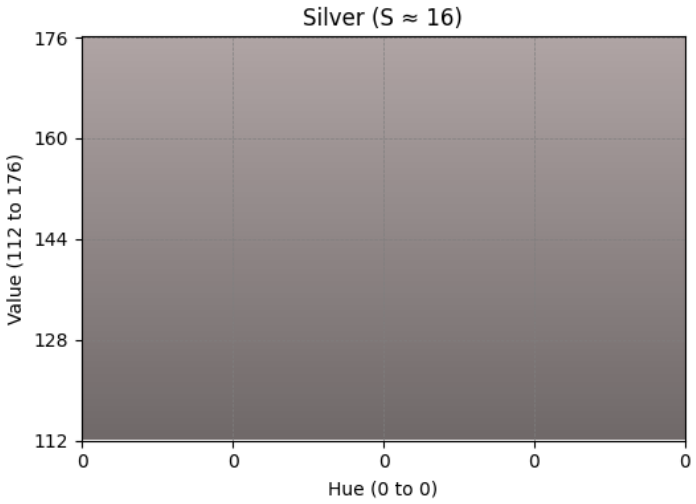
รูปที่ 3. 51 ตัวอย่างเฉดสีเทา

ตัวอย่างของรถที่มีสีเทามีดังนี้



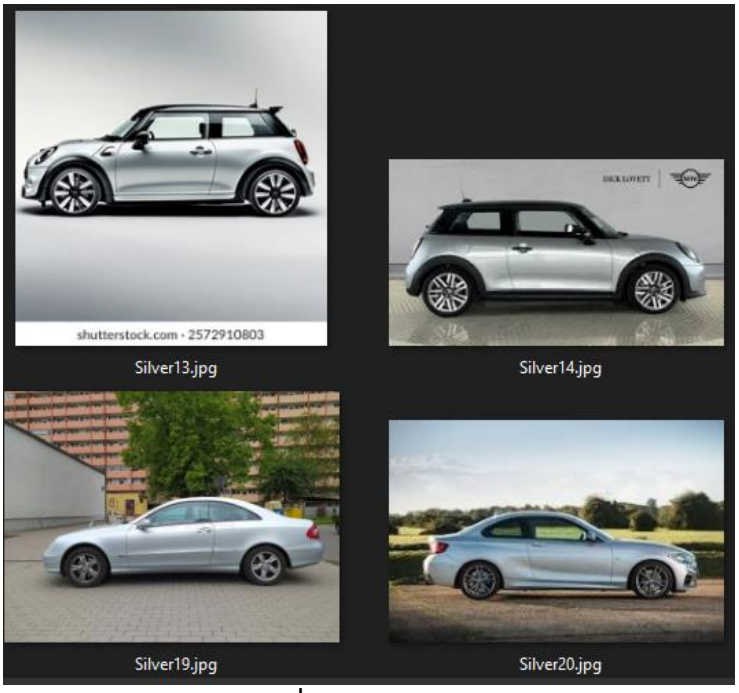
รูปที่ 3. 52 ตัวอย่างรถสีเทา

ง. สีเงิน (Silver) เป็นเฉดพิเศษที่อยู่ระหว่างสีขาวกับเทา มีความสว่างปานกลางถึงสูง ซึ่ง Value จะอยู่ระหว่าง 100–14 แต่ยังคงมี Saturation ต่ำ มีตัวอย่างช่วงเฉดสีดังนี้



รูปที่ 3. 53 ตัวอย่างเฉดสีเงิน

ตัวอย่างของรถที่มีสีเงินมีดังนี้



รูปที่ 3. 54 ตัวอย่างรถสีเงิน

3.11 การจำแนกสีของรถ

หลังจากที่เราปรับแสงของภาพให้สมดุลตามข้อ 3.9 แล้ว เราจะทำการตัดรูปภาพรถออกจากรูปภาพทั้งหมด และวิเคราะห์หาจุดที่สนใจจากรูปรถนั้นโดยอ้างอิงจากตำแหน่งของล้อรถตามที่กล่าวไว้ในข้อ 3.5 เมื่อเราได้ภาพพื้นที่ที่สนใจจะจำแนกสีมาแล้ว ก็จะนำภาพนั้นไปประมวลผลต่อใน 4 ขั้นตอน ได้แก่ การเบลอภาพ, การแปลงภาพให้อยู่ในรูปแบบสี HSV, การระบุค่า HSV ของภาพด้วย K-Means Clustering และการระบุชื่อของสีโดยการเปรียบเทียบค่า HSV

3.11.1 การเบลอภาพ

ลดความละเอียดของภาพลงเพื่อลดความซับซ้อนของสีในภาพ เพื่อให้สามารถจำแนกสีได้ง่ายขึ้น ดยใช้คำสั่ง blur ของไลบรารี OpenCV

3.11.2 การแปลงภาพให้อยู่ในรูปแบบสี HSV

เมื่อทำการเบลอภาพและได้ภาพที่มีความซับซ้อนของสีลดลงแล้ว ในขั้นตอนนี้จะทำการแปลงภาพให้อยู่ในรูปแบบสี HSV โดยใช้ไลบรารี OpenCV เพื่อให้สามารถวิเคราะห์เฉดสี (Hue) ได้ง่ายขึ้น และลดผลกระทบจากความเข้มของแสงและเงา

3.11.3 การระบุค่า HSV ของภาพด้วย K-Means Clustering

เมื่อได้ภาพที่อยู่ในรูปแบบสี HSV แล้ว ในขั้นตอนนี้จะใช้ K-Means Clustering เพื่อระบุค่า HSV ของสีหลักในภาพ โดยมีขั้นตอนดังนี้

ก. กำหนดค่า K โดยอ้างอิงจากจำนวนสีทั้งหมดที่เรากำหนดไว้

ข. ใช้ K-Means Clustering ของไลบรารี Scikit-learn เพื่อใช้หลักการ K-Means Clustering ในการหาสีหลักของภาพ โดยกำหนดค่า K ตามที่เรากำหนดไว้

ค. บันทึกค่า HSV ของสีหลักในภาพเพื่อนำไปประมวลผลต่อไป

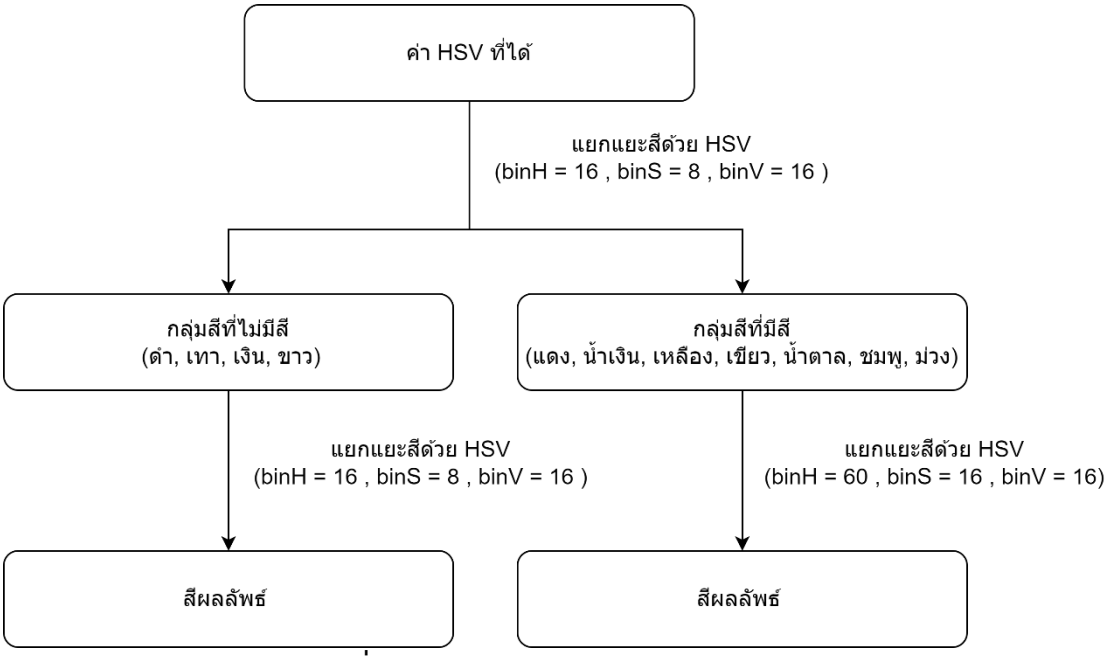
3.11.4 การระบุชื่อของสีโดยการเปรียบเทียบค่า HSV

นำค่า HSV ที่ได้ไปเปรียบเทียบโดยการแบ่ง bin และเปรียบเทียบใน 2 ขั้นตอน ได้แก่

ก. แยกภาพที่มีสีกับไม่มีสี

ข. เปรียบเทียบอีกครั้งเพื่อแยกแยะสี

ดังรูปที่ 3.55



รูปที่ 3. 55 การเปรียบเทียบค่า HSV

3.7.5 การระบุชื่อสีโดยการเปรียบเทียบค่า HSV ร่วมกับ K-Means Clustering

ในระบบที่ออกแบบไว้ จะมีการระบุชื่อของสีโดยการเปรียบเทียบค่า HSV 2 ขั้นตอน คือ แยกภาพที่มีสีกับไม่มีสี และเปรียบเทียบอีกครั้งเพื่อแยกแยะสี ดังนั้นจึงได้ทำการปรับใช้กับ K-Means Clustering โดยใช้ K-Means Clustering ในทั้งสองขั้นตอน โดยให้ค่า K ที่แตกต่างกันตามจำนวนของสีที่จะเปรียบเทียบ ดังนี้

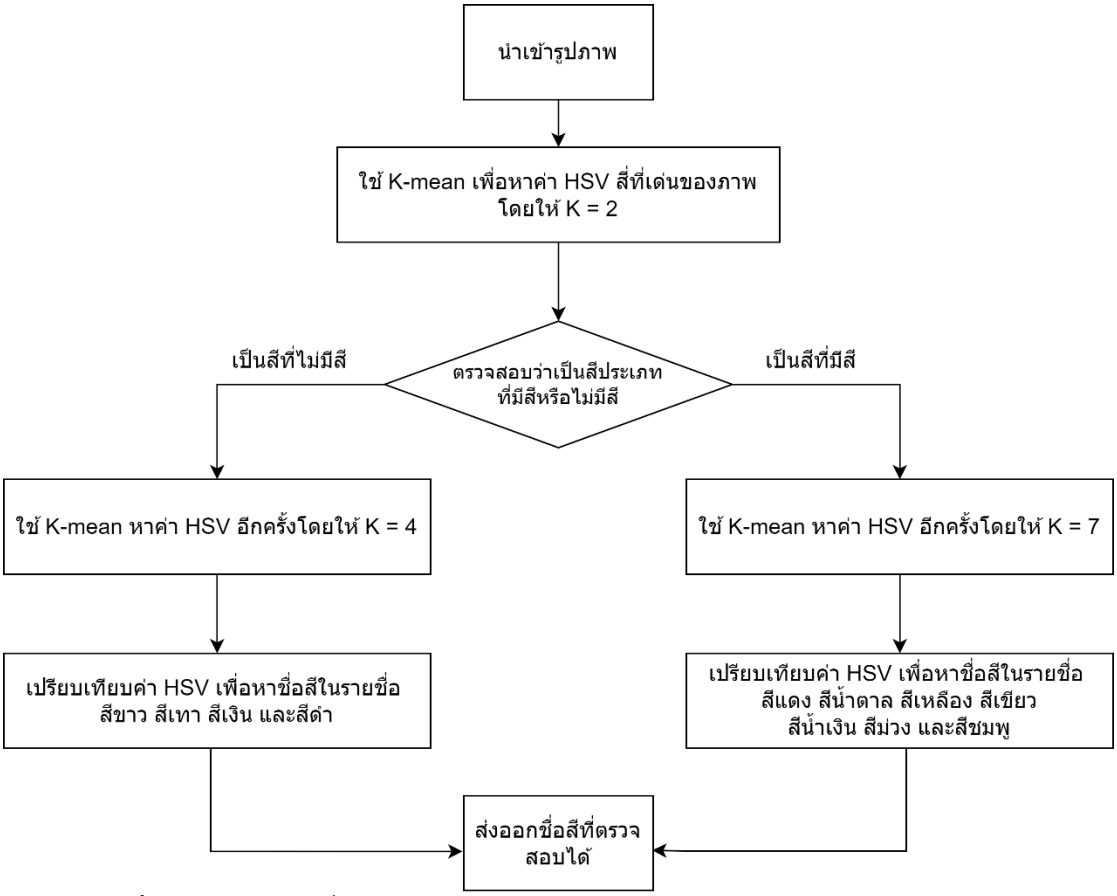
ก. ขั้นตอนที่ 1 แยกภาพที่มีสีกับไม่มีสีด้วย K-Means Clustering โดยให้ค่า K = 2 ซึ่งแทนจำนวนของประเภทสีที่จะเปรียบเทียบ ได้แก่ มีสีและไม่มีสี เพื่อให้ได้ค่า HSV ของสีหลักในภาพ

ข. ขั้นตอนที่ 2 เปรียบเทียบค่า HSV เพื่อแยกแยะภาพที่มีสีกับไม่มีสี

ค. ขั้นตอนที่ 3.1 หากผลลัพธ์เป็นภาพที่มีสี จะเปรียบเทียบอีกครั้งเพื่อแยกแยะสีด้วย K-Means Clustering โดยให้ค่า K = 7 ซึ่งแทนจำนวนของสีที่จะเปรียบเทียบ ได้แก่ สีแดง, สีน้ำตาล, สีเหลือง, สีเขียว, สีน้ำเงิน, สีม่วง และสีชมพู

ง. ขั้นตอนที่ 3.2 หากผลลัพธ์เป็นภาพที่ไม่มีสี จะเปรียบเทียบอีกครั้งเพื่อแยกแยะสีด้วย K-Means Clustering โดยให้ค่า K = 4 ซึ่งแทนจำนวนของสีที่จะเปรียบเทียบ ได้แก่ สีดำ, สีขาว, สีเทา และสีเงิน

จ. ขั้นตอนที่ 4 เปรียบเทียบค่า HSV เพื่อระบุว่าสีหลักของภาพคือสีอะไร ได้แก่ สีดำ, สีขาว, สีเทา, สีเงิน, สีแดง, สีน้ำตาล, สีเหลือง, สีเขียว, สีน้ำเงิน, สีม่วง และสีชมพู



รูปที่ 3. 56 การระบุชื่อสีโดยการเปรียบเทียบค่า HSV ร่วมกับ K-Means Clustering

3.12 ทดสอบการระบุชื่อสีโดยการเปรียบเทียบค่า HSV ร่วมกับ K-Means Clustering

ขั้นตอนการทดสอบมีดังนี้

ก. จัดเตรียมรูปภาพโดยนำรูปภาพของจุดที่สนใจที่ผ่านการปรับแสงให้สมดุลตามข้อ 3.6 มาแล้ว โดยเตรียมภาพในแต่ละสี ได้แก่ สีดำ, สีขาว, สีเทา, สีเงิน, สีแดง, สีน้ำตาล, สีเหลือง, สีเขียว, สีน้ำเงิน, สีม่วง และสีชมพู โดยแต่ละสีจะมีจำนวน 20 ภาพ

ข. ทดสอบการจำแนกสีโดยใช้ภาพที่เตรียมไว้เพื่อตรวจสอบกระบวนการจำแนกสีโดยใช้ K-Means Clustering และการเปรียบเทียบค่า HSV

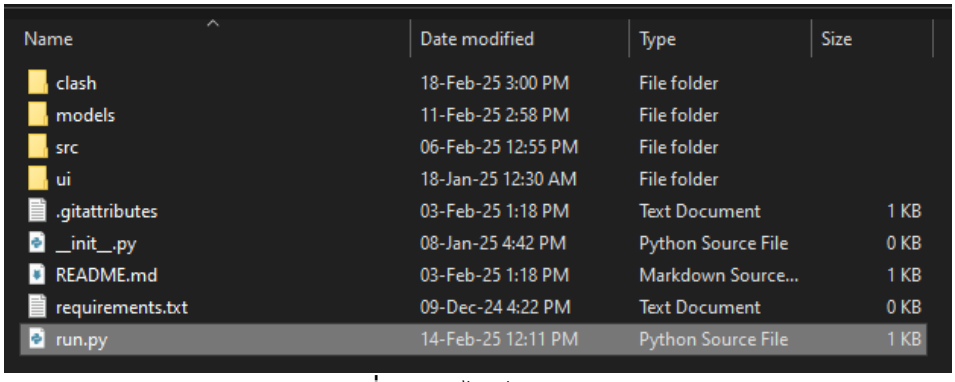
ค. บันทึกผลลัพธ์ จัดเก็บผลลัพธ์ที่ได้จากการทดสอบ พร้อมทั้งวิเคราะห์ความถูกต้องของการจำแนกสี

3.13 การทำงานของโปรแกรมโดยรวม

โปรแกรมนี้นำวิธีการและหลักการทั้งหมดที่กล่าวมาในข้อก่อนหน้ามาทำงานร่วมกัน เพื่อให้สามารถตรวจสอบประเภทและสีของรถภายในวิดีโอได้ โดยใช้ไลบรารี Tkinter เพื่อสร้าง UI ให้โปรแกรมใช้งานได้ง่ายขึ้น

3.13.1 การเริ่มต้นโปรแกรม

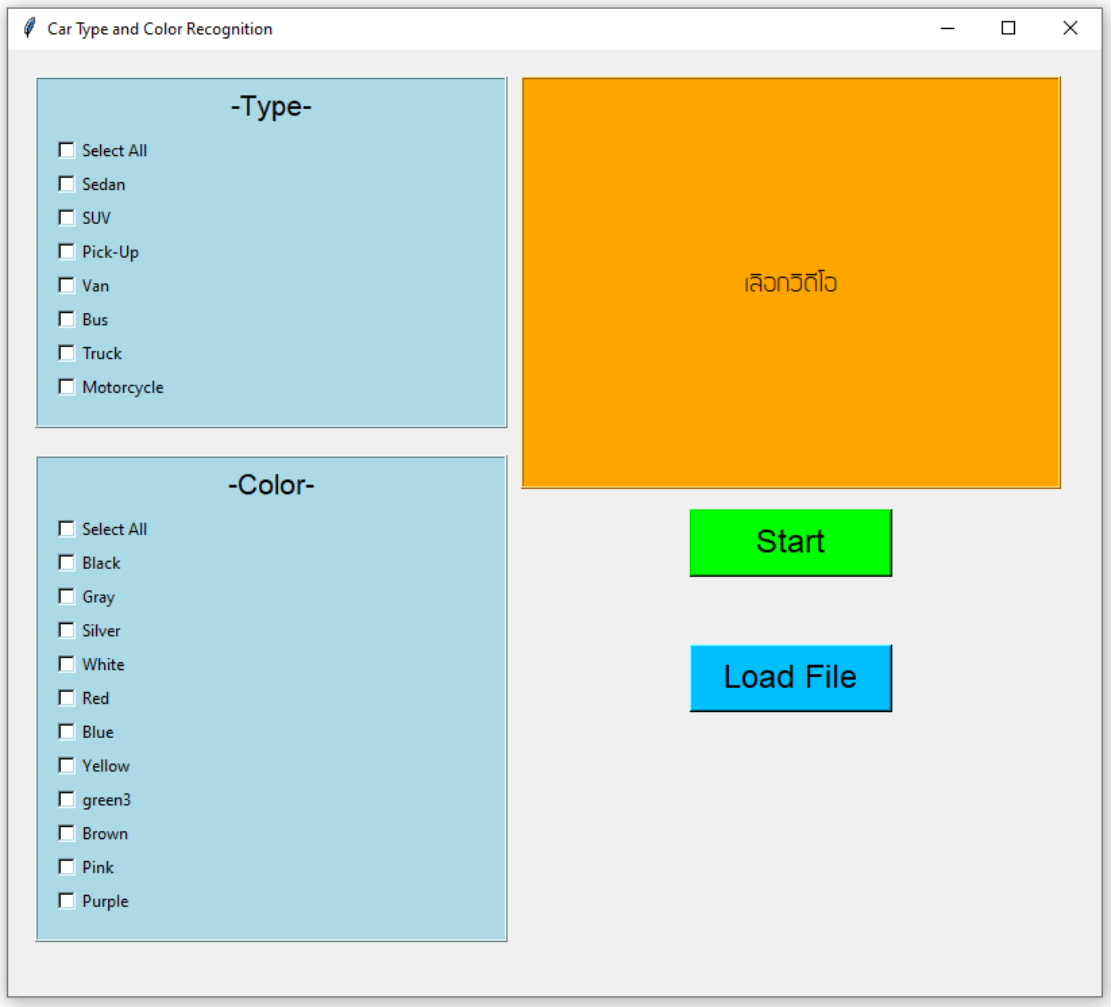
เปิดไฟล์ run.py เพื่อทำการเปิดโปรแกรม



รูปที่ 3. 57 ไฟล์ run.py

3.13.2 การกำหนดค่าเพื่อเริ่มต้นการประมวลผล

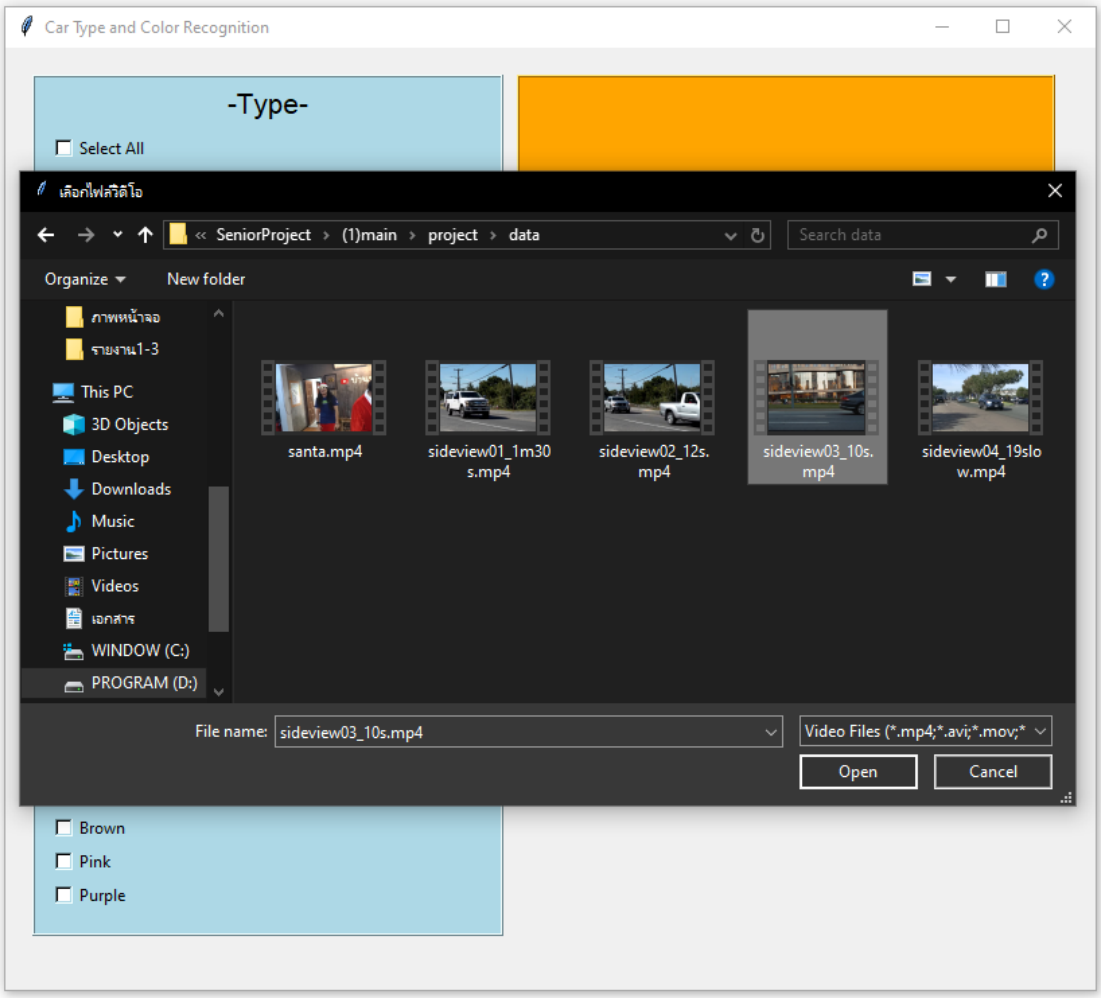
เมื่อเปิดโปรแกรมขึ้นมาแล้ว หน้าตาของโปรแกรมจะเป็นดังนี้



รูปที่ 3. 58 หน้าตาของโปรแกรม

สำหรับการค้นหาประเภทและสีของรถในวิดีโอ มีขั้นตอนเริ่มต้นดังนี้

ก. นำเข้าวิดีโอที่ต้องการค้นหาประเภทและสีของรถ

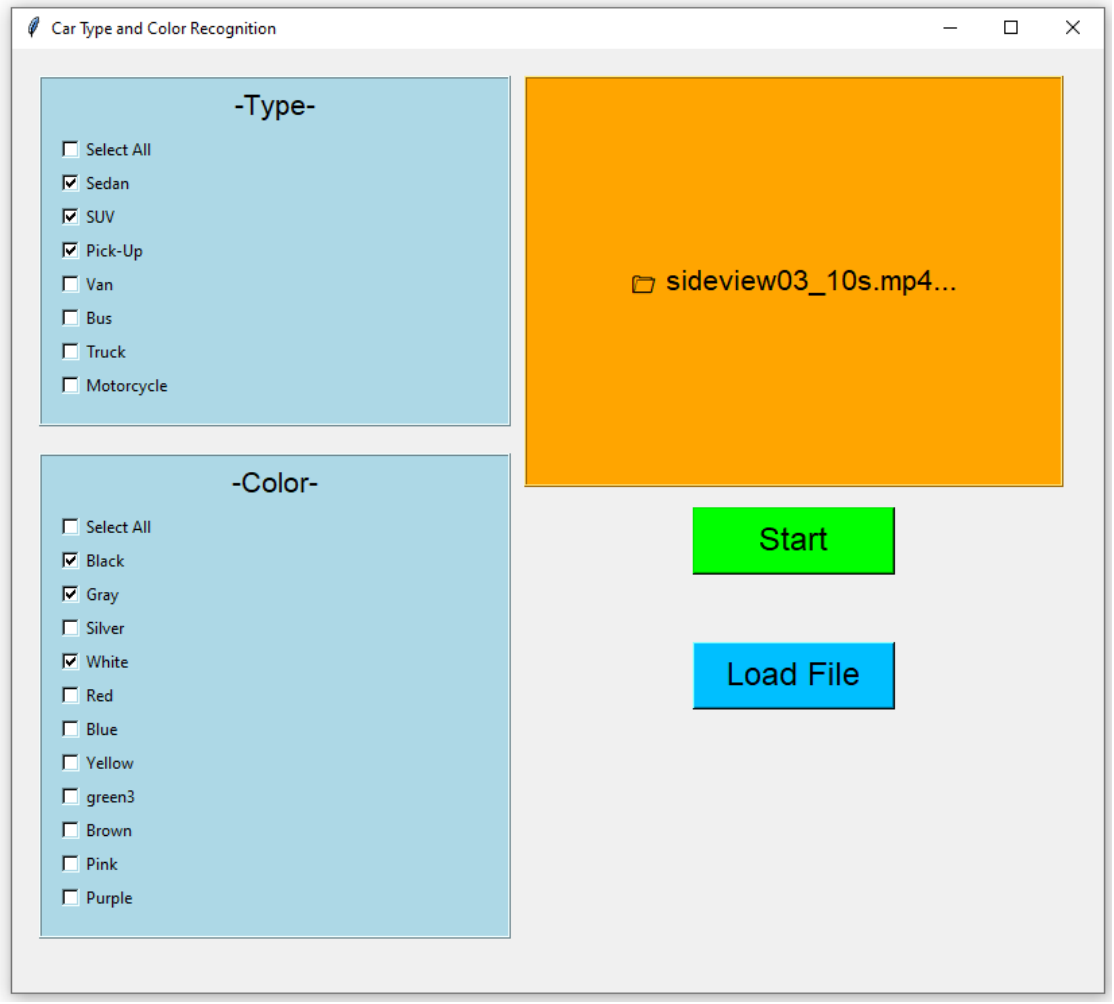


รูปที่ 3. 59 การนำเข้าวิดีโอ

ข. กำหนดสีของรถที่ต้องการค้นหา

ค. กำหนดประเภทของรถที่จะค้นหา

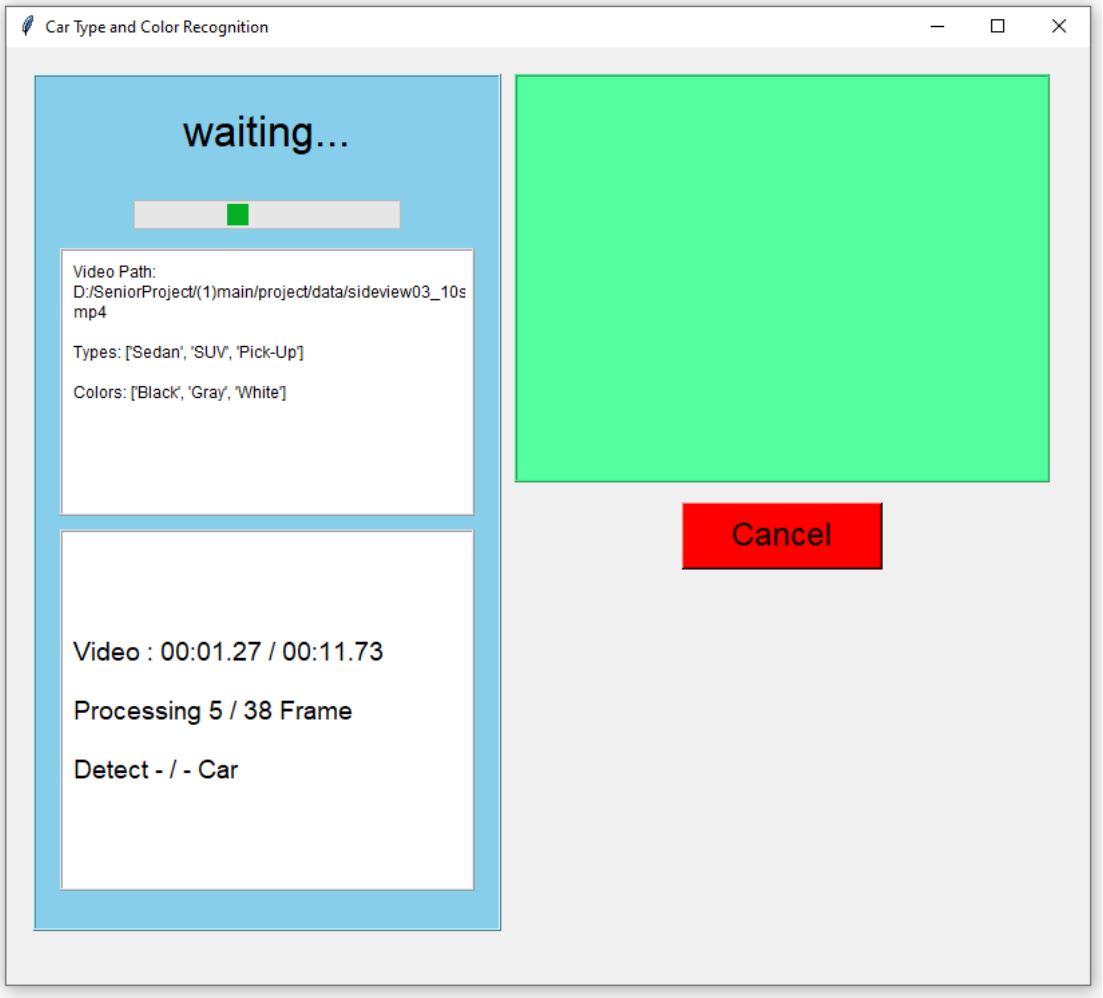
ง. กด Start เพื่อเริ่มการประมวลผล



รูปที่ 3. 60 ตัวอย่างการกำหนดค่าเพื่อเริ่มประมวลผล

3.13.3 การประมวลผล

เมื่อเริ่มการประมวลผล หน้าตาของโปรแกรมจะเป็นดังนี้

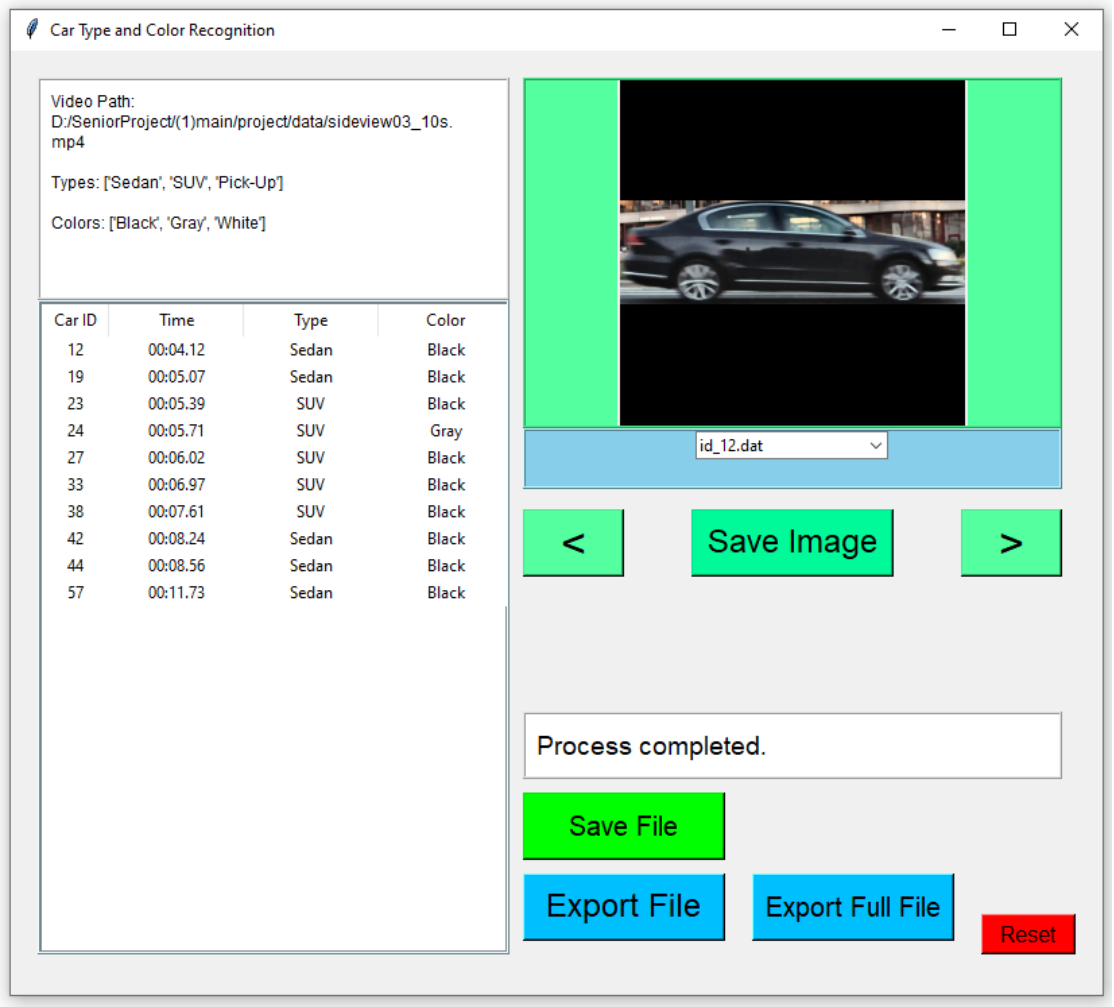


รูปที่ 3. 61 หน้าต่างระหว่างประมวลผล

ในหน้าต่างนี้จะระบุรายละเอียดของการค้นหาและความคืบหน้าของการประมวลผล หากพบข้อผิดพลาดหรือต้องการแก้ไขรายละเอียดการค้นหา สามารถกด Cancel เพื่อกลับไปยังหน้าเริ่มต้น

3.13.4 การแสดงผลลัพธ์

เมื่อการประมวลผลเสร็จสิ้น หน้าตาของโปรแกรมจะเป็นดังนี้

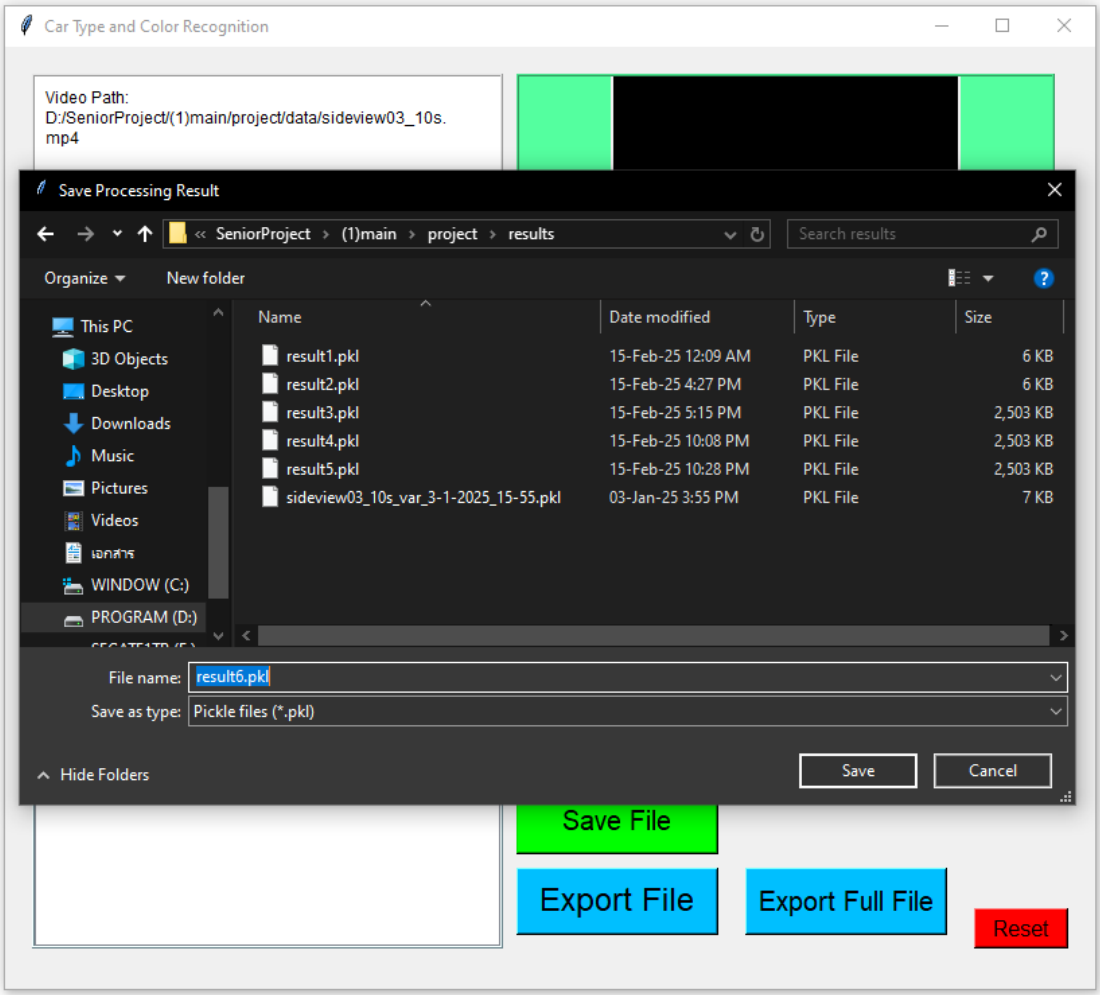


รูปที่ 3. 62 หน้าต่างแสดงผลลัพธ์

ในหน้าต่างนี้จะแสดงรายละเอียดของผลลัพธ์ในรูปแบบตาราง พร้อมภาพประกอบของรถที่พบในวิดีโอ เพื่อช่วยในการตรวจสอบผลการประมวลผล

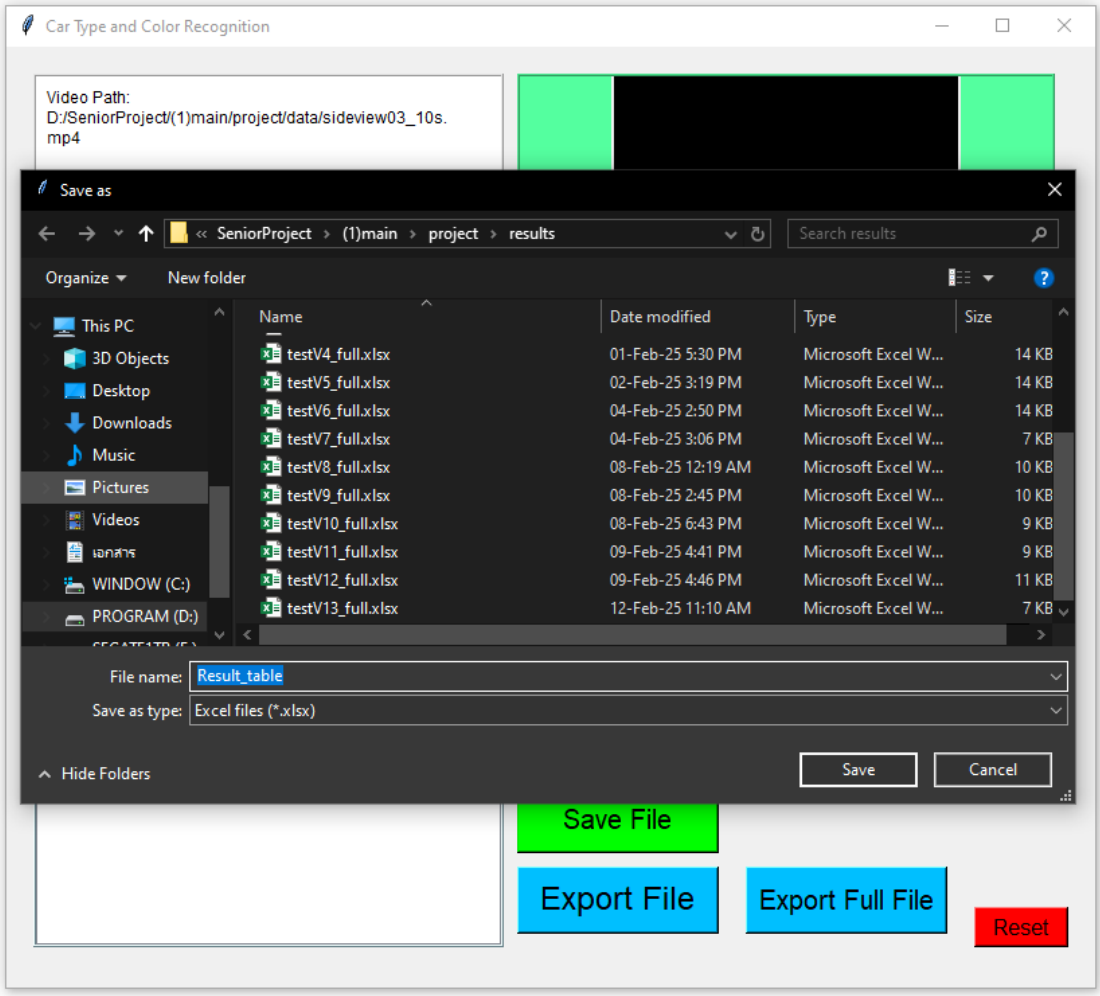
3.13.5 การส่งออกและบันทึกผลลัพธ์

เมื่อพอใจกับผลลัพธ์แล้ว สามารถกดปุ่ม Save File เพื่อบันทึกไฟล์ในรูปแบบ .plk และสามารถโหลดกลับมาแสดงผลภายหลังโดยใช้โปรแกรมนี้



รูปที่ 3. 63 การบันทึกไฟล์ในรูปแบบ .plk

หรือสามารถกดปุ่ม Export File เพื่อบันทึกผลลัพธ์ในรูปแบบ ตาราง Excel เพื่อนำไปใช้งานต่อ โดยมีรายละเอียดของตารางดังนี้

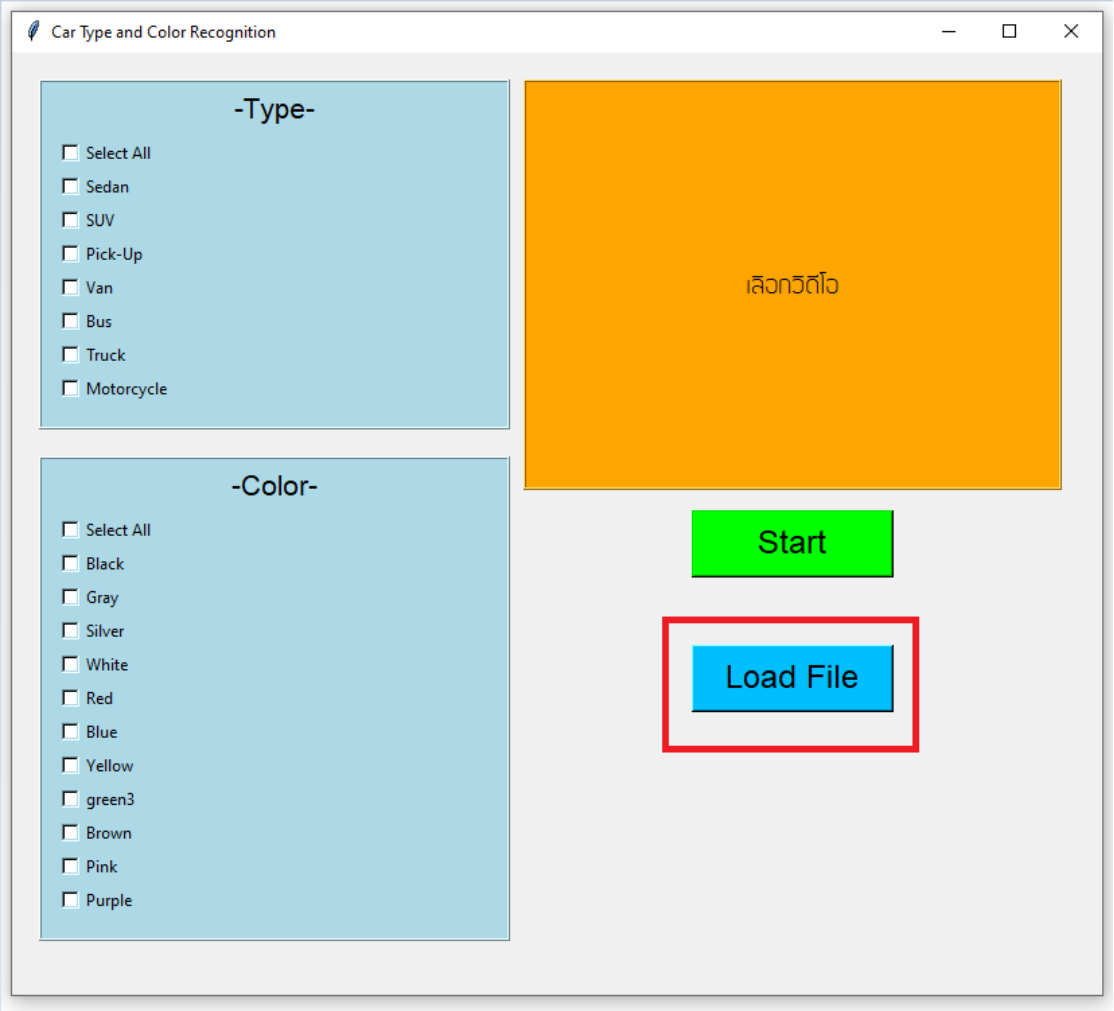


รูปที่ 3. 64 การบันทึกไฟล์เป็นตาราง Excel

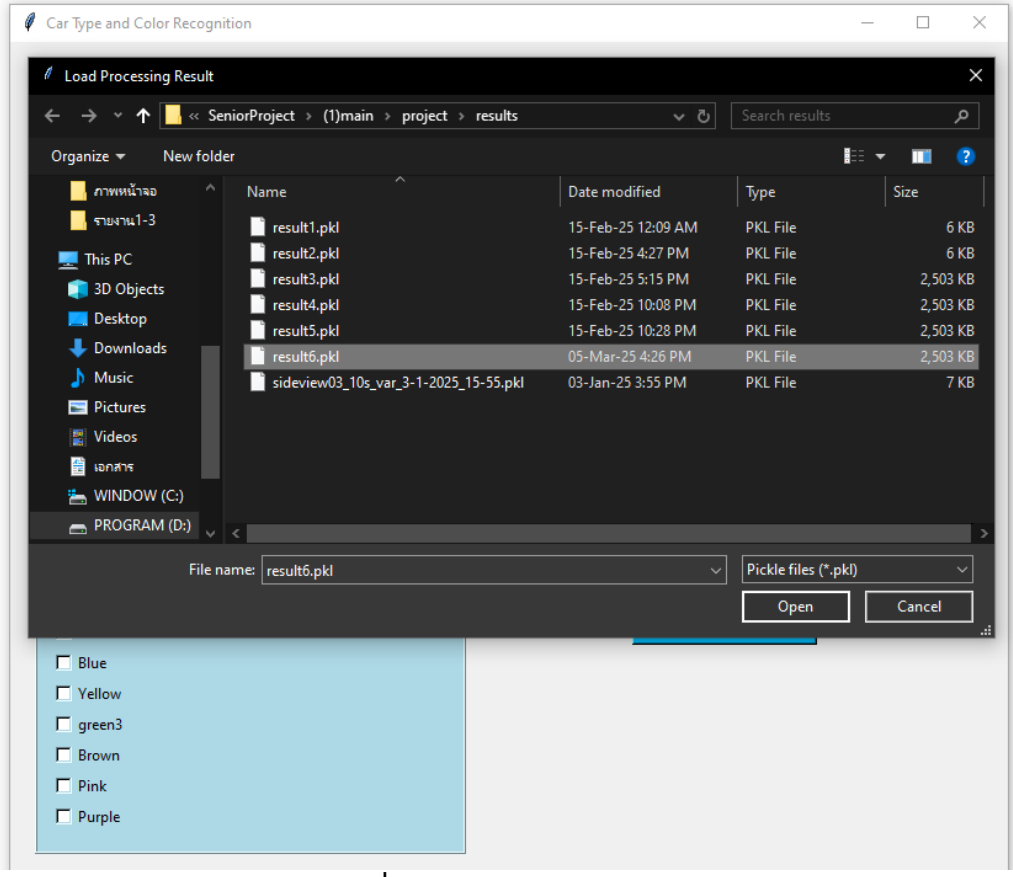
	A	B	C	D	E	F	G	H	I	J	K
1	ID	Frame	Time (Second)	Timestamp	Type	Color	H	S	V	Confidence	
2	12	14	4.12	00:04.12	Sedan	Black	110.8205573	30.92727623	34.59262227	94.75328922	
3	19	17	5.07	00:05.07	Sedan	Black	108.2737564	76.37993139	56.14939966	91.72107577	
4	23	18	5.39	00:05.39	SUV	Black	113.9895225	38.05014796	56.54610893	90.77337384	
5	24	19	5.71	00:05.71	SUV	Gray	96.3465311	57.59694986	100.3572615	95.39011717	
6	27	20	6.02	00:06.02	SUV	Black	118.1651612	27.63266029	65.91640099	91.65768027	
7	33	23	6.97	00:06.97	SUV	Black	104.9213042	59.02958241	49.38604233	92.44958162	
8	38	25	7.61	00:07.61	SUV	Black	2.09368071	2.027962552	18.7122444	92.8314507	
9	42	27	8.24	00:08.24	Sedan	Black	0.310469529	1.428643148	29.41453515	84.12446976	
10	44	28	8.56	00:08.56	Sedan	Black	0.531861172	1.486643138	31.78211227	82.21107721	
11	57	38	11.73	00:11.73	Sedan	Black	109.117698	28.09789444	37.13535524	94.59938407	
12											
13											
14											

รูปที่ 3. 65 ตัวอย่างของตาราง Excel ที่บันทึก

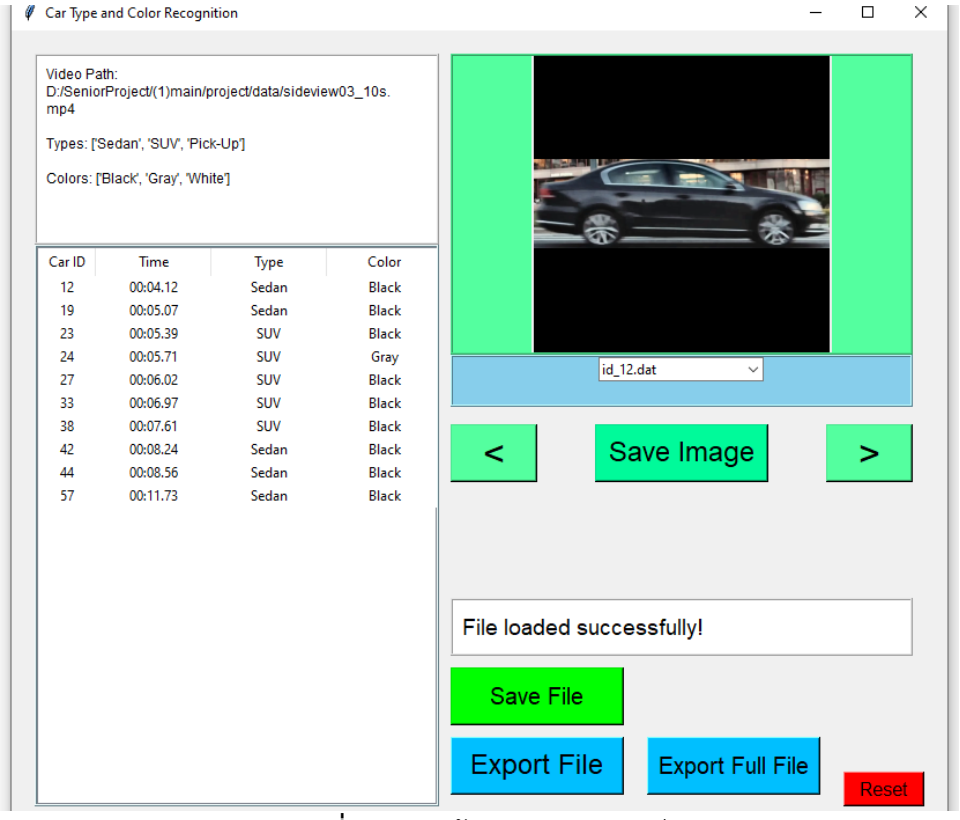
หากต้องการโหลดไฟล์ .plk กลับมาแสดงผล สามารถทำได้โดย เมื่อเริ่มต้นโปรแกรมให้กด Load File แทนการกด Start เพื่อโหลดไฟล์ .plk ที่บันทึกไว้



รูปที่ 3. 66 หน้าเริ่มต้นของโปรแกรม



รูปที่ 3. 67 การโหลดไฟล์ .plk



รูปที่ 3. 68 หน้าต่างแสดงผลลัพธ์

3.14 การเตรียมวิดีโอเพื่อใช้ในการทดสอบ

ในการทดสอบระบบจำแนกประเภทรถยนต์และสีของรถจากภาพวิดีโอ จำเป็นต้องมีการจัดเตรียมวิดีโอที่มีคุณภาพและเหมาะสมกับสภาพแวดล้อมจริง เพื่อให้การทดสอบมีความสมจริงและสะท้อนถึงการใช้งานจริงมากที่สุด โดยขั้นตอนการเตรียมวิดีโอมีรายละเอียดดังนี้

ก. เข้าไปที่เว็บไซต์ที่ให้บริการกล้องวงจรปิดบนท้องถนนแบบออนไลน์ โดยในที่นี้เลือกใช้เว็บไซต์ https://live.iticfoundation.org/ ซึ่งเป็นแหล่งข้อมูลภาพวิดีโอจากกล้องจราจรจริงในประเทศไทย

ข. เลือกตำแหน่งกล้องที่มีภาพคมชัด และมีมุมกล้องที่สามารถมองเห็นด้านข้างของรถยนต์ได้อย่างชัดเจน เพื่อให้สามารถวิเคราะห์ลักษณะของรถยนต์และสีของรถได้อย่างถูกต้อง ซึ่งในการทดลองนี่จะใช้กล่องวงงจนปิดในบริเวณ (จ.ฉะเชิงเทรา) สามแยกถนนศรีโสธรตัดใหม่-ถนนมหาจักรพรรดิ์ มุ่งหน้ากรุงเทพฯ

ค. ทำการบันทึกวิดีโอตามช่วงเวลาที่ต้องการใช้ในการทดสอบ โดยเน้นทั้งช่วงเวลากลางวันและเวลากลางคืน เพื่อประเมินความแม่นยำของระบบในสภาพแวดล้อมที่แตกต่างกัน

3.15 การทดสอบการทำงานของโปรแกรม

ขั้นตอนการทดสอบมีดังนี้

ก. เตรียมไฟล์สำหรับทดสอบ โดยใช้วิดีโอบนท้องถนนที่มีความยาว 1 นาที ทั้งในเวลากลางวันและเวลากลางคืน รวมทั้งหมด 2 วิดีโอ

ข. ตรวจสอบวิดีโอทุกไฟล์ด้วยมือ โดยบันทึกประเภทและสีของรถทุกคัน พร้อมช่วงเวลาที่พบ เพื่อใช้เป็นเกณฑ์ในการเปรียบเทียบกับผลลัพธ์ของโปรแกรม

ค. เริ่มต้นประมวลผลวิดีโอด้วยโปรแกรม โดยกำหนดให้ค้นหารถทุกประเภทและทุกสีที่สามารถตรวจพบได้

ง. ทำตามขั้นตอน ค. กับทุกวิดีโอที่เตรียมไว้

จ. เปรียบเทียบผลลัพธ์ของโปรแกรมกับข้อมูลที่บันทึกไว้ในตอนแรก

ฉ. บันทึกผลการทดสอบ

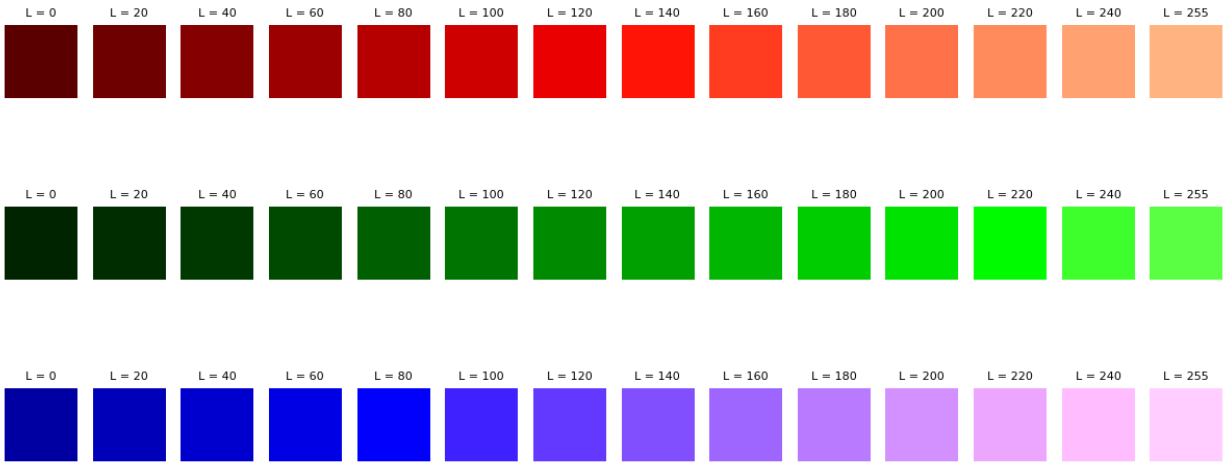
บทที่ 4
ผลการทดลองและวิเคราะห์

4.1 ผลการทดสอบเพื่อหาวิธีในการปรับแสงภาพ

ในการทดลองนี้จะแบ่งเป็นสองขั้นตอนคือ การปรับค่า L ด้วยตัวเอง และ การสังเกตค่า มัธยฐานและค่าเฉลี่ยนที่ถูกตัดขอบ 5% ของค่า L จากรูปภาพในสถานที่จริง

4.1.1 ผลการปรับค่า L ด้วยตัวเอง

ในหัวข้อนี้ เราจะวิเคราะห์ผลของการปรับค่า L (ความสว่าง) ในสีสามสี ได้แก่ แดง (Red), เขียว (Green), และน้ำเงิน (Blue) ในระบบสี LAB* โดยการปรับค่า L ทีละ 20 หน่วยจากค่าเริ่มต้น 0 ไปจนถึง 255 เพื่อสังเกตการเปลี่ยนแปลงของสีเหล่านี้เมื่อค่า L เปลี่ยนไป ดังรูปที่ 4.1



รูปที่ 4. 1 การปรับค่า L เพื่อสังเกตความเปลี่ยนแปลง

การปรับค่า L ในสีทั้งสาม (แดง, เขียว, และน้ำเงิน) ส่งผลให้ความสว่างของแต่ละสีเพิ่มขึ้นตามลำดับ เมื่อค่า L เพิ่มขึ้นจาก 0 ถึง 255 จะทำให้สีที่ได้มีความสว่างและสดใสมากขึ้น โดยเฉพาะในระดับที่ค่า L สูงขึ้นจะทำให้สีดูสว่างชัดเจนขึ้น ขณะเดียวกันอาจส่งผลให้ความเข้มของสีลดลงหรือบิดเบือนตามค่า L ที่สูงขึ้น

การวิเคราะห์ผล:

ก. สีแดง (Red): ในตอนเริ่มต้นสีแดงที่มี L = 0 จะมีสีที่เข้มมาก เมื่อค่า L เพิ่มขึ้น สีแดงจะดูสว่างขึ้นตามลำดับ แต่สีแดงที่มีค่า L สูงมากอาจดูจางหรือเป็นสีอ่อนที่ไม่คมชัด

ข. สีเขียว (Green): สีเขียวจะมีลักษณะคล้ายกับสีแดง ในตอนเริ่มต้นที่มี L = 0 จะมีสีที่เข้มมาก เมื่อค่า L เพิ่มขึ้นก็จะมีความสว่างขึ้น แต่การปรับค่า L สูงเกินไปอาจทำให้สีเขียวดูซีด

ค. สีน้ำเงิน (Blue): สีน้ำเงินจะมีความต่างจากสีแดงและเขียว เนื่องจากในตอนเริ่มต้นที่มี L = 0 จะมีสีที่เข้มแต่ยังคงเป็นสีนำเงิน การปรับค่า L ทำให้สีนี้อาจดูจางเร็วที่สุดเมื่อเทียบกับสีอื่นๆ เพราะน้ำเงินมีลักษณะมืดกว่าทั้งสองสี

ผลการทดลองนี้แสดงให้เห็นว่าช่วง L ที่สีทั้งสามมีความคมชัดจะอยู่ที่ช่วง L = 80 - 100 สีทั้งสามจะมีความคมชัดมากที่สุด ส่วนในช่วงอื่นจะเห็นว่าหากค่า ก็จะสังเกตเห็นว่าสีซีดจางลง หรือถ้าหากน้อยไปกว่านี้ก็จะสังเกตเห็นว่าสีมีความเข้มเกินไป

4.1.2 ผลการทดสอบโดยสังเกตค่า มัธยฐานและค่าเฉลี่ยนที่ถูกตัดขอบ 5% ของค่า L จากรูปภาพในสถานที่จริง

ในการทดลองนี้ ได้ทำการวิเคราะห์ค่า L (Luminance) จากชุดภาพถ่ายในสถานที่จริง ซึ่งมีการแบ่งกลุ่มของค่า L ออกเป็นช่วง ๆ ตามค่าแสงที่ได้จากภาพ โดยการทดสอบแบ่งออกเป็น สองช่วงเวลา คือ กลางวัน และ กลางคืน. การคำนวณใช้ทั้ง มัธยฐาน และ ค่าเฉลี่ยที่ถูกตัดขอบ 5% เพื่อให้สามารถสังเกตแนวโน้มและผลกระทบจากช่วงเวลาได้อย่างชัดเจน ตารางที่ 4.1 นี้แสดงผลการทดสอบ โดยระบุช่วงของค่า L และจำนวนภาพที่ตรงกับช่วงค่าดังกล่าวในแต่ละช่วงเวลา

ตารางที่ 4. 1 ผลการทดสอบโดยสังเกตค่า มัธยฐานและค่าเฉลี่ยนที่ถูกตัดขอบ 5% ของค่า L จากรูปภาพในสถานที่จริง

ช่วงค่า L	มัธยฐาน		ค่าเฉลี่ยที่ถูกตัดขอบ 5%	
	กลางวัน	กลางคืน	กลางวัน	กลางคืน
0 - 19	0	11	0	11
20 - 39	0	9	0	9
40 - 59	0	9	0	9
60 – 79	1	1	1	1
80 - 99	7	0	7	0
100 – 119	7	0	7	0

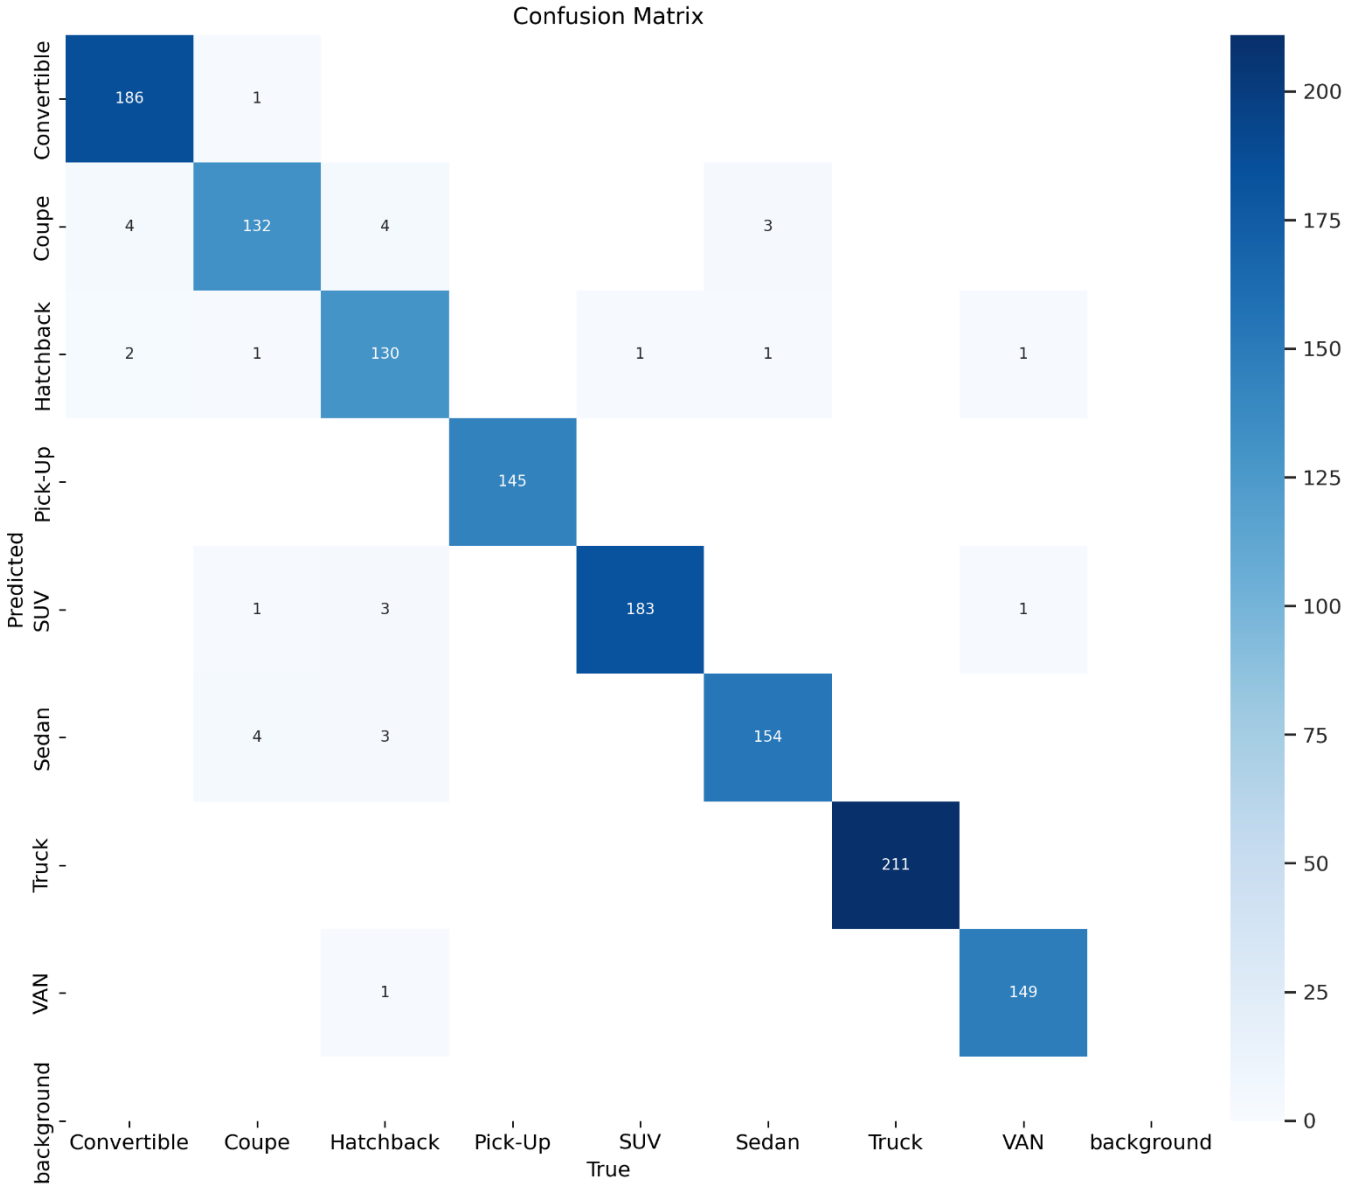
ช่วงค่า L	มัธยฐาน		ค่าเฉลี่ยที่ถูกตัดขอบ 5%	
	กลางวัน	กลางคืน	กลางวัน	กลางคืน
120 – 139	6	0	6	0
140 – 159	7	0	7	0
160 – 179	1	0	1	0
180 – 199	1	0	1	0
200 – 219	0	0	0	0
220 – 239	0	0	0	0
240 - 255	0	0	0	0

จากผลการทดลองพบว่า ภาพถ่ายในช่วงเวลากลางคืนจะมีค่ามัธยฐานและค่าเฉลี่ยที่ถูกตัดขอบ 5% ของค่า L ต่ำ อยู่ในช่วง 0 ถึง 79 ส่วนภาพถ่ายในช่วงเวลากลางวันจะมีค่ามัธยฐานและค่าเฉลี่ยที่ถูกตัดขอบ 5% ของค่า L อยู่ในช่วง 60 ถึง 199 ซึ่งทั้งสองช่วงเวลามีการแบ่งช่วงอย่างชัดเจน ทำให้สามารถแยกความแตกต่างระหว่างภาพมืดกับภาพสว่างได้

ด้วยเหตุนี้ เราจึงตัดสินใจใช้ค่ามัธยฐานและค่าเฉลี่ยที่ถูกตัดขอบ 5% ของค่า L ที่ 80 เป็นเกณฑ์ในการแบ่งแยกระหว่างภาพมืดกับภาพสว่าง เพื่อใช้ในการตัดสินใจปรับปรุงภาพ โดยการเพิ่มแสงหรือลดแสงตามที่กล่าวไว้ในข้อ 3.6.1

4.2 ผลการทดสอบการแยะแยกประเภทของรถด้วยโมเดล Yolo

การทดสอบนี้มุ่งเน้นการประเมินประสิทธิภาพของโมเดล YOLO-Cls ในการแยกประเภทของรถในรูปแบบต่าง ๆ Convertible, Coupe, Hatchback, Pick-Up, SUV, Sedan, Truck, และ VAN โดยการทดสอบนี้ใช้ Confusion Matrix เพื่อวิเคราะห์ความแม่นยำของโมเดลในการจำแนกประเภทต่าง ๆ ได้ผลลัพธ์ดังรูปที่ 4.2



รูปที่ 4. 2 Confusion Matrix ในการแยกประเภทของรถในรูปแบบต่าง ๆ

สามารถวิเคราะห์ความผิดพลาดแบบเจาะจงรายคลาสได้ดังนี้

ก. Convertible สำหรับรถประเภท Convertible โมเดลสามารถจำแนกได้อย่างถูกต้องถึง 186 จาก 187 ตัวอย่าง มีเพียง 1 กรณีที่เกิดความผิดพลาด โดยโมเดลจำแนกรถ Convertible ผิดเป็น Coupe ซึ่งเป็นความผิดพลาดที่สามารถเข้าใจได้เนื่องจากรถทั้งสองประเภทมีลักษณะภายนอกที่คล้ายคลึงกัน โดยเฉพาะในกรณีที่รถ Convertible มีการพับหลังคาลง ทำให้ไม่สามารถแยกความแตกต่างจาก Coupe ได้ชัดเจน โมเดลจึงอาจใช้ลักษณะของโครงสร้างภายนอกเพียงบางส่วนในการจำแนก ส่งผลให้เกิดความสับสน การปรับปรุงอาจทำได้โดยเพิ่มข้อมูลภาพที่แสดง

ให้เห็นลักษณะของหลังคาแบบเปิดหรือพับอย่างชัดเจน เพื่อให้โมเดลสามารถจับความแตกต่างของประเภทนี้ได้ดียิ่งขึ้น

ข. Coupe ในกลุ่มรถ Coupe โมเดลสามารถจำแนกได้ถูกต้องจำนวน 132 ตัวอย่าง จากทั้งหมด 140 ตัวอย่าง ซึ่งมีความผิดพลาดเกิดขึ้น 8 ครั้ง โดยถูกจำแนกผิดเป็น Convertible 4 ครั้ง, Hatchback 4 ครั้ง, SUV 1 ครั้ง และ Sedan อีก 1 ครั้ง สาเหตุที่ทำให้เกิดความผิดพลาดนี้คือ รูปลักษณ์ของ Coupe ที่มีขนาดกะทัดรัดและรูปทรงสปอร์ต ซึ่งมีความใกล้เคียงกับ Convertible โดยเฉพาะรถเปิดประทุนแบบสองประตู และในบางกรณี Hatchback หรือ SUV ขนาดเล็กก็อาจมีเส้นสายของตัวรถคล้ายกันจนทำให้เกิดการสับสนได้ หากภาพถ่ายไม่ได้แสดงจำนวนประตูหรือรายละเอียดของส่วนท้ายอย่างชัดเจน ความแตกต่างก็จะไม่สามารถสังเกตได้ชัดเจน สำหรับแนวทางการปรับปรุงโมเดล อาจพิจารณาใช้คุณลักษณะเพิ่มเติม เช่น จำนวนประตู หรือแนวหลังคา เพื่อช่วยในการจำแนกประเภทของรถให้แม่นยำยิ่งขึ้น

ค. Hatchback รถ Hatchback ถูกจำแนกได้ถูกต้อง 130 ตัวอย่างจากทั้งหมด 136 ตัวอย่าง โดยมีการสับสนกับ Coupe จำนวน 1 ครั้ง, Convertible 2 ครั้ง, SUV 1 ครั้ง, Sedan 1 ครั้ง และ VAN อีก 1 ครั้ง ซึ่งแสดงให้เห็นถึงความท้าทายในการจำแนกรถกลุ่มนี้ ความผิดพลาดส่วนใหญ่มาจากลักษณะท้ายลาดของ Hatchback ที่คล้ายคลึงกับรถกลุ่มอื่น โดยเฉพาะ SUV หรือ VAN ขนาดเล็กที่มีลักษณะของตัวถังสูงเล็กน้อยและมีเส้นหลังที่ลาดคล้ายกัน อีกทั้งในบางกรณีที่ภาพถ่ายไม่สามารถเห็นเส้นหลังรถอย่างชัดเจน ก็ยิ่งเพิ่มโอกาสให้เกิดความสับสน แนวทางการปรับปรุงที่แนะนำคือการเพิ่มข้อมูลภาพที่ถ่ายจากด้านท้ายหรือมุมบน เพื่อให้เห็นโครงสร้างของฝาท้ายและหลังคาชัดเจน รวมถึงใช้ตัวชี้วัดทางเรขาคณิต เช่น อัตราส่วนความสูงของกระจกหลังและระยะห่างของฐานล้อ เข้ามาช่วยในการจำแนก

ง. Pick-Up ในหมวดหมู่ของรถ Pick-Up โมเดลสามารถจำแนกได้อย่างแม่นยำโดยไม่มีความผิดพลาดเลยจาก 145 ตัวอย่างทั้งหมด ซึ่งแสดงให้เห็นว่ารถประเภทนี้มีลักษณะเฉพาะที่โดดเด่นและสามารถแยกออกจากคลาสอื่นได้อย่างชัดเจน เช่น กระบะท้ายที่ยาว และโครงสร้างตัวถังที่แตกต่างจากรถยนต์นั่งส่วนบุคคลทั่วไป ลักษณะเฉพาะเหล่านี้ส่งผลให้โมเดลสามารถเรียนรู้และจำแนกได้แม่นยำเป็นพิเศษ จึงไม่พบปัญหาในการจำแนกรถประเภทนี้

จ. SUV รถประเภท SUV ถูกจำแนกได้ถูกต้อง 183 จาก 187 ตัวอย่าง โดยมีความผิดพลาดเกิดขึ้น 4 ครั้ง ซึ่งประกอบด้วยการจำแนกผิดเป็น Coupe 3 ครั้ง, Hatchback 1 ครั้ง และ VAN อีก 1 ครั้ง ความผิดพลาดเหล่านี้มักเกิดจากลักษณะรูปร่างของ SUV ขนาดเล็กที่อาจมีความใกล้เคียงกับ Hatchback หรือ Coupe โดยเฉพาะในกรณีที่เป็น crossover ที่มีตัวถังขนาดกะทัดรัดและหากภาพถ่ายไม่ได้แสดงความสูงของใต้ท้องรถ หรือขนาดล้ออย่างชัดเจน โมเดลก็อาจตีความผิดพลาดได้ง่าย แนวทางการปรับปรุงอาจใช้การแยกแยะด้วยความสูงของตัวรถ หรือเพิ่มภาพมุมเฉียงที่สามารถแสดงโครงสร้างด้านข้างและขนาดโดยรวมได้อย่างครบถ้วน

ฉ. Sedan สำหรับรถ Sedan โมเดลสามารถจำแนกได้อย่างแม่นยำที่ 154 จาก 158 ตัวอย่าง โดยมีการจำแนกผิดเป็น Coupe 3 ครั้ง และ Hatchback 1 ครั้ง ซึ่งสาเหตุหลักมาจากลักษณะของรถ Sedan ที่มีความคล้ายคลึงกับ Coupe ในแง่ของรูปทรงเมื่อมองจากด้านข้าง โดยเฉพาะหากภาพถ่ายแสดงเพียงด้านหนึ่งของตัวรถที่ไม่สามารถนับจำนวนประตูได้ครบ หรือในกรณีของ Sedan ที่มีท้ายลาดมาก อาจคล้ายกับ Hatchback ขนาดกลางได้ การปรับปรุงโมเดลอาจทำได้โดยเพิ่มภาพที่แสดงด้านข้างของรถอย่างชัดเจน และใช้ข้อมูลเชิงโครงสร้าง เช่น จำนวนประตู หรือการมีพื้นที่ฝากระโปรงท้ายแยกต่างหาก มาใช้เป็นตัวแยกประเภท

ช. Truck สำหรับรถประเภท Truck โมเดลสามารถจำแนกได้ถูกต้องทั้งหมด 211 ตัวอย่าง โดยไม่มีความผิดพลาดเลย ซึ่งสะท้อนให้เห็นว่ารถประเภทนี้มีลักษณะที่ชัดเจนมาก เช่น ขนาดตัวถังใหญ่ ความสูง และโครงสร้างที่แตกต่างจากรถนั่งทั่วไป ทำให้โมเดลสามารถแยกแยะได้ง่ายและมีความแม่นยำสูง ไม่จำเป็นต้องมีการปรับปรุงเพิ่มเติมในส่วนนี้

ซ. VAN โมเดลสามารถจำแนกรถประเภท VAN ได้ถูกต้อง 149 จาก 151 ตัวอย่าง โดยมีการจำแนกผิดเป็น Hatchback 1 ครั้ง และ SUV อีก 1 ครั้ง ความผิดพลาดดังกล่าวสามารถอธิบายได้ว่าเกิดจากความใกล้เคียงกันของรูปลักษณ์ภายนอกระหว่าง VAN ขนาดเล็กกับ Hatchback โดยเฉพาะในมุมที่ไม่สามารถประเมินขนาดตัวถังหรือความสูงได้อย่างชัดเจน อีกทั้ง SUV บางรุ่นที่มีรูปทรงคล้ายกล่องก็อาจสร้างความสับสนให้โมเดลได้เช่นกัน แนวทางการปรับปรุงโมเดลคือการใช้คุณลักษณะด้านเรขาคณิต เช่น อัตราส่วนความสูงต่อความกว้างของตัวรถ (aspect ratio) เพื่อช่วยแยกรถ VAN ออกจากกลุ่มอื่นได้อย่างมีประสิทธิภาพมากขึ้น และการเพิ่มภาพจากมุมมองด้านหน้าและด้านข้างของรถ VAN ในชุดข้อมูลฝึกก็จะช่วยให้โมเดลเรียนรู้ลักษณะเฉพาะของรถประเภทนี้ได้ดียิ่งขึ้น

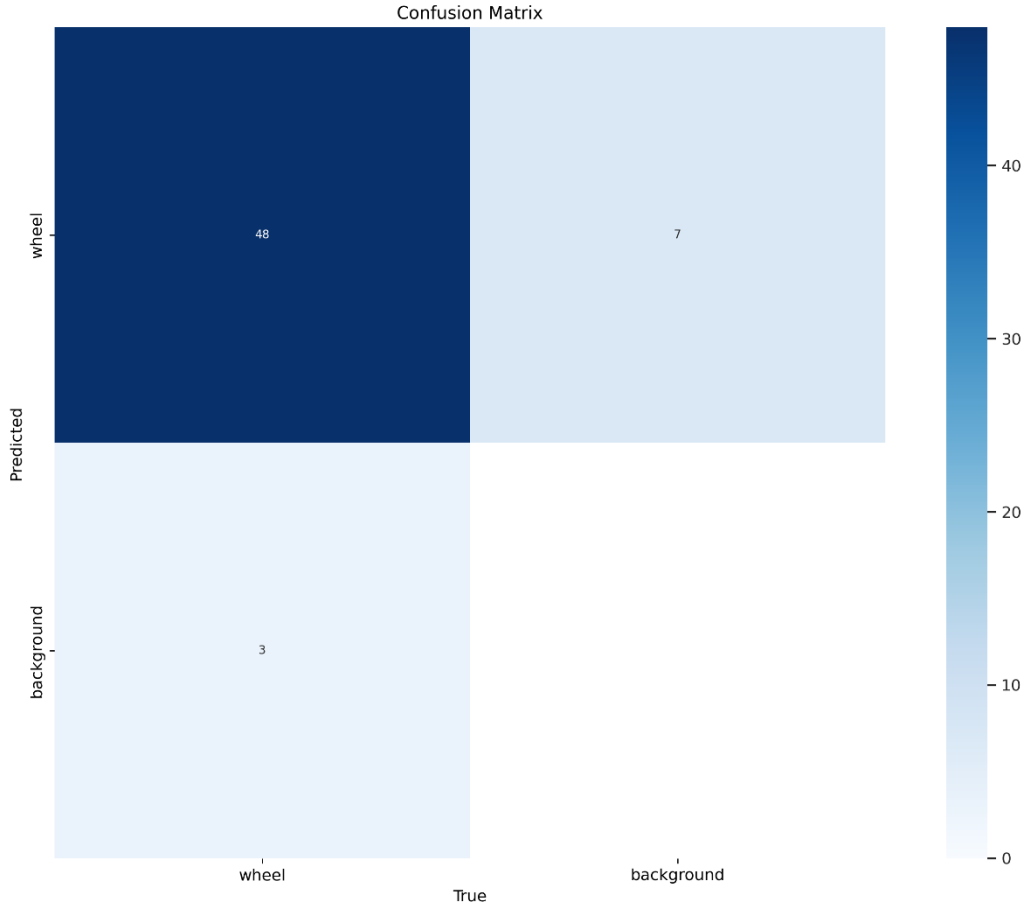
จากผลลัพธ์ของ Confusion Matrix โมเดล YOLO-Cls สามารถจำแนกประเภทของรถได้อย่างมีประสิทธิภาพในระดับที่ดี โดยคลาสที่มีความแม่นยำสูง ได้แก่ Convertible, Truck และ VAN ซึ่งมีจำนวนการทำนายที่ถูกต้องเป็นส่วนใหญ่ ในขณะที่บางคลาส เช่น Coupe, Hatchback และ Sedan มีความสับสนระหว่างกัน ซึ่งอาจเกิดจากความคล้ายคลึงของรูปทรงรถยนต์ในกลุ่มดังกล่าว นอกจากนี้ SUV และ Sedan ก็มีการสับสนกันในบางกรณี ซึ่งอาจเกิดจากการที่รูปลักษณ์ของรถทั้งสองประเภทมีความใกล้เคียงกันในบางมุมมอง โดยรวมแล้ว โมเดลสามารถจำแนกประเภทของรถได้ในระดับที่น่าพอใจ แต่ยังสามารถปรับปรุงเพิ่มเติมเพื่อเพิ่มความแม่นยำในการแยกแยะรถประเภทที่มีความคล้ายคลึงกันได้ดียิ่งขึ้น

4.3 ผลการทดสอบโมเดลตรวจจับล้อรถและการวิเคราะพื้นที่ที่สนใจ

ในการทดลองนี้จะแบ่งเป็นสองขั้นตอนคือ การทดสอบโมเดลตรวจจับล้อรถ และการวิเคราะห์พื้นที่ที่สนใจ

4.3.1 ผลการทดสอบโมเดลตรวจจับล้อรถ

การทดสอบนี้มุ่งเน้นการประเมินประสิทธิภาพของโมเดล YOLO ในการตรวจจับล้อรถเพื่อนำไปใช้ในการวิเคราะห์พื้นที่ที่สนใจเพื่อตรวจสอบสี โดยการทดสอบนี้ใช้ Confusion Matrix เพื่อวิเคราะห์ความแม่นยำของโมเดล ซึ่งได้ผลลัพธ์ดังรูปที่ 4.3



รูปที่ 4. 3 Confusion Matrix ในการตรวจจับล้อรถ

จากผลลัพธ์ของ Confusion Matrix โมเดลสามารถตรวจจับล้อรถได้ในระดับที่ดี แต่ยังมีความสับสนระหว่างพื้นที่ที่ไม่ใช่ล้อรถอยู่บ้าง ทำให้การตรวจจับล้อรถเพื่อนำไปใช้ในการวิเคราะห์พื้นที่ที่สนใจเพื่อตรวจสอบสีอาจมีข้อผิดพลาดเกิดขึ้นได้

4.3.2 ผลการวิเคราะห์พื้นที่ที่สนใจ

หลังจากสามารถตรวจจับล้อหน้าและล้อหลังของรถได้ทั้งสองล้อแล้ว ในขั้นตอนนี้จะทำการตัดรูปภาพเพื่อนำพื้นที่ที่สนใจซึ่งมีสีเด่นชัดไปวิเคราะห์หาชื่อสีต่อไป โดยได้ผลลัพธ์ของการตัดรูปภาพดังรูปที่ 4.4



รูปที่ 4. 4 ผลการวิเคราะห์พื้นที่ที่สนใจในภาพ

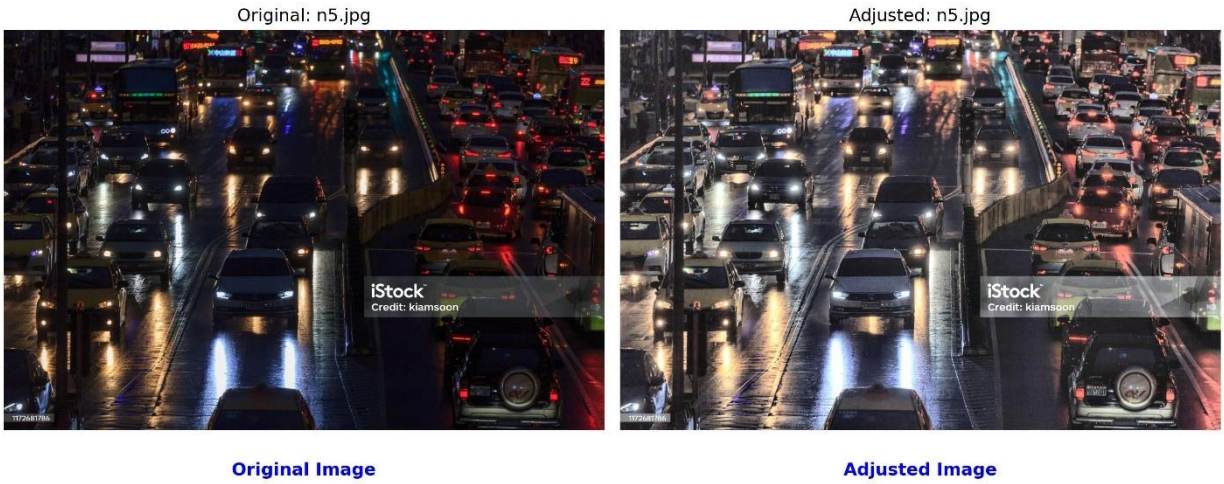
จากภาพจะเห็นว่าภาพที่ถูกตัดมีสีที่ชัดเจน และพื้นที่ส่วนใหญ่ในภาพเป็นสีที่แท้จริงของรถ ซึ่งเหมาะสมแก่การนำไปใช้ในการวิเคราะห์พื้นที่ที่สนใจเพื่อตรวจสอบชื่อสี

4.4 ผลการทดสอบการปรับแสงภาพ

ในการทดสอบนี้ ได้ทำการปรับลดแสงของภาพที่มีความสว่างสูง และเพิ่มแสงของภาพที่มีความมืด เพื่อปรับปรุงความชัดเจนของรถและสีของรถ ตัวอย่างผลลัพธ์แสดงให้เห็นถึงความแตกต่างก่อนและหลังการปรับแสง ดังดังรูปที่ 4.5 และ รูปที่ 4.6



รูปที่ 4. 5 ผลการปรับลดแสงในภาพสว่าง

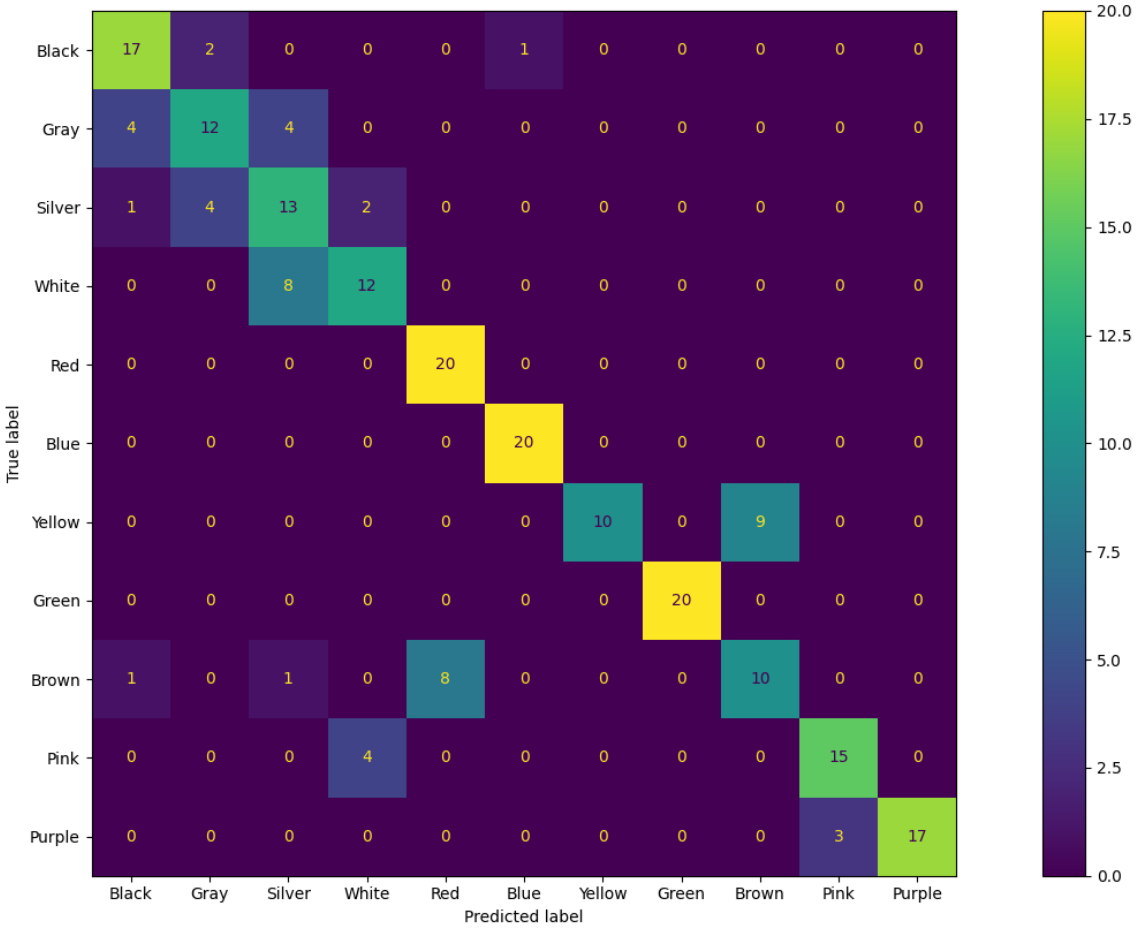


รูปที่ 4. 6 ผลการปรับเพิ่มแสงในภาพมืด

จากตัวอย่างการทดลองจะเห็นว่า ในกรณีที่เป็นภาพสว่าง สีของรถจะเด่นชัดขึ้นและสามารถมองเห็นรายละเอียดได้ดีขึ้น ส่วนในกรณีที่เป็นภาพมืด จะเห็นได้ว่าสามารถมองเห็นรูปร่างของรถได้ชัดเจนขึ้นเมื่อเทียบกับภาพเดิม

4.5 ผลการทดสอบการจำแนกสีจากภาพ

จากการทดสอบระบบจำแนกสีของรถโดยใช้การแยกสีผ่านค่าสีในระบบ HSV และทำการแสดงลัพธ์ผ่าน Confusion Matrix ดังดังรูปที่ 4.7



รูปที่ 4. 7 Confusion Matrix ของระบบจำแนกสีของรถโดยใช้การแยกสีผ่านค่าสีในระบบ HSV

จากผลการจำแนกสีของระบบโดยใช้ค่าในระบบสี HSV ร่วมกับวิธีการจัดกลุ่มแบบ K-Means พบว่าการจำแนกสีส่วนใหญ่เป็นไปอย่างแม่นยำ โดยเฉพาะในกลุ่มสีที่มีความโดดเด่น เช่น สีแดง สีน้ำเงิน และสีเขียว อย่างไรก็ตามยังพบข้อผิดพลาดบางประการในกลุ่มสีที่มีลักษณะคล้ายคลึงกันหรือมีความแตกต่างทางค่าสีเพียงเล็กน้อย ซึ่งสามารถจำแนกและวิเคราะห์ข้อผิดพลาดในแต่ละกลุ่มสีได้ดังนี้

ก. สี Gray (เทา)ระบบจำแนกสี Gray ผิดเป็นสี Black จำนวน 3 ครั้ง, สี Silver จำนวน 4 ครั้ง และสี White อีก 1 ครั้ง ความผิดพลาดนี้เกิดจากลักษณะของสีเทาที่มีค่า Hue ต่ำหรือแทบไม่มี ซึ่งคล้ายคลึงกับสีดำและสีเงินในระบบ HSV นอกจากนี้ สี Gray มักมีค่า Saturation

และ Value ต่ำ ทำให้ดูคล้ายกับสีดำในสภาพแสงน้อย หรือดูคล้ายสีขาวหรือเงินในสภาพแสงจ้า โดยความแตกต่างเล็กน้อยด้านความสว่างไม่เพียงพอให้ K-Means จำแนกกลุ่มได้อย่างแม่นยำ

ข. สี Silver (เงิน) มีการจำแนกสี Silver ผิดเป็นสี Gray จำนวน 4 ครั้ง, สี White จำนวน 2 ครั้ง และสี Black อีก 1 ครั้ง ปัญหานี้เกิดจากสีเงินในภาพที่มีการสะท้อนแสงสูง ส่งผลให้มีค่า Value สูงคล้ายสีขาวในระบบ HSV ประกอบกับค่า Hue และ Saturation ของสีเงินอยู่ในช่วงต่ำ จึงใกล้เคียงกับสี Gray และ White มาก ส่งผลให้ระบบจำแนกผิดกลุ่ม โดยเฉพาะในภาพที่มีแสงจ้า

ค. สี White (ขาว) ระบบจำแนกสี White ผิดเป็นสี Silver จำนวน 8 ครั้ง ซึ่งเป็นผลจากลักษณะของสีขาวและสีเงินที่คล้ายคลึงกันอย่างมากในเชิงข้อมูล HSV ทั้งในด้านค่า Hue ที่มักไม่แสดงผล และค่า Value ที่สูงมากทั้งคู่ เมื่อสีขาวมีแสงสะท้อนหรือมุมกล้องที่ทำให้เกิดเฉดสีเทาเงิน จึงส่งผลให้ระบบเข้าใจผิดและจัดให้อยู่ในกลุ่มของสีเงินแทน

ง. สี Black (ดำ) สี Black ถูกจำแนกผิดเป็นสี Blue จำนวน 2 ครั้ง, สี Brown จำนวน 1 ครั้ง และสี Gray อีก 1 ครั้ง ข้อผิดพลาดเหล่านี้อาจเกิดจากการที่บางภาพมีแสงตกกระทบบริเวณพื้นผิวของสีดำ ทำให้ค่า Value เพิ่มขึ้นจนเบลอไปทางสีน้ำเงินเข้มหรือสีน้ำตาลเข้ม อีกทั้งสีดำมักไม่มีค่า Hue ชัดเจนในระบบ HSV จึงง่ายต่อการถูกจัดเข้ากลุ่มของสีมืดอื่น ๆ ที่มีค่าใกล้เคียงกันในระบบ K-Means

จ. สี Brown (น้ำตาล) พบการจำแนกสี Brown ผิดเป็นสี White จำนวน 8 ครั้ง, สี Black จำนวน 1 ครั้ง และสี Silver อีก 1 ครั้ง ซึ่งอาจเกิดจากกรณีที่ภาพของรถสีน้ำตาลมีความสว่างหรือค่าความอิ่มตัวต่ำ ทำให้ดูคล้ายสีขาวหรือสีอ่อนอื่น ๆ โดยเฉพาะในภาพถ่ายกลางแจ้งที่มีแสงมาก นอกจากนี้ Hue ของสีน้ำตาลซึ่งอยู่ในช่วงประมาณ 10–30 องศา อาจทับซ้อนกับโทนสีครีมหรือสีขาวอุ่น ส่งผลให้การจัดกลุ่มของ K-Means เกิดความคลาดเคลื่อนได้

ฉ. สี Purple (ม่วง) ระบบจำแนกสี Purple ผิดเป็นสี Pink จำนวน 3 ครั้ง โดยสาเหตุหลักมาจาก Hue ของสองสีนี้อยู่ในช่วงที่ใกล้กันในระบบ HSV คือระหว่าง 300–330 องศา ในกรณีที่ค่า Saturation ต่ำ หรือมีแสงสว่างมาก สีม่วงอ่อนอาจถูกกล้องตีความเป็นสีชมพู ส่งผลให้การจัดกลุ่มผิดพลาดได้ง่าย

ช. สี Pink (ชมพู) สี Pink มีการจำแนกผิดเป็นสี White จำนวน 4 ครั้ง ซึ่งเกิดจากลักษณะของสีชมพูอ่อนที่มีความอิ่มตัวต่ำในภาพถ่าย โดยเฉพาะเมื่ออยู่ในบริเวณที่มีแสงมาก สีชมพูอาจสูญเสียความเข้มของสีไปจนกลายเป็นลักษณะใกล้เคียงกับสีขาว K-Means ซึ่งใช้การวัดระยะห่างของค่าสีจึงอาจจัดกลุ่มผิดได้หากสีชมพูไม่แสดงคุณลักษณะเฉพาะที่ชัดเจน

ซ. สี Yellow (เหลือง) แม้จะจำแนกถูก 10 ครั้ง แต่สี Yellow ถูกจำแนกผิดเป็นสีน้ำตาลถึง 9 ครั้ง เนื่องจากทั้งสองสีมีค่า Hue ใกล้เคียงกันในระบบ HSV โดยเฉพาะเมื่อสีเหลืองมีค่าความสว่าง (Value) ต่ำลง จะทำให้ดูคล้ายสีน้ำตาล ส่งผลให้ K-Means แยกแยะไม่ชัดเจนในบางกรณี

จากผลการทดสอบสามารถสรุปได้ว่า ระบบจำแนกสีโดยใช้ค่าสีในระบบ HSV ร่วมกับการจัดกลุ่มแบบ K-Means มีประสิทธิภาพในระดับหนึ่งสำหรับการจำแนกสีที่มีความแตกต่างชัดเจน อย่างไรก็ตาม ยังคงพบข้อผิดพลาดในการจำแนกสีที่มีลักษณะใกล้เคียงกัน เช่น สีเทา เงิน ขาว ดำ และน้ำตาล ซึ่งมักมีค่า Hue ต่ำหรือใกล้กัน รวมถึงค่าความอิ่มตัวและความสว่างที่อาจซ้อนทับกันในหลายบริบทของภาพ การใช้ HSV อย่างเดียวอาจไม่เพียงพอในบริบทที่มีแสง เงา หรือการสะท้อนแสงที่หลากหลาย จึงแนะนำว่าการปรับปรุงในอนาคตอาจพิจารณาร่วมใช้ข้อมูลจากบริบทของภาพ หรือพัฒนาเทคนิคการจำแนกที่สามารถเรียนรู้ลักษณะของสีในสภาพแสงจริงได้ดียิ่งขึ้น

4.6 ผลการทดสอบการทำงานของโปรแกรม

ทดสอบการทำงานของโปรแกรมโดยการใช้วิดีโอที่มีความยาว 1 นาที ในสองช่วงเวลา คือ ช่วงเวลากลางวันและ ผลลัพธ์ที่ได้จากการทดสอบจะแสดงให้เห็นถึงความแม่นยำของโปรแกรมในแต่ละช่วงเวลา ดังตารางที่ 4.2

ตารางที่ 4. 2 ผลการทดสอบการทำงานของโปรแกรมในเวลากลางวัน

เวลา	ประเภท			สี		
	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง
0	Pick-Up	Sedan	ไม่ถูกต้อง	Gray	Gray	ถูกต้อง
0.33	Pick-Up	Sedan	ไม่ถูกต้อง	Gray	Gray	ถูกต้อง
0.33	Pick-Up	Truck	ไม่ถูกต้อง	White	Silver	ไม่ถูกต้อง
0.33	Motorcycle	Sedan	ไม่ถูกต้อง	Blue	Black	ไม่ถูกต้อง
0.67	Pick-Up	Sedan	ไม่ถูกต้อง	White	Gray	ไม่ถูกต้อง
0.67	Pick-Up	Sedan	ไม่ถูกต้อง	Gray	Silver	ไม่ถูกต้อง
1	Pick-Up	Sedan	ไม่ถูกต้อง	White	Gray	ไม่ถูกต้อง
1.33	Pick-Up	Sedan	ไม่ถูกต้อง	White	Gray	ไม่ถูกต้อง
1.67	Pick-Up	Sedan	ไม่ถูกต้อง	Gray	Silver	ไม่ถูกต้อง
2	Motorcycle	VAN	ไม่ถูกต้อง	Blue	Silver	ไม่ถูกต้อง
2.33	Pick-Up	VAN	ไม่ถูกต้อง	Silver	Silver	ถูกต้อง
2.33	Pick-Up	Sedan	ไม่ถูกต้อง	White	Silver	ไม่ถูกต้อง
2.67	Pick-Up	VAN	ไม่ถูกต้อง	White	Silver	ไม่ถูกต้อง
3	Sedan	Truck	ไม่ถูกต้อง	Gray	Silver	ไม่ถูกต้อง
3.33	Sedan	Truck	ไม่ถูกต้อง	Gray	Black	ไม่ถูกต้อง
4.33	Sedan	SUV	ไม่ถูกต้อง	Red	Black	ไม่ถูกต้อง
4.67	SUV	Sedan	ไม่ถูกต้อง	Red	Red	ถูกต้อง
5	SUV	Sedan	ไม่ถูกต้อง	Red	Red	ถูกต้อง
7.67	Pick-Up	Sedan	ไม่ถูกต้อง	Gray	Gray	ถูกต้อง

เวลา	ประเภท			สี		
	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง
9.33	Pick-Up	Pick-Up	ถูกต้อง	Silver	Black	ไม่ถูกต้อง
9.67	Pick-Up	Sedan	ไม่ถูกต้อง	Silver	Black	ไม่ถูกต้อง
10	Pick-Up	Sedan	ไม่ถูกต้อง	Silver	Black	ไม่ถูกต้อง
10.67	Pick-Up	Pick-Up	ถูกต้อง	Silver	Gray	ไม่ถูกต้อง
11	Sedan	Pick-Up	ไม่ถูกต้อง	Silver	Gray	ไม่ถูกต้อง
11.33	Sedan	Sedan	ถูกต้อง	Silver	Gray	ไม่ถูกต้อง
12.33	Pick-Up	Sedan	ไม่ถูกต้อง	White	Gray	ไม่ถูกต้อง
12.67	Pick-Up	Pick-Up	ถูกต้อง	White	Silver	ไม่ถูกต้อง
13	Pick-Up	SUV	ไม่ถูกต้อง	White	Silver	ไม่ถูกต้อง
14	Sedan	Sedan	ถูกต้อง	Silver	Gray	ไม่ถูกต้อง
14.33	SUV	SUV	ถูกต้อง	Silver	Gray	ไม่ถูกต้อง
14.67	SUV	SUV	ถูกต้อง	Silver	Gray	ไม่ถูกต้อง
15	Truck	VAN	ไม่ถูกต้อง	Gray	Silver	ไม่ถูกต้อง
16	Pick-Up	SUV	ไม่ถูกต้อง	Blue	Gray	ไม่ถูกต้อง
16	Truck	Truck	ถูกต้อง	Silver	Silver	ถูกต้อง
16.33	Pick-Up	Sedan	ไม่ถูกต้อง	Blue	Blue	ถูกต้อง
16.33	Pick-Up	Sedan	ไม่ถูกต้อง	White	Blue	ไม่ถูกต้อง
16.67	Pick-Up	Sedan	ไม่ถูกต้อง	Blue	Black	ไม่ถูกต้อง
17	Pick-Up	SUV	ไม่ถูกต้อง	White	Silver	ไม่ถูกต้อง
17.67	Pick-Up	SUV	ไม่ถูกต้อง	Gray	Silver	ไม่ถูกต้อง
19.33	Pick-Up	Truck	ไม่ถูกต้อง	Silver	Silver	ถูกต้อง
19.33	Sedan	Pick-Up	ไม่ถูกต้อง	Silver	Black	ไม่ถูกต้อง
19.67	Pick-Up	Truck	ไม่ถูกต้อง	Silver	Silver	ถูกต้อง
19.67	Pick-Up	Sedan	ไม่ถูกต้อง	Silver	Gray	ไม่ถูกต้อง

เวลา	ประเภท			สี		
	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง
20	Pick-Up	Sedan	ไม่ถูกต้อง	Silver	Silver	ถูกต้อง
20	Pick-Up	Sedan	ไม่ถูกต้อง	Silver	Black	ไม่ถูกต้อง
20.33	Pick-Up	Bus	ไม่ถูกต้อง	Silver	Black	ไม่ถูกต้อง
21	Pick-Up	Pick-Up	ถูกต้อง	Silver	Gray	ไม่ถูกต้อง
21.33	Pick-Up	Truck	ไม่ถูกต้อง	Black	Black	ถูกต้อง
21.67	Pick-Up	Sedan	ไม่ถูกต้อง	Black	Black	ถูกต้อง
21.67	Pick-Up	Truck	ไม่ถูกต้อง	Black	Gray	ไม่ถูกต้อง
22	Pick-Up	Sedan	ไม่ถูกต้อง	Black	Black	ถูกต้อง
22.33	Pick-Up	Sedan	ไม่ถูกต้อง	Black	Black	ถูกต้อง
22.67	Pick-Up	Sedan	ไม่ถูกต้อง	White	Silver	ไม่ถูกต้อง
22.67	Pick-Up	VAN	ไม่ถูกต้อง	Black	Silver	ไม่ถูกต้อง
23	Pick-Up	VAN	ไม่ถูกต้อง	White	Silver	ไม่ถูกต้อง
23.33	Pick-Up	VAN	ไม่ถูกต้อง	White	Silver	ไม่ถูกต้อง
24.33	SUV	Sedan	ไม่ถูกต้อง	Black	Black	ถูกต้อง
24.67	SUV	VAN	ไม่ถูกต้อง	Black	Black	ถูกต้อง
24.67	SUV	Sedan	ไม่ถูกต้อง	Gray	Gray	ถูกต้อง
25	SUV	SUV	ถูกต้อง	Gray	Black	ไม่ถูกต้อง
25	SUV	SUV	ถูกต้อง	Black	Silver	ไม่ถูกต้อง
25.67	SUV	SUV	ถูกต้อง	Black	Black	ถูกต้อง
26	SUV	SUV	ถูกต้อง	Black	Black	ถูกต้อง
26.33	Truck	SUV	ไม่ถูกต้อง	Gray	Black	ไม่ถูกต้อง
26.67	Truck	VAN	ไม่ถูกต้อง	Gray	Black	ไม่ถูกต้อง
27.67	SUV	Sedan	ไม่ถูกต้อง	Red	Red	ถูกต้อง
28	SUV	Sedan	ไม่ถูกต้อง	Red	Red	ถูกต้อง

เวลา	ประเภท			สี		
	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง
29	SUV	SUV	ถูกต้อง	Red	Silver	ไม่ถูกต้อง
29.33	SUV	SUV	ถูกต้อง	Red	Silver	ไม่ถูกต้อง
30	SUV	Sedan	ไม่ถูกต้อง	White	Gray	ไม่ถูกต้อง
30.33	Sedan	VAN	ไม่ถูกต้อง	Silver	Gray	ไม่ถูกต้อง
30.67	Sedan	Sedan	ถูกต้อง	Gray	Silver	ไม่ถูกต้อง
31	Sedan	Sedan	ถูกต้อง	Silver	Silver	ถูกต้อง
31.33	SUV	Sedan	ไม่ถูกต้อง	Black	Black	ถูกต้อง
32.33	Truck	VAN	ไม่ถูกต้อง	White	Black	ไม่ถูกต้อง
32.33	SUV	Sedan	ไม่ถูกต้อง	Black	Silver	ไม่ถูกต้อง
32.67	SUV	SUV	ถูกต้อง	Black	Black	ถูกต้อง
32.67	Truck	VAN	ไม่ถูกต้อง	White	Black	ไม่ถูกต้อง
33	SUV	VAN	ไม่ถูกต้อง	Black	Black	ถูกต้อง
33.33	SUV	VAN	ไม่ถูกต้อง	Black	Black	ถูกต้อง
33.33	Pick-Up	SUV	ไม่ถูกต้อง	Silver	Silver	ถูกต้อง
33.67	Pick-Up	SUV	ไม่ถูกต้อง	Silver	Silver	ถูกต้อง
33.67	SUV	VAN	ไม่ถูกต้อง	Black	Black	ถูกต้อง
34	Pick-Up	Truck	ไม่ถูกต้อง	Silver	Silver	ถูกต้อง
34	SUV	SUV	ถูกต้อง	Black	Black	ถูกต้อง
34.33	SUV	SUV	ถูกต้อง	Black	Black	ถูกต้อง
34.33	Pick-Up	Truck	ไม่ถูกต้อง	Silver	Silver	ถูกต้อง
34.67	Pick-Up	SUV	ไม่ถูกต้อง	Silver	Black	ไม่ถูกต้อง
35	SUV	SUV	ถูกต้อง	Black	Black	ถูกต้อง
35.33	SUV	SUV	ถูกต้อง	Black	Black	ถูกต้อง
35.67	SUV	VAN	ไม่ถูกต้อง	Black	Blue	ไม่ถูกต้อง

เวลา	ประเภท			สี		
	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง
36.33	Pick-Up	VAN	ไม่ถูกต้อง	Gray	Black	ไม่ถูกต้อง
36.67	SUV	SUV	ถูกต้อง	Black	Gray	ไม่ถูกต้อง
37	Pick-Up	Sedan	ไม่ถูกต้อง	Gray	Black	ไม่ถูกต้อง
37	SUV	SUV	ถูกต้อง	Gray	Black	ไม่ถูกต้อง
37.33	Pick-Up	Sedan	ไม่ถูกต้อง	Silver	Black	ไม่ถูกต้อง
37.67	Pick-Up	Pick-Up	ถูกต้อง	Silver	Gray	ไม่ถูกต้อง
38	SUV	Sedan	ไม่ถูกต้อง	Silver	Black	ไม่ถูกต้อง
38	Pick-Up	Pick-Up	ถูกต้อง	Silver	Gray	ไม่ถูกต้อง
38.33	SUV	Pick-Up	ไม่ถูกต้อง	Gray	Gray	ถูกต้อง
38.33	Pick-Up	Sedan	ไม่ถูกต้อง	Silver	Silver	ถูกต้อง
38.33	Pick-Up	Sedan	ไม่ถูกต้อง	Gray	Black	ไม่ถูกต้อง
38.67	SUV	Truck	ไม่ถูกต้อง	Gray	Gray	ถูกต้อง
38.67	SUV	VAN	ไม่ถูกต้อง	Gray	Black	ไม่ถูกต้อง
39	SUV	SUV	ถูกต้อง	Gray	Silver	ไม่ถูกต้อง
39.33	SUV	SUV	ถูกต้อง	Gray	Silver	ไม่ถูกต้อง
39.33	SUV	Sedan	ไม่ถูกต้อง	White	Black	ไม่ถูกต้อง
39.33	Sedan	Sedan	ถูกต้อง	Silver	Silver	ถูกต้อง
39.67	SUV	SUV	ถูกต้อง	Gray	Silver	ไม่ถูกต้อง
39.67	SUV	SUV	ถูกต้อง	White	Black	ไม่ถูกต้อง
40	SUV	SUV	ถูกต้อง	Gray	Silver	ไม่ถูกต้อง
40	SUV	Sedan	ไม่ถูกต้อง	White	Silver	ไม่ถูกต้อง
40.33	SUV	SUV	ถูกต้อง	Gray	Silver	ไม่ถูกต้อง
40.33	SUV	Motorcycle	ไม่ถูกต้อง	White	Silver	ไม่ถูกต้อง
40.67	SUV	SUV	ถูกต้อง	Gray	Silver	ไม่ถูกต้อง

เวลา	ประเภท			สี		
	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง
41	SUV	SUV	ถูกต้อง	Gray	Silver	ไม่ถูกต้อง
41.33	SUV	SUV	ถูกต้อง	White	Silver	ไม่ถูกต้อง
42	SUV	SUV	ถูกต้อง	White	Gray	ไม่ถูกต้อง
42.33	SUV	Sedan	ไม่ถูกต้อง	White	Gray	ไม่ถูกต้อง
42.67	Motorcycle	Sedan	ไม่ถูกต้อง	White	Black	ไม่ถูกต้อง
42.67	Sedan	Truck	ไม่ถูกต้อง	Silver	Silver	ถูกต้อง
43	Truck	Truck	ถูกต้อง	White	Silver	ไม่ถูกต้อง
43.33	Sedan	Truck	ไม่ถูกต้อง	Silver	Silver	ถูกต้อง
43.33	Truck	Sedan	ไม่ถูกต้อง	White	Gray	ไม่ถูกต้อง
43.67	Sedan	Sedan	ถูกต้อง	Silver	Black	ไม่ถูกต้อง
44	Sedan	Sedan	ถูกต้อง	Silver	Gray	ไม่ถูกต้อง
44.33	Sedan	Sedan	ถูกต้อง	Silver	Gray	ไม่ถูกต้อง
44.67	Sedan	Truck	ไม่ถูกต้อง	Silver	Silver	ถูกต้อง
44.67	Truck	SUV	ไม่ถูกต้อง	Gray	Gray	ถูกต้อง
45	Truck	Truck	ถูกต้อง	Gray	Black	ไม่ถูกต้อง
45.33	Truck	Truck	ถูกต้อง	Gray	Black	ไม่ถูกต้อง
46	Sedan	Sedan	ถูกต้อง	Gray	Gray	ถูกต้อง
46.33	Sedan	Sedan	ถูกต้อง	Gray	Gray	ถูกต้อง
46.67	Sedan	Sedan	ถูกต้อง	Gray	Gray	ถูกต้อง
47	Sedan	Sedan	ถูกต้อง	Gray	Black	ไม่ถูกต้อง
47.33	Sedan	Sedan	ถูกต้อง	Gray	Gray	ถูกต้อง
48.67	SUV	Sedan	ไม่ถูกต้อง	Gray	Silver	ไม่ถูกต้อง
49	Sedan	Sedan	ถูกต้อง	White	Silver	ไม่ถูกต้อง
49	SUV	Sedan	ไม่ถูกต้อง	White	Silver	ไม่ถูกต้อง

เวลา	ประเภท			สี		
	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง
49.33	Sedan	Sedan	ถูกต้อง	White	Silver	ไม่ถูกต้อง
49.33	SUV	Sedan	ไม่ถูกต้อง	White	Silver	ไม่ถูกต้อง
49.67	SUV	Sedan	ไม่ถูกต้อง	White	Silver	ไม่ถูกต้อง
50.67	SUV	Sedan	ไม่ถูกต้อง	Black	Black	ถูกต้อง
51	Sedan	SUV	ไม่ถูกต้อง	Black	Black	ถูกต้อง
51.33	SUV	SUV	ถูกต้อง	Black	Black	ถูกต้อง
51.67	SUV	SUV	ถูกต้อง	Gray	Black	ไม่ถูกต้อง
52.33	Sedan	SUV	ไม่ถูกต้อง	White	Black	ไม่ถูกต้อง
52.67	SUV	Sedan	ไม่ถูกต้อง	Black	Black	ถูกต้อง
52.67	Sedan	Motorcycle	ไม่ถูกต้อง	White	Black	ไม่ถูกต้อง
55.33	Pick-Up	Sedan	ไม่ถูกต้อง	Silver	Silver	ถูกต้อง
56.33	Truck	Truck	ถูกต้อง	Gray	Black	ไม่ถูกต้อง
56.67	Pick-Up	Truck	ไม่ถูกต้อง	Gray	Black	ไม่ถูกต้อง
57	Pick-Up	Truck	ไม่ถูกต้อง	Silver	Black	ไม่ถูกต้อง
57.33	Truck	Sedan	ไม่ถูกต้อง	Gray	Silver	ไม่ถูกต้อง

ตารางที่ 4. 3 ผลการทดสอบการทำงานของโปรแกรมในเวลากลางคืน

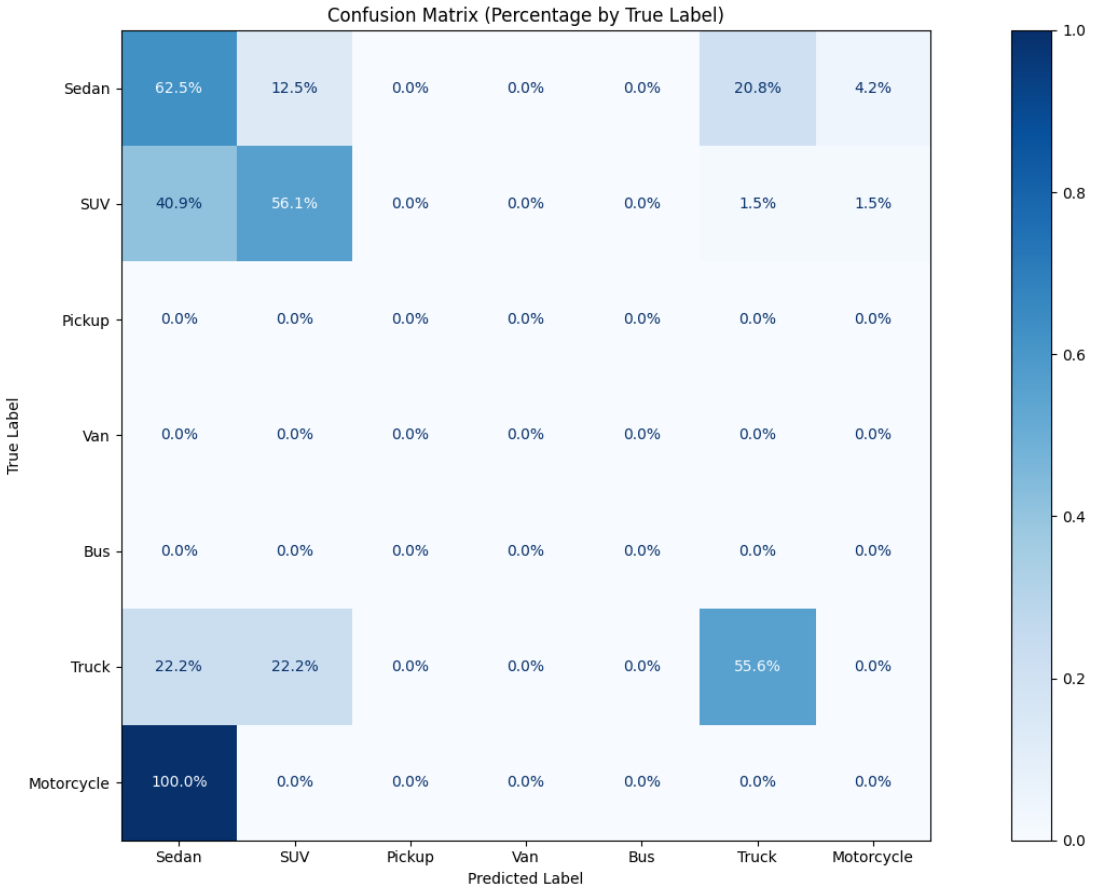
เวลา	ประเภท			สี		
	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง	ข้อมูลจริง	ผลลัพธ์จากโปรแกรม	ความถูกต้อง
4.33	SUV	SUV	ถูกต้อง	White	Silver	ไม่ถูกต้อง
4.67	SUV	SUV	ถูกต้อง	White	Silver	ไม่ถูกต้อง
5.33	SUV	SUV	ถูกต้อง	White	Silver	ไม่ถูกต้อง
5.67	SUV	SUV	ถูกต้อง	White	Blue	ไม่ถูกต้อง
6	SUV	SUV	ถูกต้อง	White	Blue	ไม่ถูกต้อง
6.33	SUV	SUV	ถูกต้อง	White	Blue	ไม่ถูกต้อง
6.67	SUV	SUV	ถูกต้อง	White	Blue	ไม่ถูกต้อง
7	SUV	SUV	ถูกต้อง	White	Blue	ไม่ถูกต้อง
7.33	SUV	SUV	ถูกต้อง	White	Blue	ไม่ถูกต้อง
8	SUV	SUV	ถูกต้อง	White	Blue	ไม่ถูกต้อง
20.67	SUV	Sedan	ไม่ถูกต้อง	Black	Black	ถูกต้อง
25.67	SUV	Sedan	ไม่ถูกต้อง	Black	Blue	ไม่ถูกต้อง
26	SUV	VAN	ไม่ถูกต้อง	Black	Black	ถูกต้อง
31	Pick-Up	Sedan	ไม่ถูกต้อง	White	Blue	ไม่ถูกต้อง
50.33	SUV	Sedan	ไม่ถูกต้อง	Black	Black	ถูกต้อง
51.33	SUV	Sedan	ไม่ถูกต้อง	Black	Black	ถูกต้อง
51.67	SUV	Sedan	ไม่ถูกต้อง	Black	Black	ถูกต้อง
52	SUV	Sedan	ไม่ถูกต้อง	Black	Black	ถูกต้อง
52.67	SUV	Sedan	ไม่ถูกต้อง	Black	Black	ถูกต้อง
53	SUV	Sedan	ไม่ถูกต้อง	Black	Black	ถูกต้อง

ตารางที่ 4. 4 ผลการทดสอบการทำงานของโปรแกรม

ช่วงเวลา	ความถูกต้องของการระบุสีรถ		ความถูกต้องของการระบุประเภทรถ		ความถูกต้องรวม	
	จำนวนที่ทายถูกต้อง	เปอร์เซ็นต์ (%)	จำนวนที่ทายถูกต้อง	เปอร์เซ็นต์ (%)	จำนวนที่ทายถูกต้อง	เปอร์เซ็นต์ (%)
กลางวัน	53/154	34.42%	53/154	34.42%	106/308	34.42%
กลางคืน	8/20	40.00%	10/20	50.00%	18/40	45.00%
สรุป	61/174	35.06%	63/174	36.21%	124/348	35.63%

จากผลการทดลองโปรแกรมวิเคราะห์สีและประเภทรถยนต์จากวิดีโอ โดยใช้วิดีโอช่วงกลางวันและกลางคืนที่มีความยาว 1 นาที พบว่าความแม่นยำโดยรวมของระบบอยู่ที่ประมาณ 35.63% ซึ่งถือว่ายังอยู่ในระดับต่ำ แสดงให้เห็นว่ายังมีข้อจำกัดในการวิเคราะห์ข้อมูลจากภาพเคลื่อนไหว โดยในช่วงเวลากลางวันซึ่งมีจำนวนข้อมูลมากที่สุด ระบบสามารถทำนายได้ถูกต้องทั้งในด้านสีและประเภทของรถในอัตราเท่ากันคือ 34.42% ขณะที่ในช่วงกลางคืน แม้จะมีจำนวนตัวอย่างน้อยกว่าอย่างมาก แต่กลับได้ความแม่นยำที่สูงกว่า โดยการทำนายประเภทของรถถูกต้องถึง 50.00% และการทำนายสีอยู่ที่ 40.00% ซึ่งอาจเกิดจากลักษณะแสงจากไฟหน้ารถที่ช่วยเน้นรูปทรงและรายละเอียดของรถให้ชัดเจนขึ้น อย่างไรก็ตามเนื่องจากจำนวนข้อมูลในช่วงกลางคืนมีเพียง 20 คัน จึงยังไม่สามารถสรุปได้อย่างชัดเจนถึงประสิทธิภาพของระบบในสภาพแสงนั้น จึงควรเก็บข้อมูลเพิ่มเติมเพื่อเพิ่มความน่าเชื่อถือของผลการทดสอบ นอกจากนี้ยังควรปรับปรุงกระบวนการวิเคราะห์ภาพทั้งในด้านการตรวจจับและจำแนก โดยอาจพิจารณาใช้เทคนิคเพิ่มคุณภาพภาพ หรือเปลี่ยนไปใช้โมเดลปัญญาประดิษฐ์เพื่อเพิ่มความแม่นยำในการทำนายให้สูงขึ้นและสามารถรับมือกับความหลากหลายของภาพจากวิดีโอในสภาพแวดล้อมจริงได้ดียิ่งขึ้น

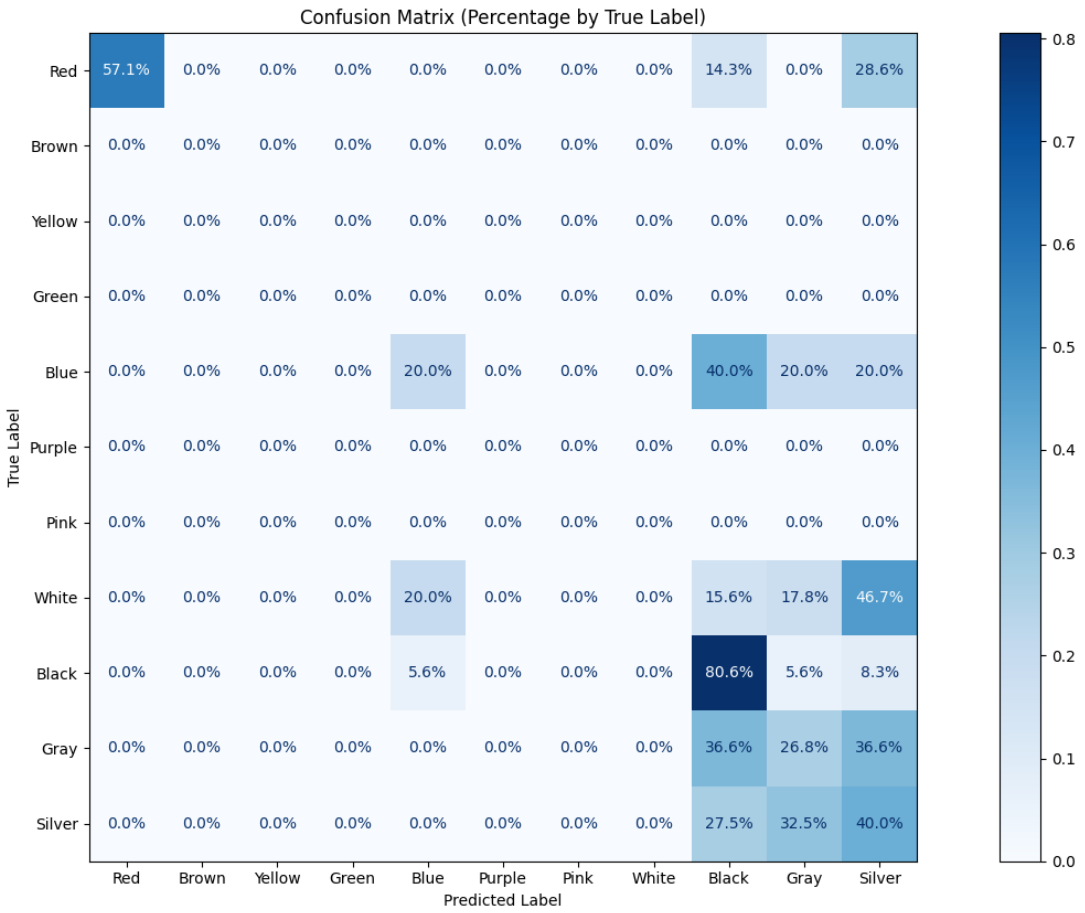
ตารางที่ 4. 5 ความถูกต้องในการระบุประเภทรถในสถานที่จริงจากผลการทดสอบการทำงานของโปรแกรม



จากผลทดสอบในสถานที่จริงผ่าน Confusion Matrix พบว่าระบบสามารถระบุประเภทรถ Sedan ได้แม่นยำที่สุดที่ร้อยละ 62.5 รองลงมาคือ SUV (ร้อยละ 56.1) และ Truck (ร้อยละ 55.6) ตามลำดับ โดยพบข้อผิดพลาดหลักจากการจำแนก SUV ผิดเป็น Sedan ถึงร้อยละ 40.9 เนื่องจากลักษณะทางกายภาพที่คล้ายคลึงกันเมื่อมองผ่านมุมกล้องในสภาพแวดล้อมจริง

ในส่วนของรถประเภท Motorcycle, Pickup, Van และ Bus ยังมีค่าความถูกต้องเป็นร้อยละ 0 โดยเฉพาะรถจักรยานยนต์ที่ระบบจำแนกผิดเป็นรถ Sedan ทั้งหมด (ร้อยละ 100) ผลลัพธ์นี้แสดงให้เห็นว่าโมเดลยังมีข้อจำกัดในการตรวจจับยานพาหนะที่มีขนาดเล็ก หรือประเภทรถที่มีข้อมูลในการฝึกสอนไม่เพียงพอต่อการใช้งานในสภาพแวดล้อมที่มีปัจจัยรบกวนในสถานที่จริง

ตารางที่ 4. 6 ความถูกต้องในการระบุสีรถในสถานที่จริงจากผลการทดสอบการทำงานของโปรแกรม



จากผลการทดสอบในสถานที่จริงผ่าน Confusion Matrix พบว่าระบบจำแนก สีดำ (Black) ได้แม่นยำที่สุดที่ร้อยละ 80.6 และสีแดง (Red) ร้อยละ 57.1 แต่ประสบปัญหาอย่างมากในกลุ่มสีโทนสว่าง โดยเฉพาะ สีขาว (White) ที่มีความถูกต้องร้อยละ 0 เนื่องจากระบบมักจำแนกผิดเป็นสีเงิน (Silver) ถึงร้อยละ 46.7 เช่นเดียวกับสีเทาและสีเงินที่มีความถูกต้องเพียงร้อยละ 26.8 และ 40.0 ตามลำดับ ซึ่งสะท้อนถึงความสับสนระหว่างกลุ่มสีที่มีค่าความสว่างใกล้เคียงกัน

ข้อคลาดเคลื่อนหลักเกิดจากปัจจัยด้านสภาพแสงและการสะท้อนบนตัวถังรถในสภาพแวดล้อมจริงที่ส่งผลต่อการระบุค่าสี ส่วนกลุ่มสีที่ไม่สามารถระบุได้เลย (ร้อยละ 0) เช่น สีน้ำตาลหรือสีเขียว อาจมีสาเหตุจากจำนวนตัวอย่างในชุดฝึกสอนที่ไม่เพียงพอ หรือไม่มีกลุ่มตัวอย่างดังกล่าววิ่งผ่านขณะทดสอบจริงทำให้โมเดลมีความลำเอียงไปยังกลุ่มสีพื้นฐานที่มีปริมาณข้อมูลมากกว่า

บทที่ 5
บทสรุปและข้อเสนอแนะ

5.1 สรุปผล

5.1.1 สรุปผลลการระบุประเภทของรถ

จากผลลัพธ์ในข้อ 4.2 สามารถสรุปได้ว่า โมเดล YOLO-cls ที่ได้ทำการเทรนโดยมีสมาชิกของคลาสในโมเดล ได้แก่ Convertible, Coupe, Hatchback, Pick-Up, SUV, Sedan, Truck, และ Van สามารถทำงานได้ในระดับที่ดี โดยมีการทำนายที่ถูกต้องเป็นส่วนใหญ่ แต่ยังคงมีความสับสนในบางกรณี ซึ่งอาจเกิดจากรูปลักษณ์ของรถทั้งสองประเภทที่มีความใกล้เคียงกันในบางมุมมอง

โดยรวมแล้ว โมเดลสามารถจำแนกประเภทของรถได้ในระดับที่น่าพอใจ แต่ยังสามารถปรับปรุงเพิ่มเติมเพื่อเพิ่มความแม่นยำในการแยกแยะรถประเภทที่มีความคล้ายคลึงกันได้ดียิ่งขึ้น

5.1.2 สรุปผลการระบุประสีของรถโดยใช้ค่า HSV

จากผลลัพธ์ในข้อ 4.5 สามารถสรุปได้ว่าการจำแนกสีดดยใช้วิธีการจำแนกสีด้วย HSV มีความแม่นยำในระดับที่ดี สำหรับสีที่มีความแตกต่างชัดเจน ไม่มีการจำแนกผิดพลาดเลย อย่างไรก็ตามก็ยังคงมีบางสีที่เกิดการสับสนระหว่างกันเนื่องจากสีมีความใกล้เคียงกัน และมีมีบางกรณีที่จำแนกผิดอาจเนื่องจากขอบเขตของสีที่กำหนดใน HSV ยังไม่ครอบคลุมความหลากหลายของเฉดสีที่ปรากฏในสภาพแวดล้อมจริง

5.1.3 สรุปผลการทำงานของโปรแกรมโดยรวม

จากผลลัพธ์ในข้อ 4.6 พบว่าโปรแกรมสามารถทำนายสีและประเภทของรถได้ในระดับที่ค่อนข้างต่ำ โดยมีความแม่นยำในการทำนายสีอยู่ที่ 35.06% และความแม่นยำในการทำนายประเภทของรถอยู่ที่ 36.21% ซึ่งยังอยู่ในระดับที่ต้องปรับปรุงเพื่อให้สามารถนำไปใช้งานจริงได้อย่างมีประสิทธิภาพมากยิ่งขึ้น

ผลการทดสอบระหว่างช่วงเวลากลางวันและกลางคืนพบว่าช่วงเวลากลางคืนมีความแม่นยำในการทำนายสีและประเภทของรถสูงกว่าช่วงกลางวันเล็กน้อย แม้ว่าจะมีจำนวนข้อมูลน้อยกว่า อย่างไรก็ตามเนื่องจากข้อมูลในช่วงกลางคืนมีจำนวนน้อย จึงอาจยังไม่สามารถสรุปผลได้อย่างชัดเจนและจำเป็นต้องมีการทดลองเพิ่มเติมเพื่อยืนยันผลลัพธ์

จากผลการทดลองโดยรวม แสดงให้เห็นว่าโปรแกรมยังคงมีข้อจำกัดในการทำนายสีและประเภทของรถ โดยเฉพาะเมื่อเผชิญกับสภาพแสงที่หลากหลายและความแตกต่างของสภาพแวดล้อมในแต่ละช่วงเวลา ซึ่งแสดงให้เห็นถึงความจำเป็นในการพัฒนาและปรับปรุงระบบเพิ่มเติม ทั้งในด้านกระบวนการวิเคราะห์ภาพและวิธีการจำแนก เพื่อเพิ่มความแม่นยำและความน่าเชื่อถือในการใช้งานจริงต่อไป

5.1.4 ปัญหาและอุปสรรค

ตารางที่ 5. 1 ปัญหาและอุปสรรค

ปัญหาและอุปสรรค	แนวทางแก้ไข
ระยะเวลาในการเทรนโมเดล YOLO ที่นาน และเมื่อทำการทดสอบแล้วได้ผลลัพธ์ที่ไม่เป็นไปตามที่คาดหวังจะต้องเทรนใหม่	ใช้ CUDA เพื่อลดระยะเวลาในการเทรน และปรับแก้ข้อมูลสำหรับเทรน รวมถึงรายละเอียดในการเทรนให้มีความละเอียดและคุณภาพสูง เพื่อลดโอกาสที่จะได้ผลลัพธ์ที่ไม่เป็นไปตามที่คาดหวัง
การเตรียมสภาพแวดล้อมเพื่อใช้ CUDA มีความยุ่งยากและความเข้ากันได้ของ CUDA กับฮาร์ดแวร์ที่มีอยู่และซอฟต์แวร์ที่ใช้ทำโปรเจคมาในตอนแรก	ใช้ Google Colab ที่เป็น Runtime บน Cloud แทน ซึ่งมีการจัดสภาพแวดล้อมไว้ให้เหมาะสมแก่การทดสอบโปรเจค
ความเข้ากันได้ของซอฟต์แวร์และไลบรารีต่าง ๆ เมื่อทำการทดสอบทุกอย่างใน Google Colab แล้วสามารถทำงานได้ แต่เมื่อนำมาทดสอบด้วยเครื่องของตัวเอง โมเดลกลับทำงานไม่ได้	อัปเดตให้ Python เป็นเวอร์ชัน 10 และอัปเดตไลบรารีพื้นฐานต่าง ๆ ของ Python เช่น NumPy ซึ่งจำเป็นต้องเป็นเวอร์ชัน 1.26 ขึ้นไป
ปัญหาทรัพยากรที่มีไม่เพียงพอต่อการเทรนโมเดลที่มีประสิทธิภาพสูง	ใช้ GPU A100 ของ Google Colab ในการเทรนโมเดล แต่แลกมากับระยะเวลาที่สามารถใช้ Runtime ได้ลดลง เนื่องจากใช้หน่วยประมวลผลมากขึ้น

5.1.5 สรุปผลลัพธ์ของโปรเจค

จากการทดลองทั้งหมดในบทที่ 4 พบว่าระบบที่ใช้ระบุประเภทและสีของรถสามารถทำงานได้ดีเมื่ออยู่ในขั้นตอนของการทดสอบ จะเห็นว่าผลการทดสอบการแยกแยะประเภทรถในข้อ 4.2 และผลการทดสอบการจำแนกสีของรถในข้อ 4.5 นั้นมีผลลัพธ์ที่ดี แต่ก็ยังคงมีข้อผิดพลาดอยู่เล็กน้อย แต่เมื่อนำทั้งสองระบบมาทำงานร่วมกันในโปรแกรมจริง ผลลัพธ์ที่ได้กลับต่ำและไม่เป็นไปตามที่คาดหวังไว้ เหตุผลนั้นอาจจะมาจากหลายสาเหตุ

สาเหตุที่การระบุประเภทของรถมีความถูกต้องต่ำเมื่อนำมาใช้งานจริงนั้นอาจจะมาจากมุมกล้องที่แปลกไปและความคมชัดของกล้องในสภาพแวดล้อมจริงที่น้อยกว่าที่ได้ทำการทดสอบ ทำให้การระบุประเภทของรถมีความผิดพลาดและไม่เป็นไปตามที่ทดสอบในขั้นตอนการทดสอบ โดยทั้งสองปัญหานี้สามารถแก้ไขได้ด้วยการเทรนโมเดลใหม่ให้มีความละเอียดและหลากหลายของข้อมูลมากขึ้น

สาเหตุที่การระบุสีของรถมีความถูกต้องต่ำเมื่อนำมาใช้งานจริงนั้นอาจจะมาจากสภาพแสงในสภาพแวดล้อมจริงที่มีการเปลี่ยนแปลงมากกว่า และคุณภาพของวิดีโอที่มีความคมชัดน้อยกว่าตอนทดสอบ ส่งผลให้ค่าของสีใน HSV อาจมีความคลาดเคลื่อนจากค่าที่กำหนดไว้ในการทดสอบ ทำให้ระบบจำแนกสีได้ไม่ถูกต้อง ความไม่แน่นอนของแสงในสภาพแวดล้อมจริงอาจทำให้ค่าของสีเปลี่ยนแปลงไปจากเดิม ขณะที่คุณภาพของวิดีโอที่ลดลงส่งผลให้รายละเอียดของสีไม่ชัดเจน ซึ่งเป็นปัจจัยที่ทำให้ความแม่นยำของระบบลดลงเมื่อใช้งานจริง โดยปัญหาเหล่านี้สามารถแก้ไขได้โดยการปรับปรุงขอบเขตของค่าสีใน HSV ให้มีความยืดหยุ่นมากขึ้นเพื่อลดข้อผิดพลาดจากการเปลี่ยนแปลงของสภาพแสง รวมถึงการใช้เทคนิคปรับแต่งภาพเพื่อเพิ่มความเสถียรของสี นอกจากนี้ การปรับปรุงคุณภาพของวิดีโอและการลดสัญญาณรบกวนสามารถช่วยให้ระบบสามารถจำแนกสีได้อย่างแม่นยำมากขึ้นในสภาพแวดล้อมจริง

โดยสรุป ระบบระบุประเภทและสีของรถสามารถทำงานได้ดีในขั้นตอนการทดสอบ แต่เมื่อนำมาใช้งานจริง ประสิทธิภาพลดลงจากปัจจัยด้านมุมกล้อง ความคมชัดของวิดีโอ และสภาพแสงที่เปลี่ยนแปลง ซึ่งส่งผลต่อความถูกต้องของการจำแนกประเภทและสีของรถ ปัญหานี้สามารถแก้ไขได้โดยการปรับปรุงโมเดลให้รองรับข้อมูลที่หลากหลายมากขึ้น ปรับขอบเขตค่าสีใน HSV ให้ยืดหยุ่นขึ้น และใช้เทคนิคปรับแต่งภาพเพื่อลดผลกระทบจากคุณภาพวิดีโอและแสงแวดล้อม เพื่อให้ระบบสามารถทำงานได้แม่นยำยิ่งขึ้นในการใช้งานจริง

5.1.6 แนวทางการแก้ไขปัญหาในอนาคต

ตารางที่ 5. 2 แนวทางการแก้ไขปัญหาในอนาคต

ปัญหา	แนวทางแก้ไขในอนาคต
ความแม่นยำในการระบุประเภทรถ	เพิ่มปริมาณและความหลากหลายของข้อมูลฝึกโมเดล โดยใช้ภาพจากมุมกล้องและสภาพแวดล้อมที่หลากหลายขึ้น ปรับปรุงโมเดลให้รองรับการจำแนกประเภทรถได้ดีขึ้น
ความแม่นยำในการระบุสีรถ	ปรับปรุงขอบเขตค่าสีใน HSV ให้รองรับความเปลี่ยนแปลงของแสงมากขึ้น ใช้เทคนิคปรับแต่งภาพ เพื่อช่วยให้สีที่ระบบตรวจจับมีความแม่นยำมากขึ้น อาจพิจารณาใช้โมเดล Machine Learning หรือ Deep Learning ในการจำแนกสีแทน HSV เพียงอย่างเดียว รวมถึงปรับปรุงคุณภาพของวิดีโอโดยใช้กล้องที่มีประสิทธิภาพสูงขึ้น
โปรแกรมยังไม่สามารถระบุตำแหน่งจุดที่สนใจเพื่อนำมาวิเคราะห์สีได้อย่างสมบูรณ์ในยานพาหนะบางประเภท ได้แก่ รถจักรยานยนต์, รถบรรทุก และรถยนต์ประเภทจำเพาะ (เช่น รถยกสูง) เนื่องจากโครงสร้างและองค์ประกอบทางกายภาพของรถที่มีความหลากหลาย	พัฒนาอัลกอริทึมการตรวจจับจุดที่สนใจให้มีความยืดหยุ่นและจำเพาะเจาะจงตามประเภทของยานพาหนะ (Vehicle-type Specific ROI) โดยการเพิ่มชุดข้อมูล (Dataset) และปรับปรุงเงื่อนไขในการสกัดคุณลักษณะ (Feature Extraction) ให้ครอบคลุมลักษณะทางกายภาพที่แตกต่างกัน

ปัญหา	แนวทางแก้ไขในอนาคต
เนื่องด้วยรถจักรยานยนต์มีความหลากหลายด้านการออกแบบและตำแหน่งของส่วนประกอบที่แสดงสีหลักมีขนาดเล็กหรือกระจัดกระจาย ทำให้การกำหนดจุดที่สนใจแบบคงที่ (Static ROI) ไม่สามารถใช้ได้อย่างมีประสิทธิภาพ	เพิ่มขั้นตอนการจำแนกประเภทย่อยของรถจักรยานยนต์ (Sub-category Classification) ก่อนทำการกำหนดจุดที่สนใจ เพื่อให้โปรแกรมสามารถเลือกใช้พื้นที่วิเคราะห์สีที่เหมาะสมตามรูปทรงของรถแต่ละรุ่นได้อย่างแม่นยำ
อัลกอริทึมปัจจุบันยังไม่สามารถระบุสีของยานพาหนะได้อย่างแม่นยำเมื่อตรวจพบในมุมมองด้านหน้าตรง (Front View) หรือด้านหลังตรง (Rear View) รวมถึงในมุมมองที่บดบังทัศนียภาพของล้อรถ ซึ่งส่งผลให้การระบุตำแหน่งพื้นที่วิเคราะห์สี (ROI) ที่อ้างอิงจากฐานล้อไม่สามารถทำได้	พัฒนาโมดูลการตรวจจับองค์ประกอบย่อยของรถ (Vehicle Part Segmentation) เพื่อระบุตำแหน่งกระจกหน้า กระจกหลัง ฝากระโปรงหน้า หรือฝากระโปรงท้าย เพื่อใช้เป็นจุดอ้างอิงใหม่ในการกำหนดพื้นที่สำหรับวิเคราะห์สี (ROI) แทนการใช้ตำแหน่งล้อเพียงอย่างเดียว ซึ่งจะช่วยให้ระบบรองรับการตรวจจับได้จากหลากหลายมุมมองมากขึ้น
ความแม่นยำโดยรวมของโปรแกรม	ปรับปรุงการทำงานร่วมกันระหว่างระบบจำแนกประเภทและสีของรถให้มีประสิทธิภาพมากขึ้น ทดสอบและปรับแต่งโปรแกรมให้เหมาะกับสภาพแวดล้อมจริงเพื่อลดข้อผิดพลาดจากปัจจัยภายนอก

5.2 ข้อเสนอแนะ

จากปัญหาและอุปสรรคที่พบจากหัวข้อ 5.1.4 และ หัวข้อ 5.1.6 ผู้จัดทำจึงมีข้อเสนอแนะสำหรับผู้ที่ต้องการนำไปพัฒนาต่อควรมีความรู้ในสิ่งต่อไปนี้

5.2.1 การใช้ CUDA และการปรับแต่งการเทรนโมเดล YOLO

ผู้ที่ต้องการพัฒนาโปรเจคนี้ต่อไป ควรมีความรู้พื้นฐานเกี่ยวกับการใช้ CUDA เพื่อเร่งประสิทธิภาพการเทรนโมเดล โดยสามารถปรับแต่งการตั้งค่าการเทรนให้เหมาะสมกับฮาร์ดแวร์ที่ใช้ ทั้งนี้จะต้องเข้าใจเกี่ยวกับการปรับปรุงข้อมูลฝึกและการตั้งค่าพารามิเตอร์ให้ได้ผลลัพธ์ที่ดีขึ้น

5.2.2 การใช้งาน Google Colab และข้อจำกัดของระบบ Cloud

ควรเข้าใจถึงข้อดีและข้อจำกัดของการใช้ Google Colab ในการเทรนโมเดล รวมถึงการใช้ GPU A100 ในการทำงาน โดยต้องพิจารณาความเหมาะสมในการใช้ทรัพยากร Cloud และวิธีการจัดการข้อจำกัดเรื่องระยะเวลาการใช้งาน Runtime ในระบบ

5.2.3 ความเข้ากันได้ของซอฟต์แวร์และไลบรารีต่าง ๆ

ผู้พัฒนาควรมีความรู้เกี่ยวกับการจัดการความเข้ากันได้ของซอฟต์แวร์ที่ใช้ เช่น Python เวอร์ชันที่เหมาะสม และการอัปเดตไลบรารีต่าง ๆ เช่น NumPy หรือ OpenCV เพื่อให้แน่ใจว่าโปรเจคทำงานได้อย่างราบรื่นทั้งในระบบปฏิบัติการท้องถิ่นและใน Cloud

5.2.4 การเพิ่มปริมาณและความหลากหลายของข้อมูลในการเทรน

การเพิ่มปริมาณข้อมูลที่มีความหลากหลายจากมุมมองต่าง ๆ และสภาพแวดล้อมที่แตกต่างกัน จะช่วยเพิ่มความแม่นยำในการจำแนกประเภทของรถ ผู้พัฒนาควรมีความรู้ในการเก็บข้อมูลที่หลากหลายเพื่อตอบสนองต่อการเรียนรู้ของโมเดล

5.2.5 การใช้และปรับแต่ง HSV color space สำหรับการจำแนกสีรถ

ควรเข้าใจถึงการปรับแต่งค่าสีใน HSV เพื่อรองรับการเปลี่ยนแปลงของแสงที่มีผลต่อความแม่นยำในการจำแนกสีรถ รวมถึงการใช้เทคนิคปรับแต่งภาพและการพิจารณาใช้โมเดล Machine Learning หรือ Deep Learning ในการจำแนกสี

5.2.6 การทดสอบและปรับปรุงระบบให้เหมาะสมกับสภาพแวดล้อมจริง

ควรมีความรู้เกี่ยวกับการทดสอบระบบในสภาพแวดล้อมจริง เพื่อลดข้อผิดพลาดจากปัจจัยภายนอกและทำให้ระบบสามารถทำงานได้อย่างมีประสิทธิภาพในสภาพแวดล้อมต่าง ๆ โดยการทดสอบจะช่วยให้สามารถปรับปรุงการทำงานร่วมกันระหว่างระบบจำแนกประเภทและสีของรถได้ดีขึ้น

เอกสารอ้างอิง

[1] ค. สุขุมาลจันทร์, **การประมวลผลข้อมูลภาพ (Digital Image Processing)**, ชลบุรี: มหาวิทยาลัยบูรพา, 2550.

[2] ส. ไทยนิมิต, **การประมวลผลภาพดิจิทัลเบื้องต้นด้วย MATLAB**, กรุงเทพฯ: มหาวิทยาลัยเกษตรศาสตร์, 2553.

[3] I. Goodfellow, Y. Bengio, and A. Courville, **Deep Learning**, MIT Press, 2016.

[4] Mr.P L, "**Deep Learning แบบฉบับคนสามัญชน**," Mar. 2, 2019. Available: https://medium.com/mmp-li/deep-learning-แบบฉบับคนสามัญชน-ep-1-neural-network-history-f7789236a9a3. Accessed on: Nov. 2024.

[5] P. Sharma, "**Image Classification vs. Object Detection vs. Image Segmentation**," Aug. 21, 2019. Available: https://medium.com/analytics-vidhya/image-classification-vs-object-detection-vs-image-segmentation-f36db85fe81. Accessed on: Nov. 2024.

[6] Chooch, "**What is Object Detection?**," Oct. 10, 2023. Available: https://www.linkedin.com/pulse/what-object-detection-chooch/. Accessed on: Nov. 2024.

[7] ป. ห่อแก้ว, **Computer Vision**, นครราชสีมา: มหาวิทยาลัยเทคโนโลยีสุรนารี, 2564.

[8] X. Liu, W. Liu, H. Ma, and H. Fu, "**Large-scale vehicle re-identification in urban surveillance videos**," in 2018 IEEE International Conference on Multimedia and Expo (ICME), 2018, pp. 1-6. IEEE.

[9] L. Chen, F. Yang, and H. Yang, "**Vehicle color recognition using convolutional neural network and color histogram**," in 2019 IEEE 4th International Conference on Image, Vision and Computing (ICIVC), 2019, pp. 697-701. IEEE.

[10] ผกา เกษ, วั ตุ ยา. **โครงการวิจัยเรื่องการพัฒนาตัวตรวจจับคุณลักษณะเฉพาะสำหรับระบบการรู้จำยี่ห้อรุ่นและสีของรถยนต์เพื่อใช้ในการตรวจจับรถต้องสงสัย.**

[11] Kumpolpat Banlungrattana, "**ประเภทรถยนต์มีอะไรบ้าง แตกต่างกันอย่างไร**," One2Car.com, 2023. Available: https://www.one2car.com/ข่าว/ประเภทรถยนต์-มีอะไรบ้าง-แตกต่างกันอย่างไร/67715. Accessed on: Dec. 2024.

[12] Microsoft, **Visual Studio Code Documentation**, n.d. Available: https://code.visualstudio.com/docs. Accessed on: Dec. 2024.

[13] Roboflow, **Roboflow Documentation**, n.d. Available: https://roboflow.com. Accessed on: Dec. 2024.

[14] OpenCV, **OpenCV Documentation**, n.d. Available: https://opencv.org. Accessed on: Dec. 2024.

[15] Python Software Foundation, **Python: A Programming Language**, Version 3.x, 2024. Available: https://www.python.org. Accessed on: Nov. 2024.

[16] G. Jocher et al., "**YOLOv8: The Next Generation of Real-Time Object Detection**," Ultralytics, Jan. 2023. Available: https://github.com/ultralytics/ultralytics. Accessed on: Nov. 2024.

[17] Python Software Foundation, **Tkinter - Python's Standard GUI Toolkit**, 2024. Available: https://docs.python.org/3/library/tkinter.html. Accessed on: Nov. 2024.

[18] F. Pedregosa et al., "**Scikit-learn: Machine Learning in Python**," Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011. Available: https://scikit-learn.org. Accessed on: Nov. 2024.

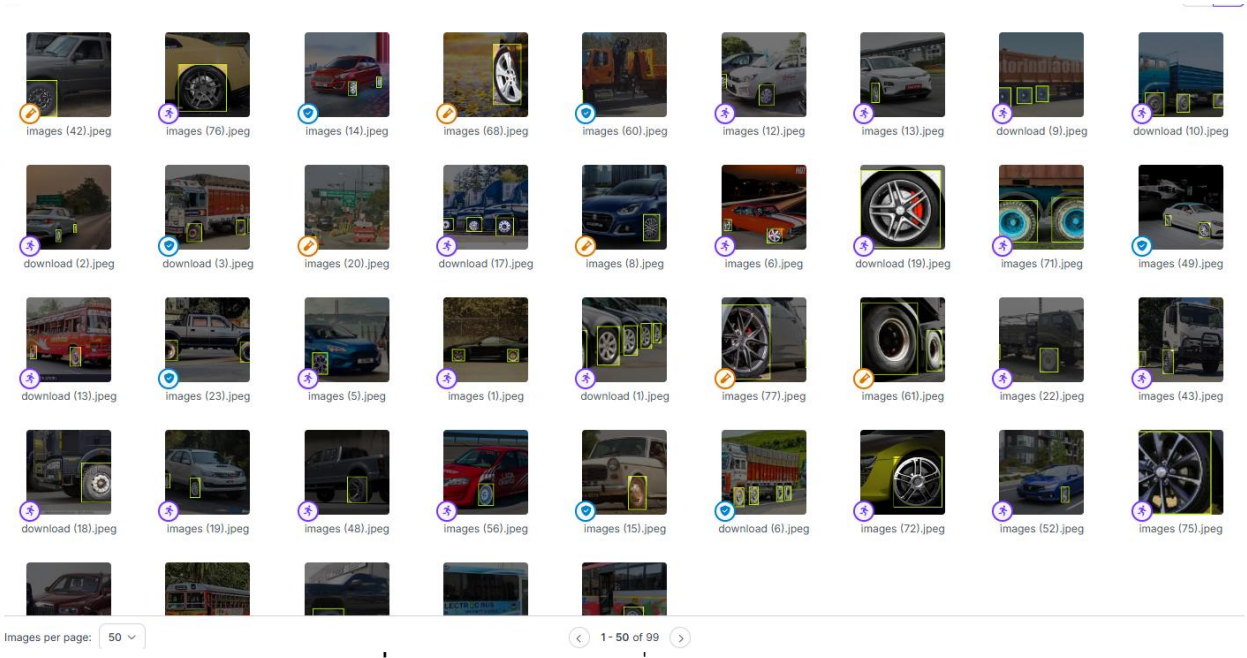
[19] A. Paszke et al., "**PyTorch: An Imperative Style, High-Performance Deep Learning Library**," in Proceedings of the 33rd Conference on Neural Information Processing Systems (NeurIPS), Vancouver, Canada, 2019. Available: https://pytorch.org. Accessed on: Nov. 2024.

[20] NVIDIA Corporation, **CUDA Toolkit Documentation**, 2024. Available: https://developer.nvidia.com/cuda-toolkit. Accessed on: Nov. 2024.

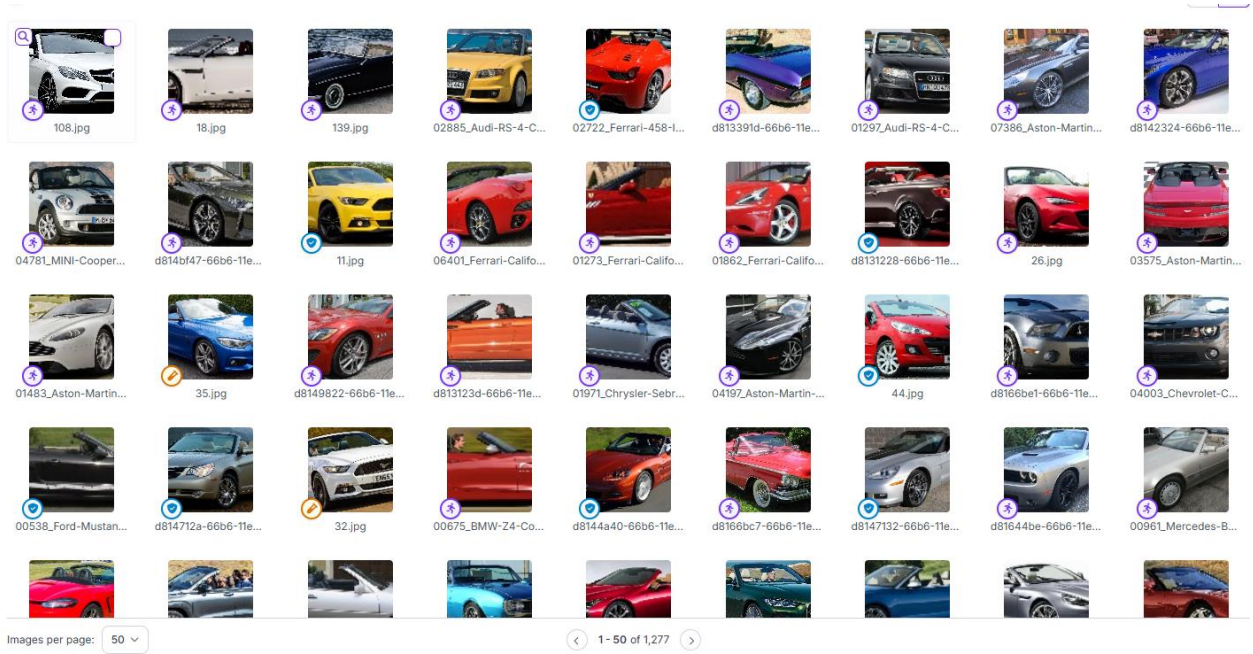
[21] Google Research, **Google Colaboratory: Cloud-Based Jupyter Notebooks**, 2024. Available: https://colab.research.google.com. Accessed on: Nov. 2024.

ภาคผนวก ก

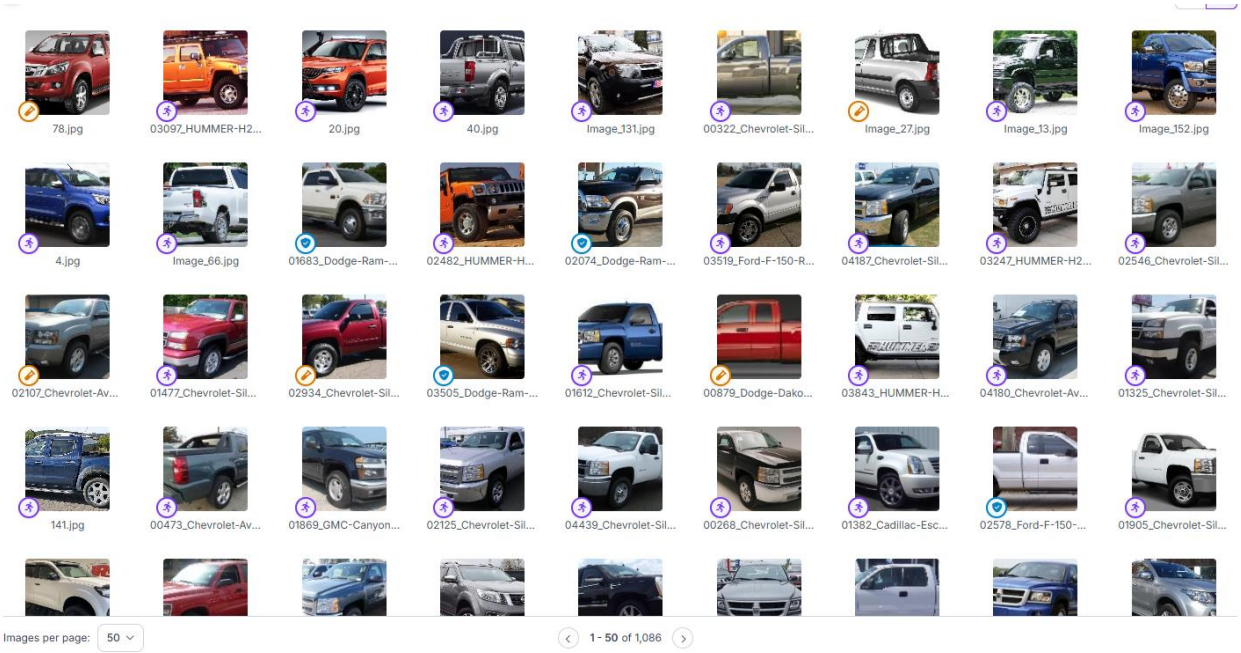
ข้อมูลที่ใช้เทรนโมเดล



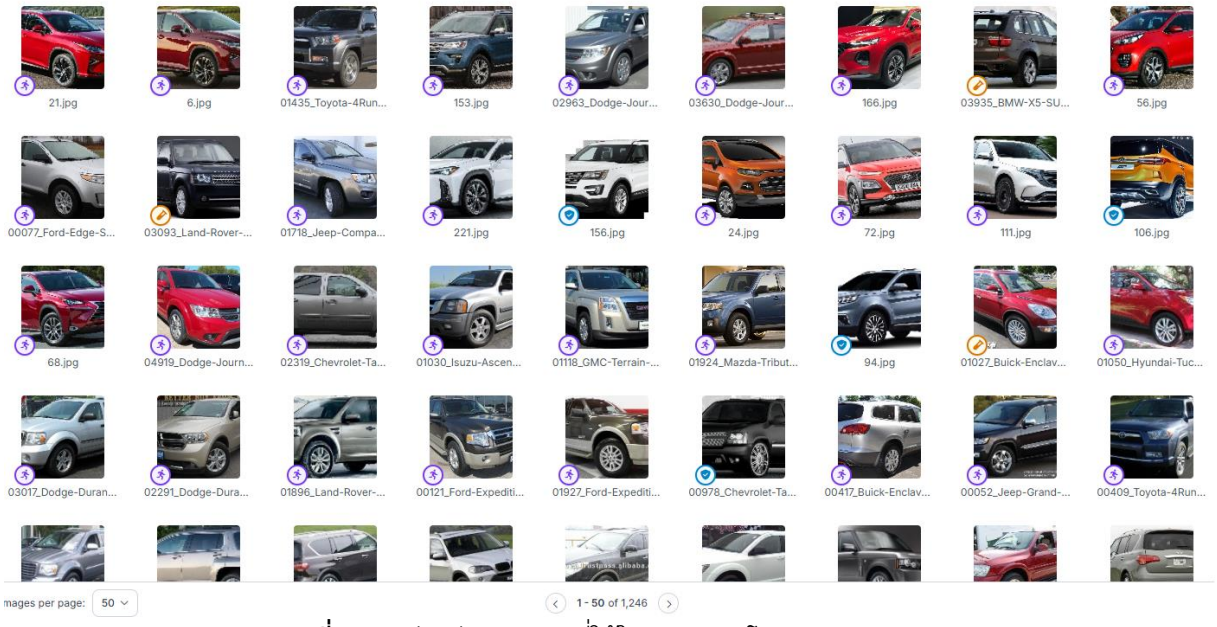
รูปที่ ก. 1 ตัวอย่างรูปภาพที่ใช้ในการเทรนโมเดลตรวจจับล้อ



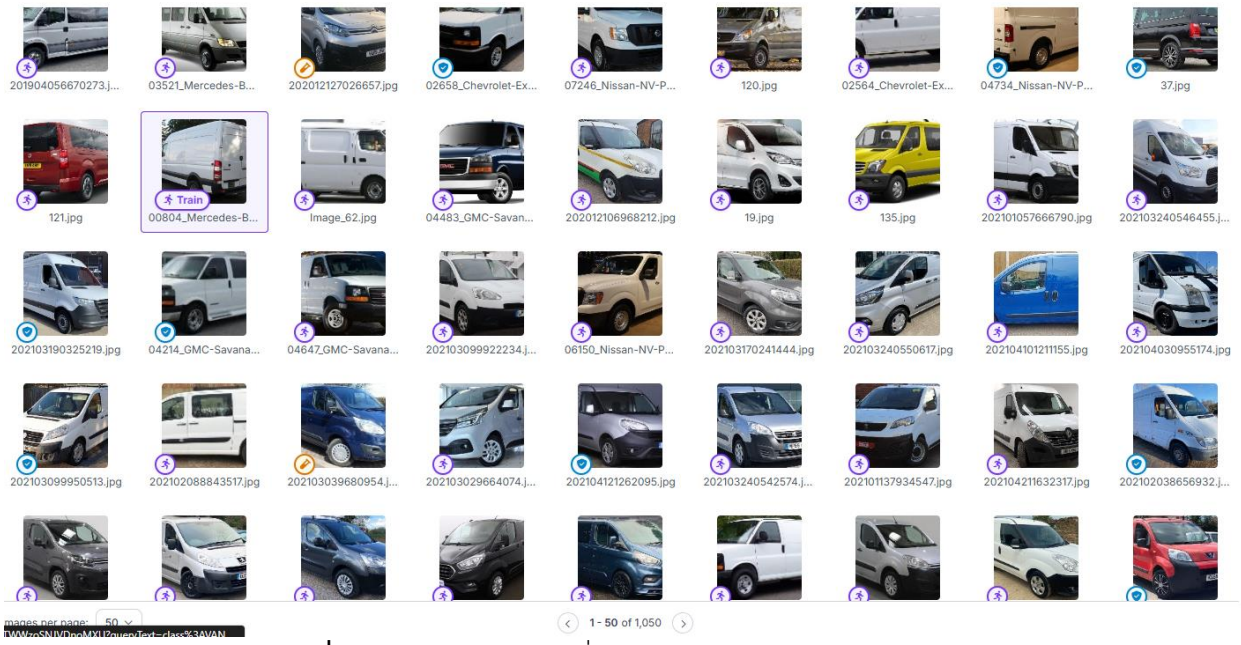
รูปที่ ก. 2 ตัวอย่างรูปภาพที่ใช้ในการเทรนโมเดลแยกแยะประเภทรถ(1)



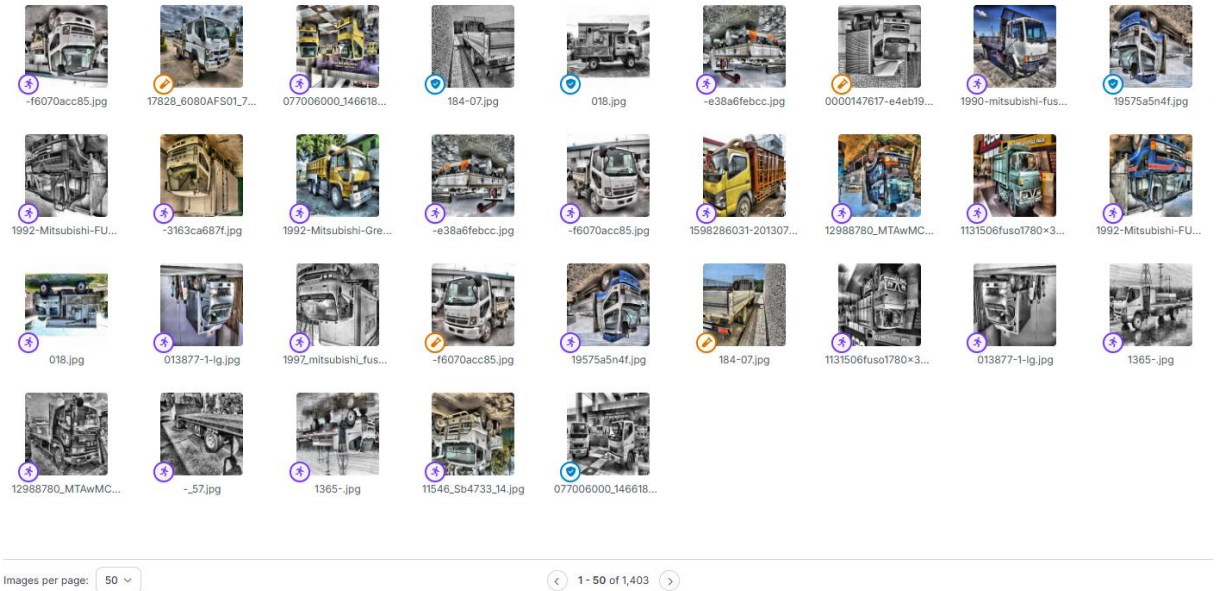
รูปที่ ก. 3 ตัวอย่างรูปภาพที่ใช้ในการเทรนโมเดลแยกแยะประเภทรถ(2)



รูปที่ ก. 4 ตัวอย่างรูปภาพที่ใช้ในการเทรนโมเดลแยกแยะประเภทรถ(3)



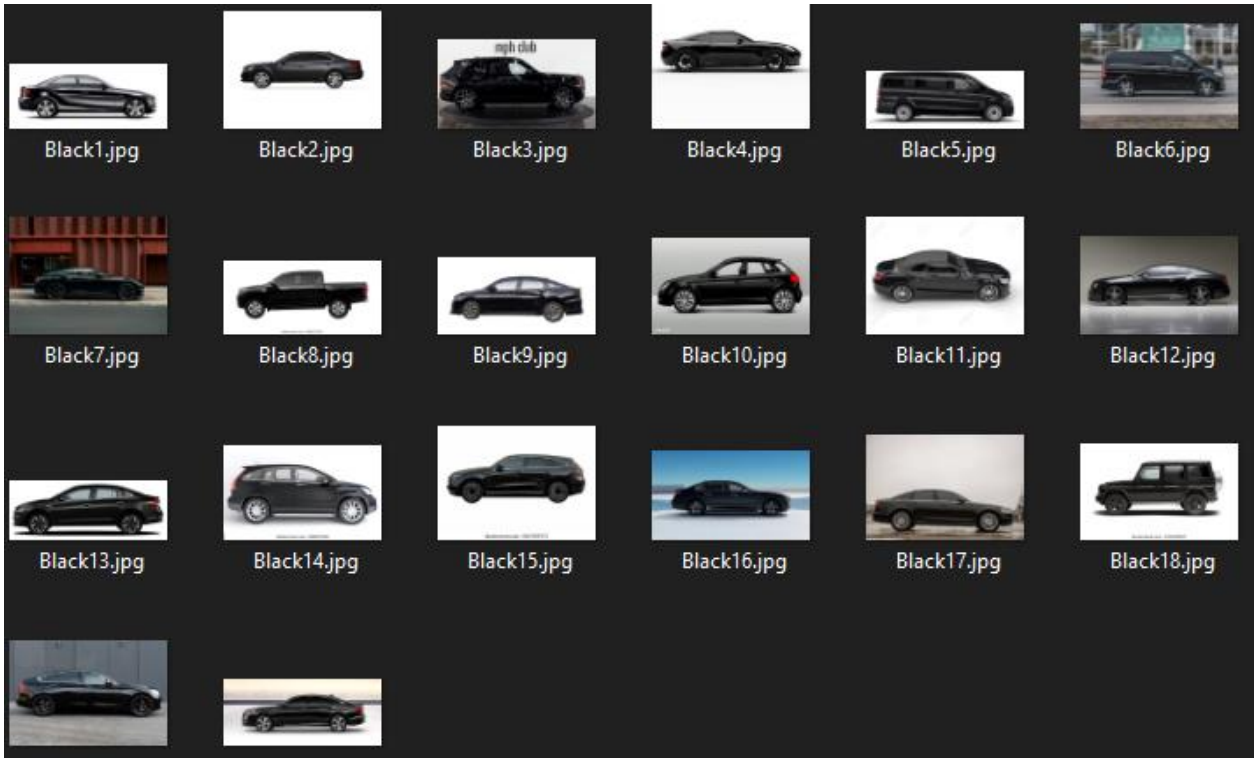
รูปที่ ก. 5 ตัวอย่างรูปภาพที่ใช้ในการเทรนโมเดลแยกแยะประเภทรถ(4)



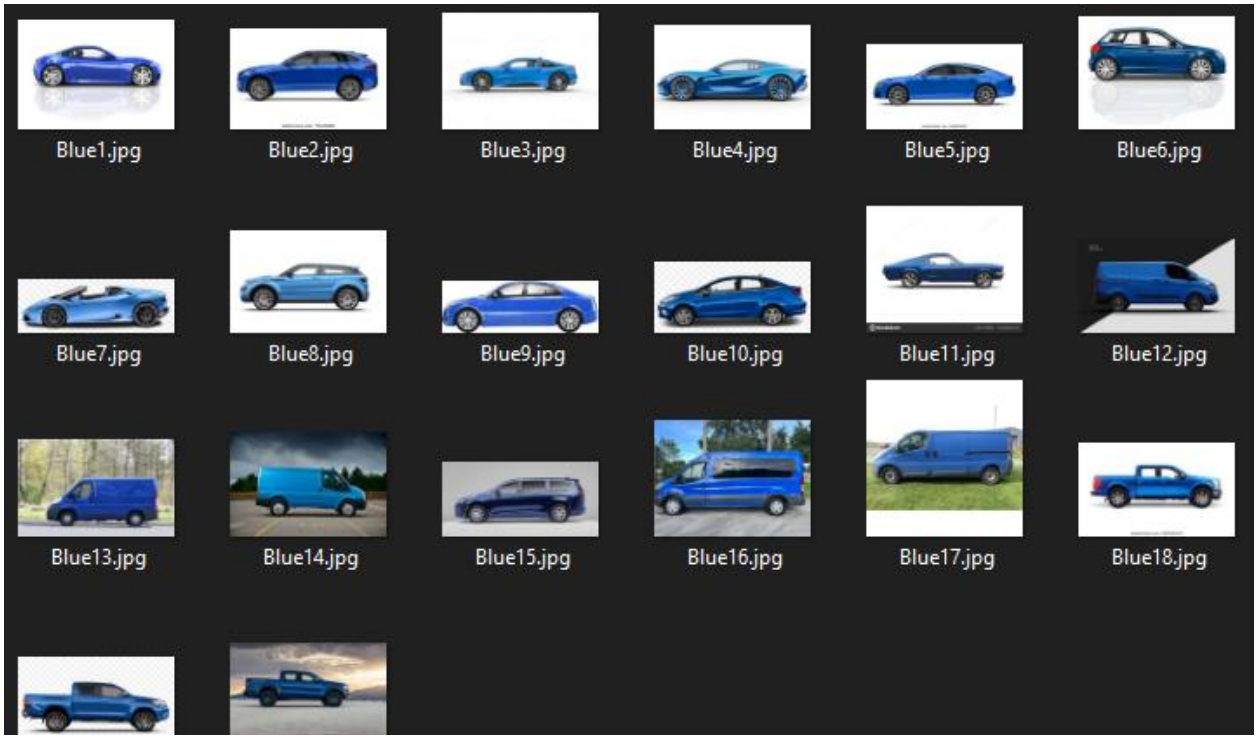
รูปที่ ก. 6 ตัวอย่างรูปภาพที่ใช้ในการเทรนโมเดลแยกแยะประเภทรถ(5)

ภาคผนวก ข

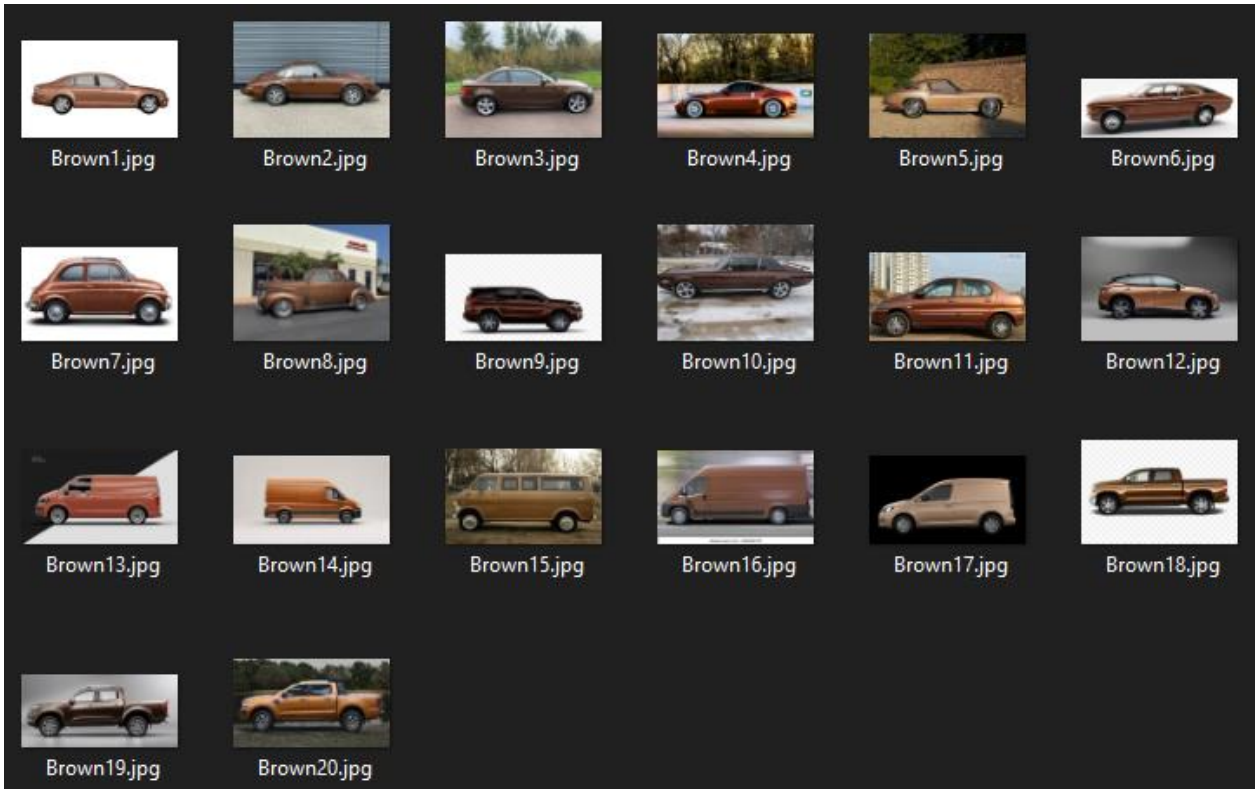
ข้อมูลสำหรับทดสอบการระบุสี



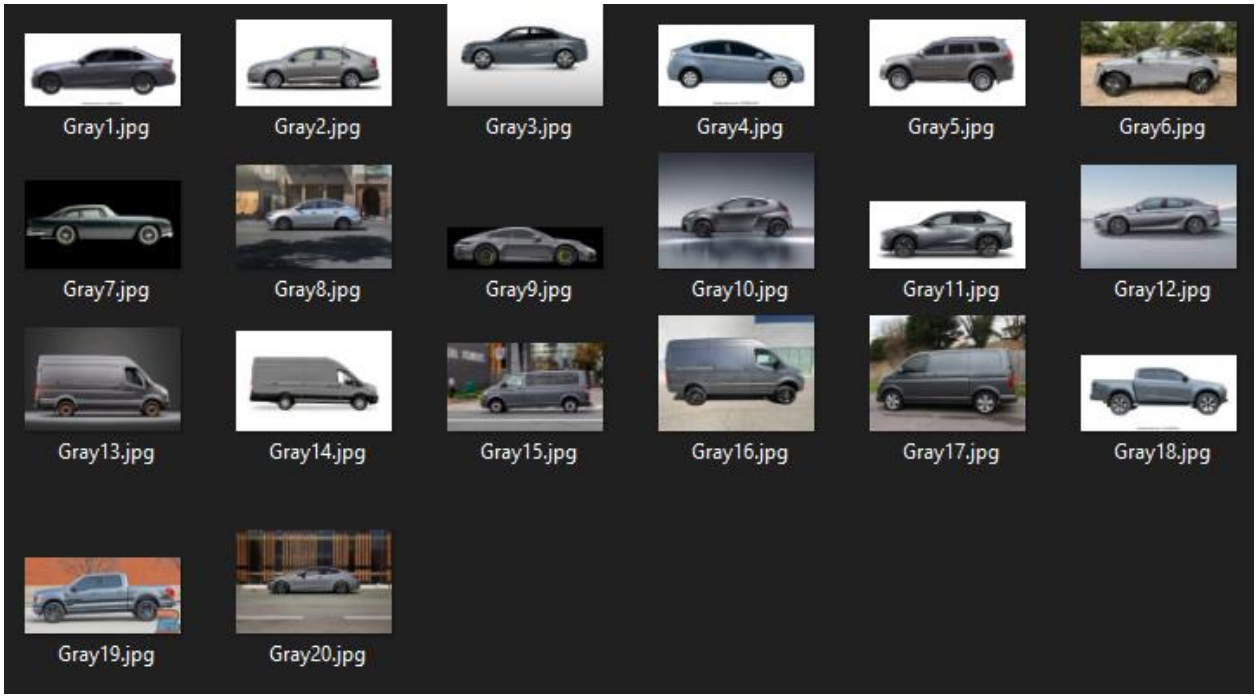
รูปที่ ข. 1 ข้อมูลสำหรับทดสอบการระบุสีรถสีดำ



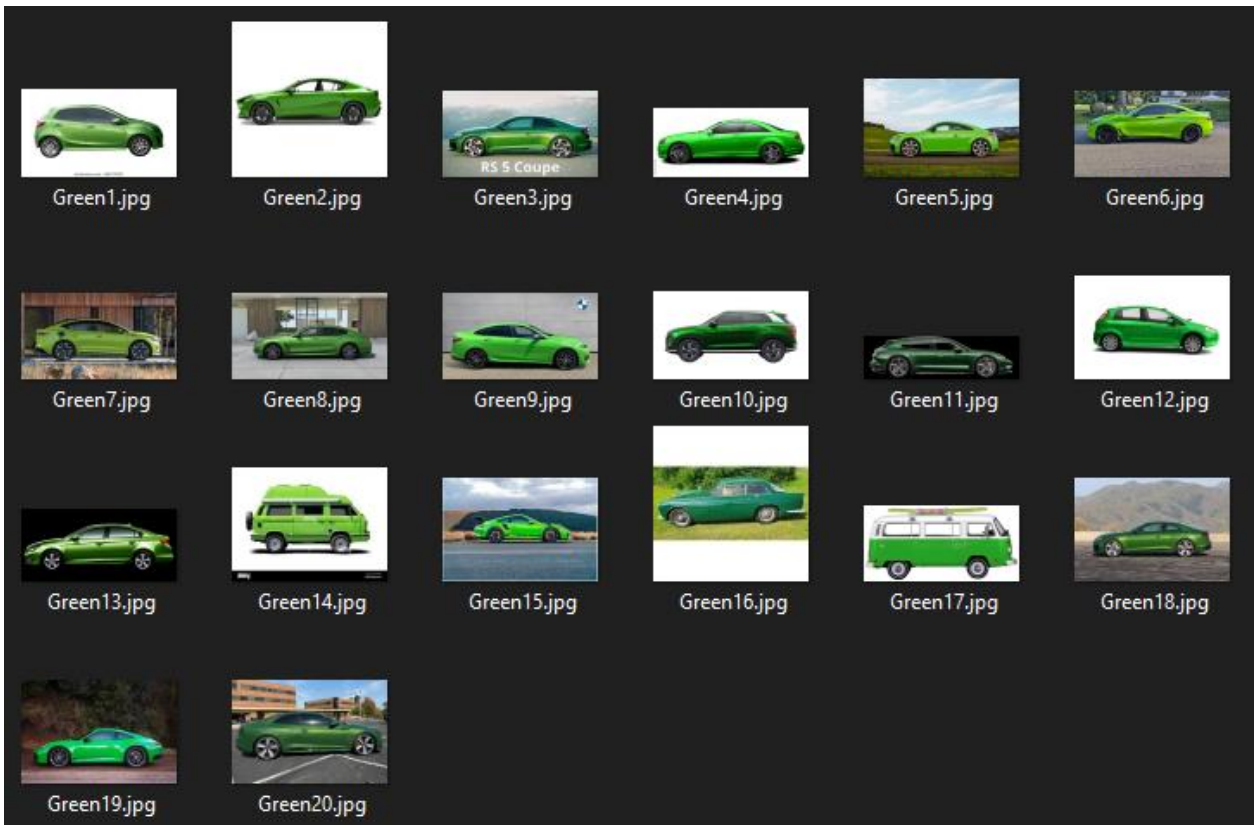
รูปที่ ข. 2 ข้อมูลสำหรับทดสอบการแยกสีรถสีนำเงิน



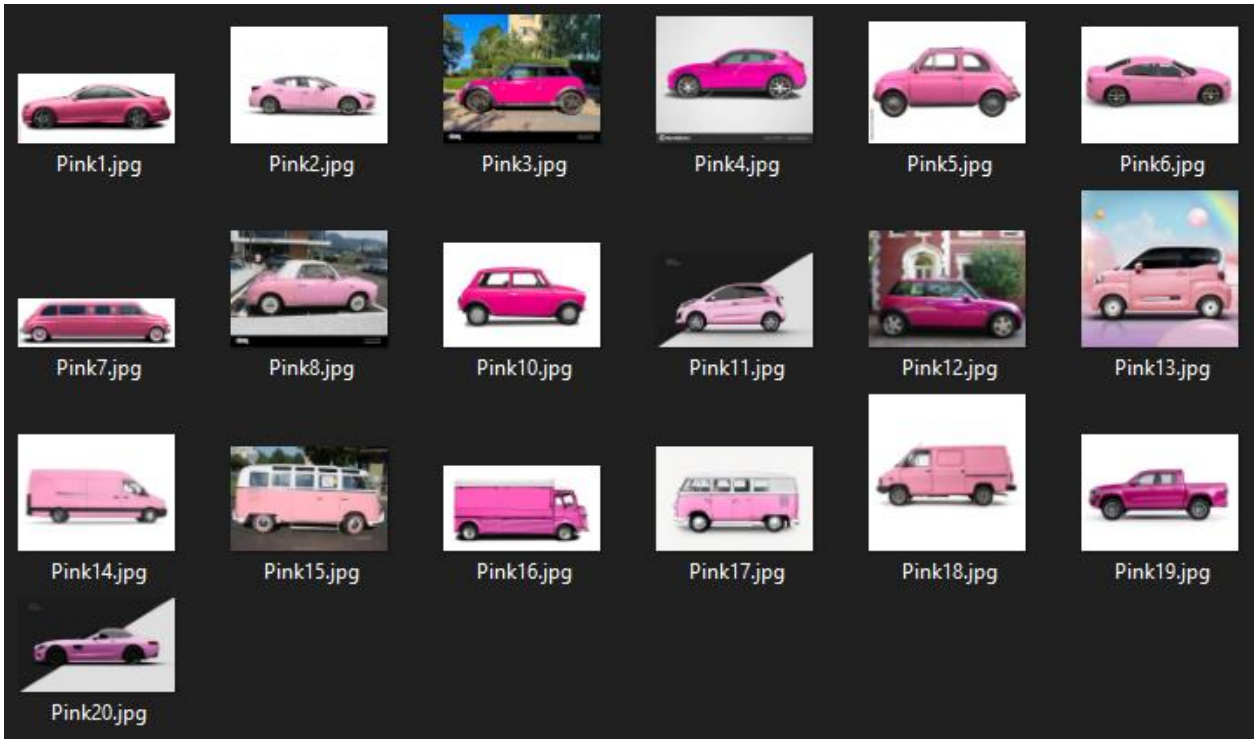
รูปที่ ข. 3 ข้อมูลสำหรับทดสอบการแยกสีรถสีน้ำตาล



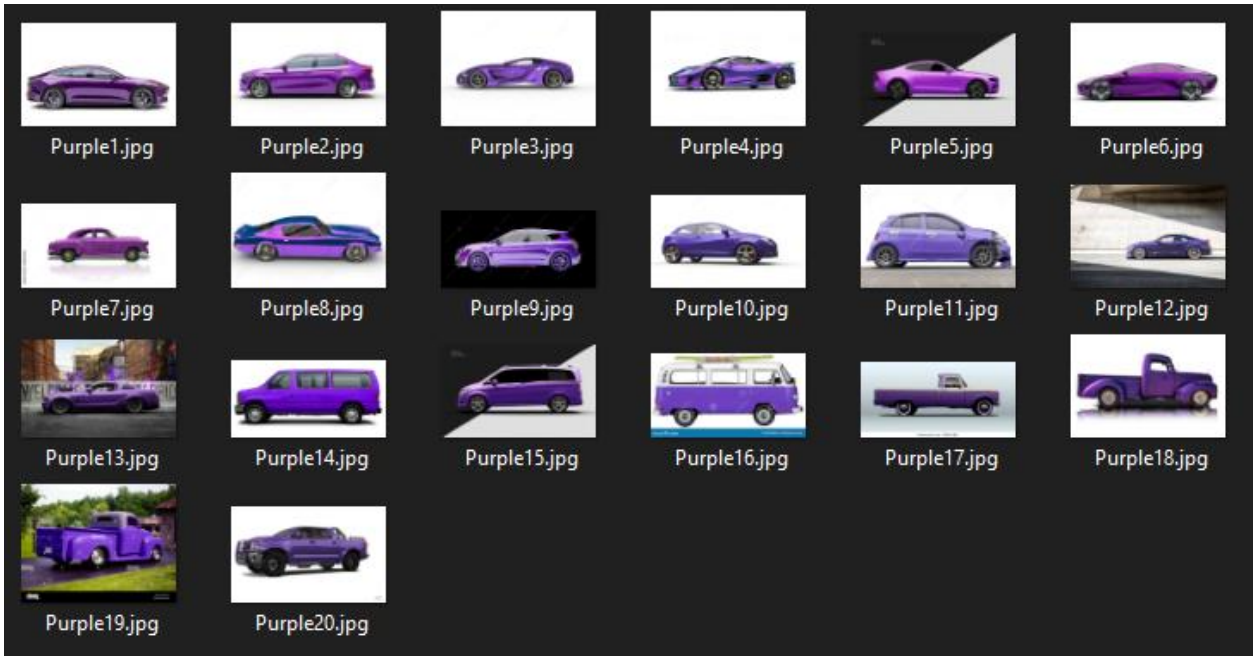
รูปที่ ข. 4 ข้อมูลสำหรับทดสอบการแยกสีรถสีเทา



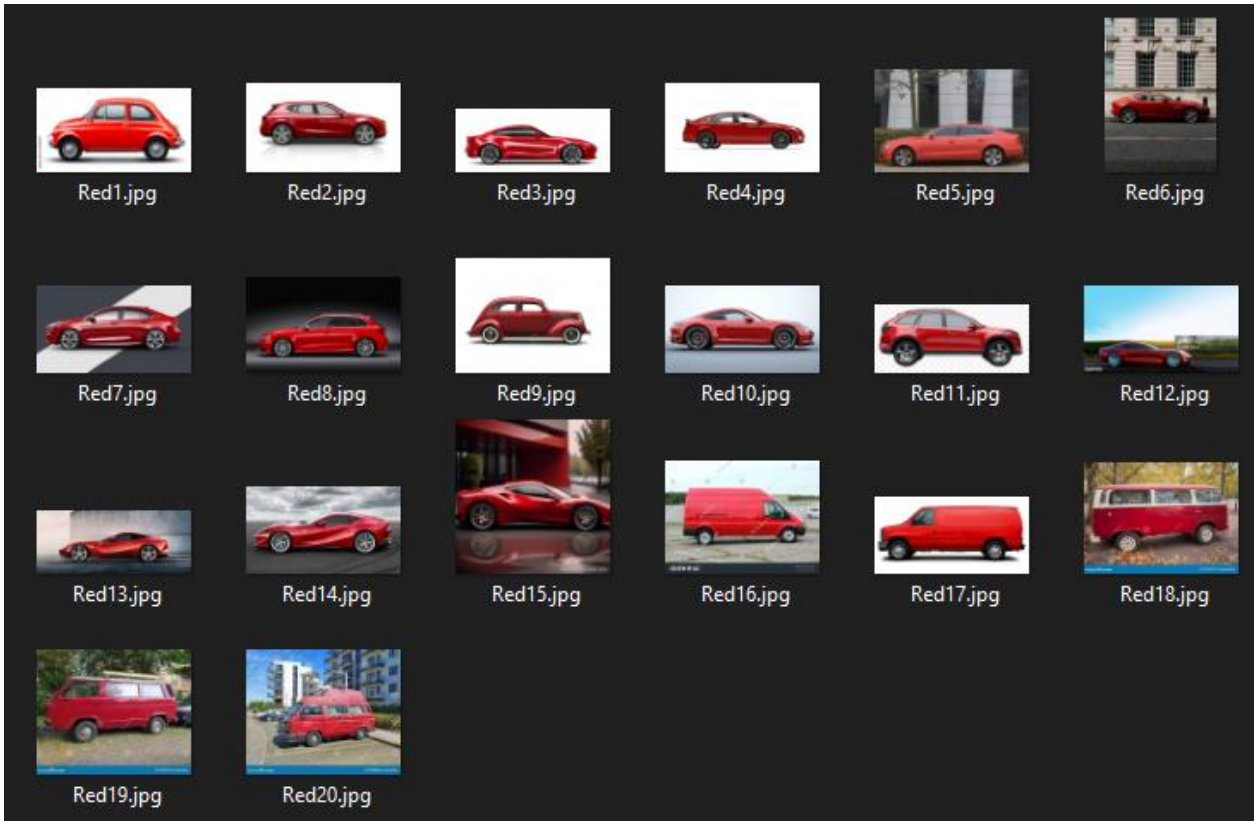
รูปที่ ข. 5 ข้อมูลสำหรับทดสอบการแยกสีรถสีเขียว



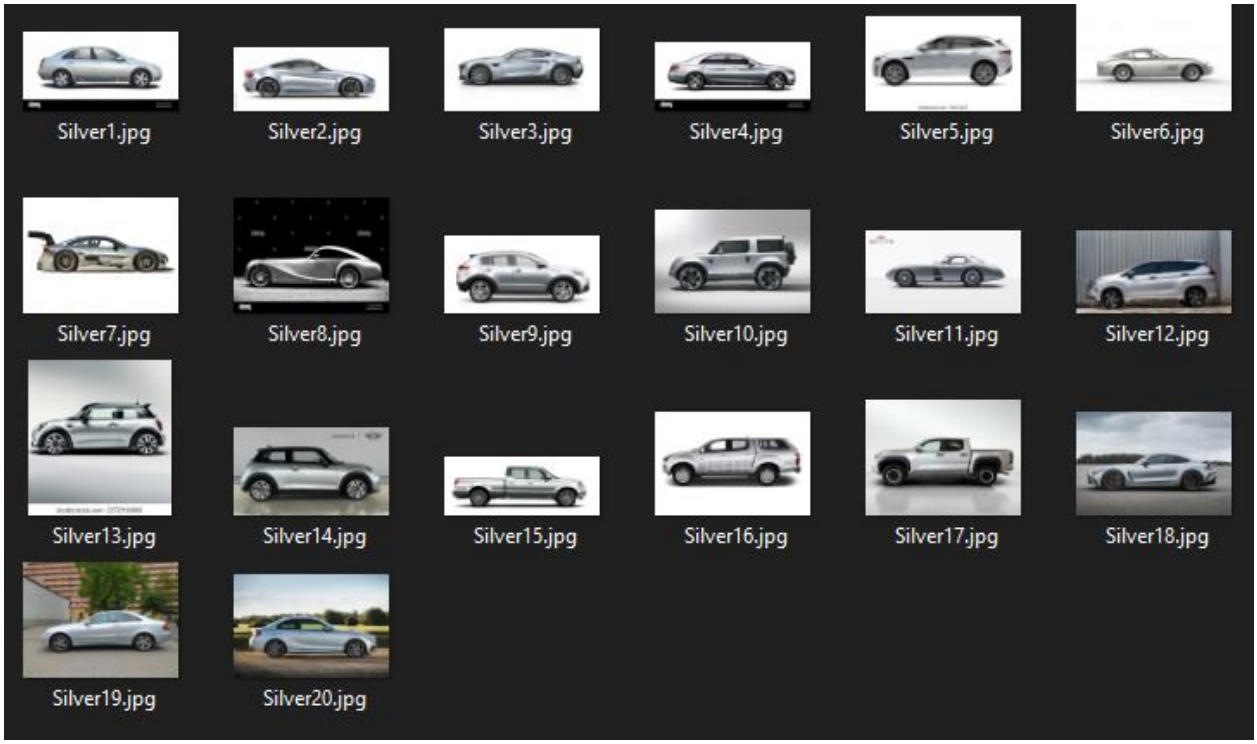
รูปที่ ข. 6 ข้อมูลสำหรับทดสอบการแยกสีรถสีชมพู



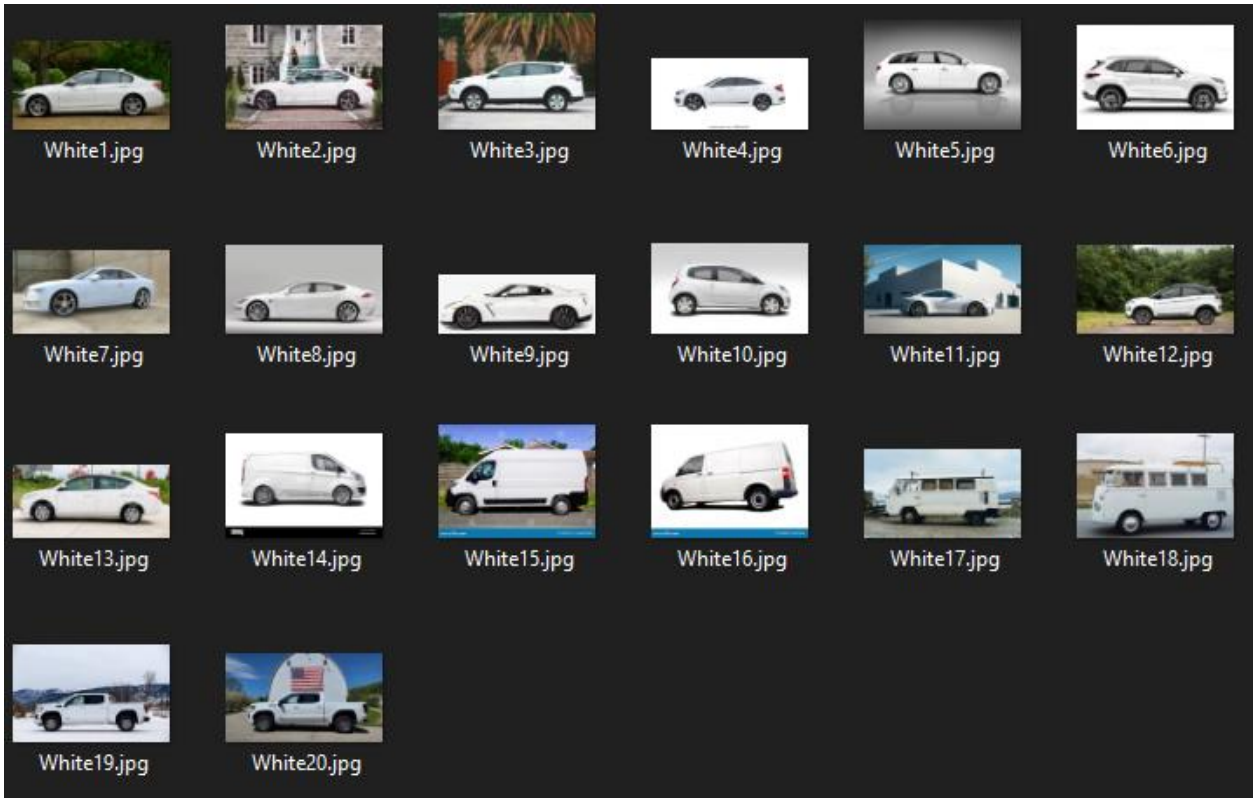
รูปที่ ข. 7 ข้อมูลสำหรับทดสอบการแยกสีรถสีม่วง



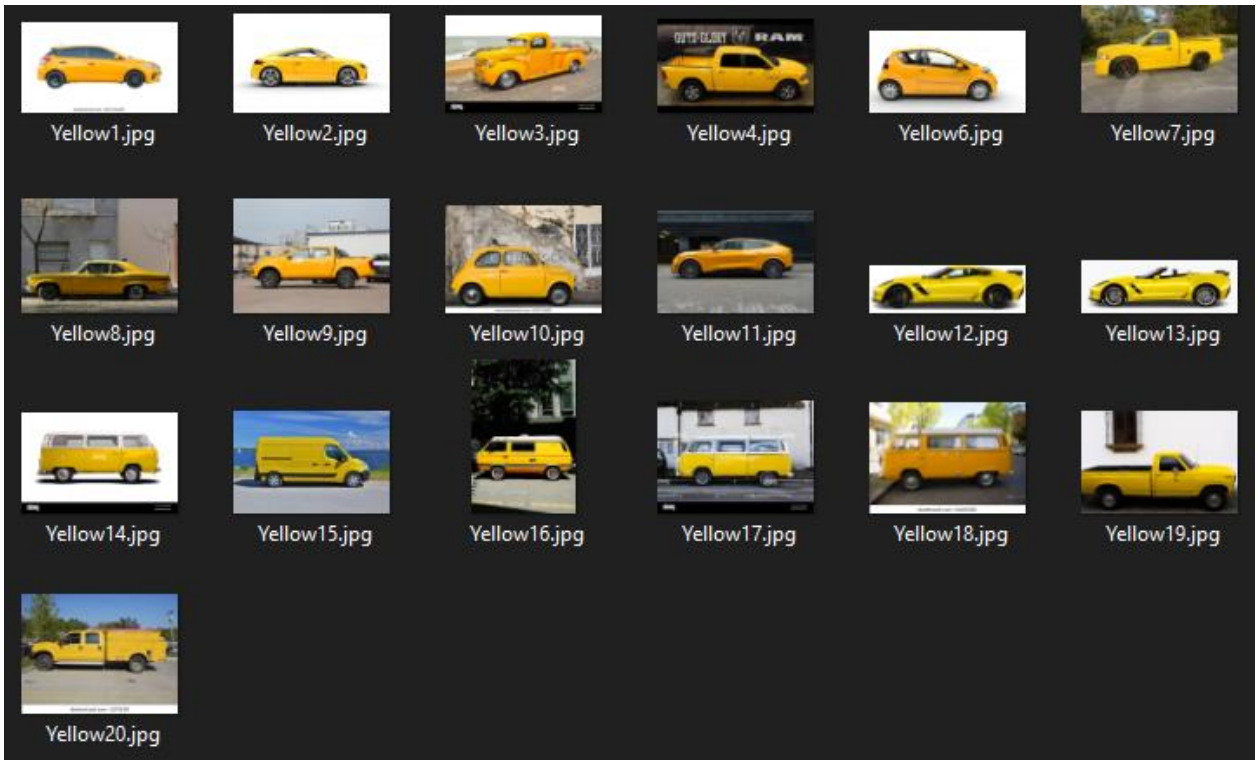
รูปที่ ข. 8 ข้อมูลสำหรับทดสอบการแยกสีรถสีแดง



รูปที่ ข. 9 ข้อมูลสำหรับทดสอบการแยกสีรถสีเงิน



รูปที่ ข. 10 ข้อมูลสำหรับทดสอบการแยกสีรถสีขาว



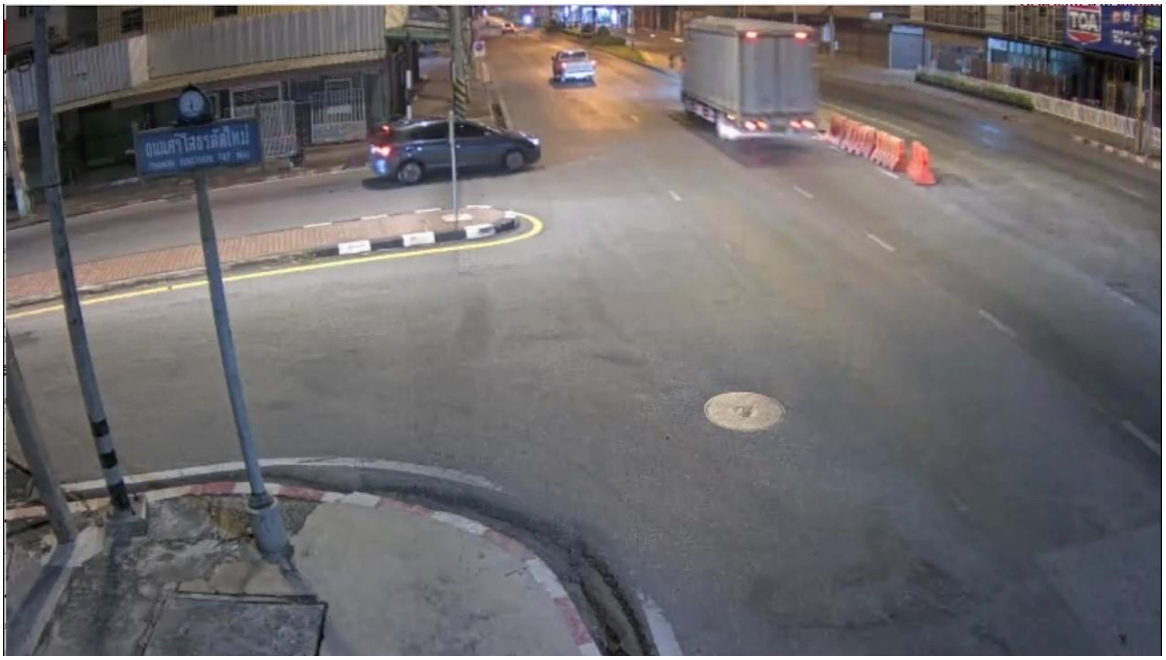
รูปที่ ข. 11 ข้อมูลสำหรับทดสอบการแยกสีรถสีเหลือง

ภาคผนวก ค

วิดีโอที่ใช้สำหรับทดสอบการทำงานของโปรแกรม



รูปที่ ค. 1 ตัวอย่างภาพวิดีโอในตอนกลางวัน



รูปที่ ค. 2 ตัวอย่างภาพวิดีโอในตอนกลางคืน

ภาคผนวก ง

ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด



รูปที่ ง. 1 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(1)



รูปที่ ง. 2 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(2)



รูปที่ ง. 3 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(3)



รูปที่ ง. 4 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(4)



รูปที่ ง. 5 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(5)



รูปที่ ง. 6 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(6)



รูปที่ ง. 7 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(7)



รูปที่ ง. 8 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(8)



รูปที่ ง. 9 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(9)



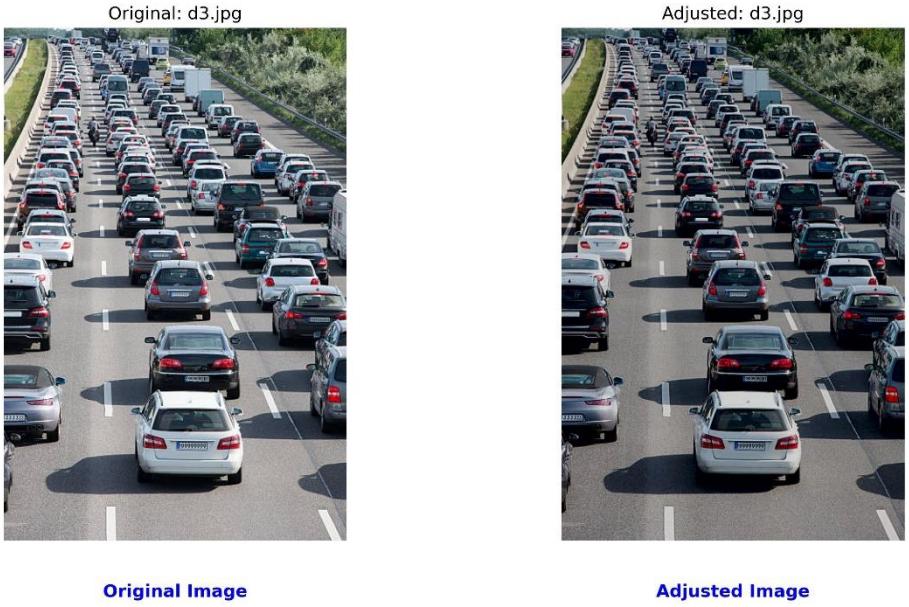
รูปที่ ง. 10 ผลการวิเคราะห์พื้นที่ที่สนใจเพื่อระบุสีรถโดยละเอียด(10)

ภาคผนวก จ

ผลการทดลองการปรับแสงในภาพโดยละเอียด



รูปที่ จ. 1 ผลการทดลองการปรับแสงในภาพสว่าง(1)



รูปที่ จ. 2 ผลการทดลองการปรับแสงในภาพสว่าง(2)



รูปที่ จ. 3 ผลการทดลองการปรับแสงในภาพสว่าง(3)



รูปที่ จ. 4 ผลการทดลองการปรับแสงในภาพสว่าง(4)



รูปที่ จ. 5 ผลการทดลองการปรับแสงในภาพสว่าง(5)



รูปที่ จ. 6 ผลการทดลองการปรับแสงในภาพสว่าง(6)



รูปที่ จ. 7 ผลการทดลองการปรับแสงในภาพสว่าง(7)



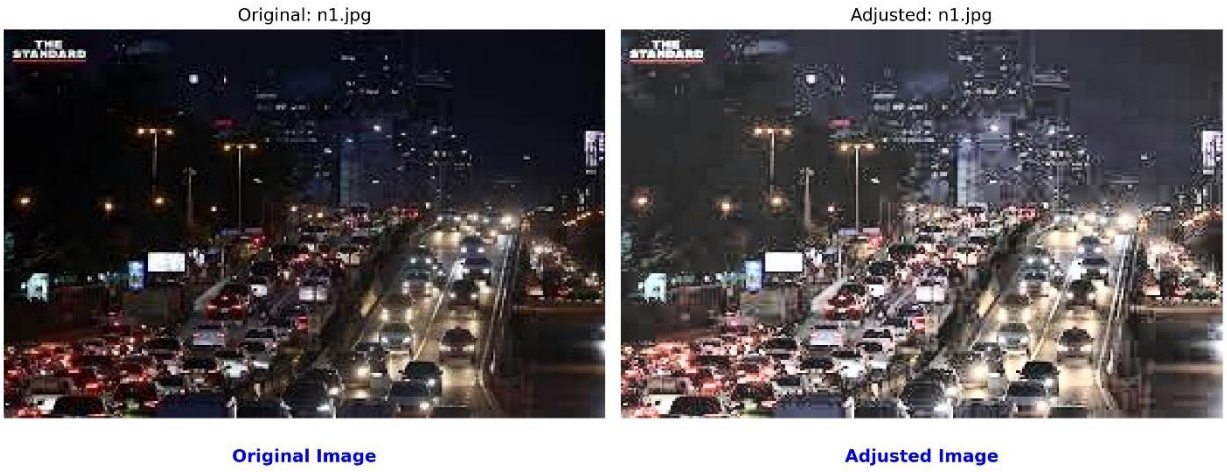
รูปที่ จ. 8 ผลการทดลองการปรับแสงในภาพสว่าง(8)



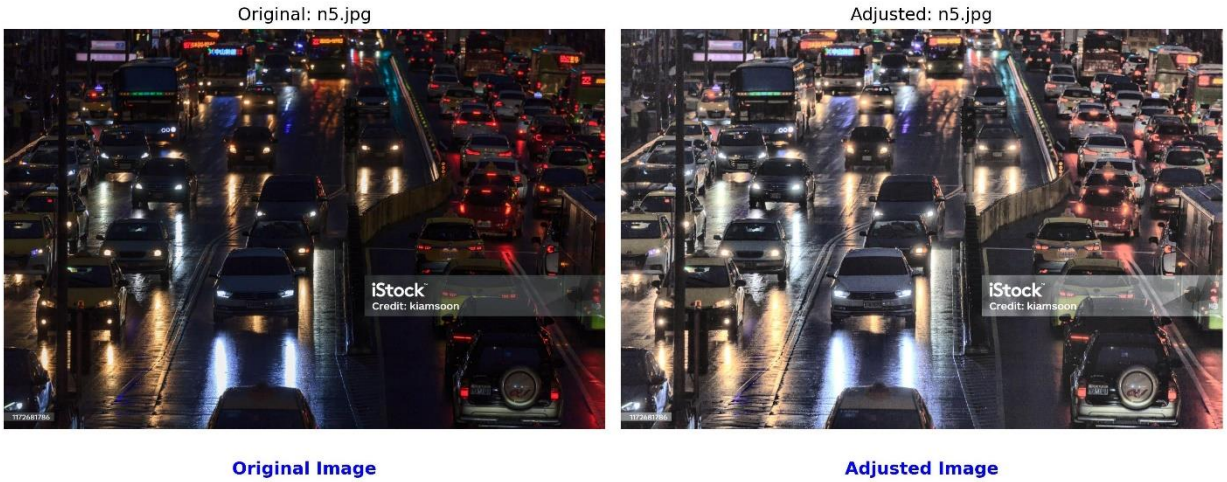
รูปที่ จ. 9 ผลการทดลองการปรับแสงในภาพสว่าง(9)



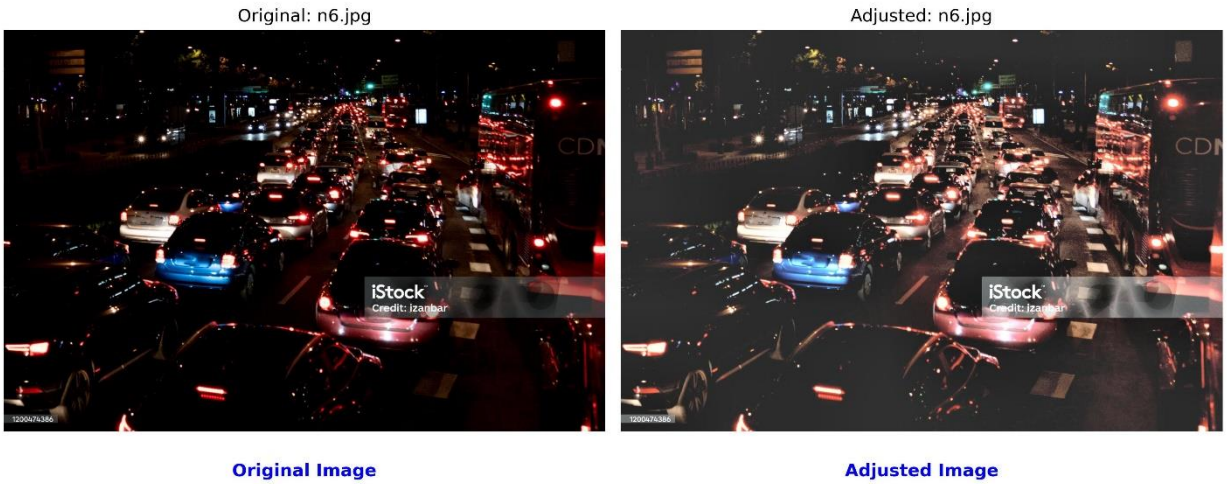
รูปที่ จ. 10 ผลการทดลองการปรับแสงในภาพสว่าง(10)



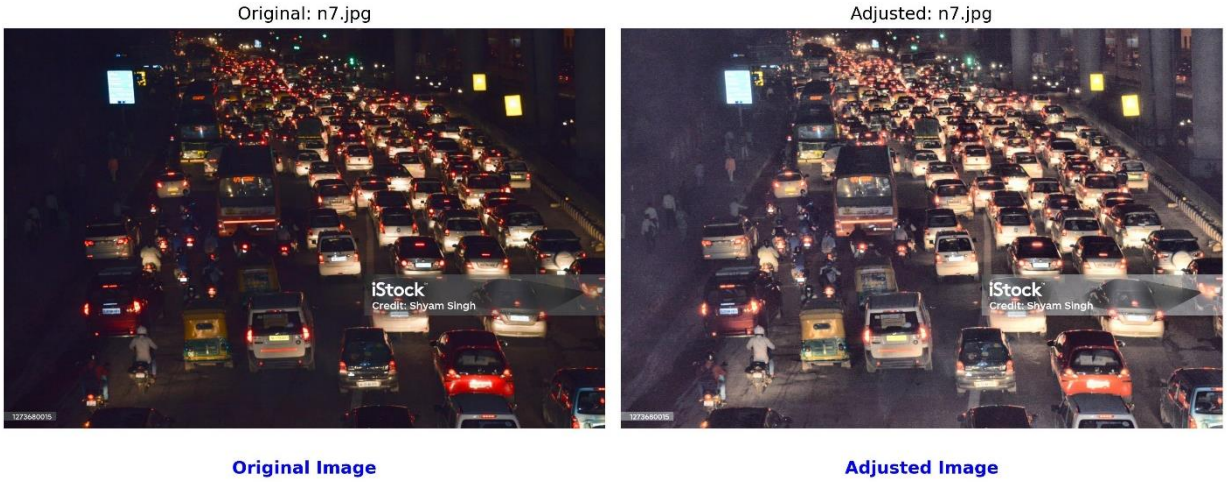
รูปที่ จ. 11 ผลการทดลองการปรับแสงในภาพมืด(1)



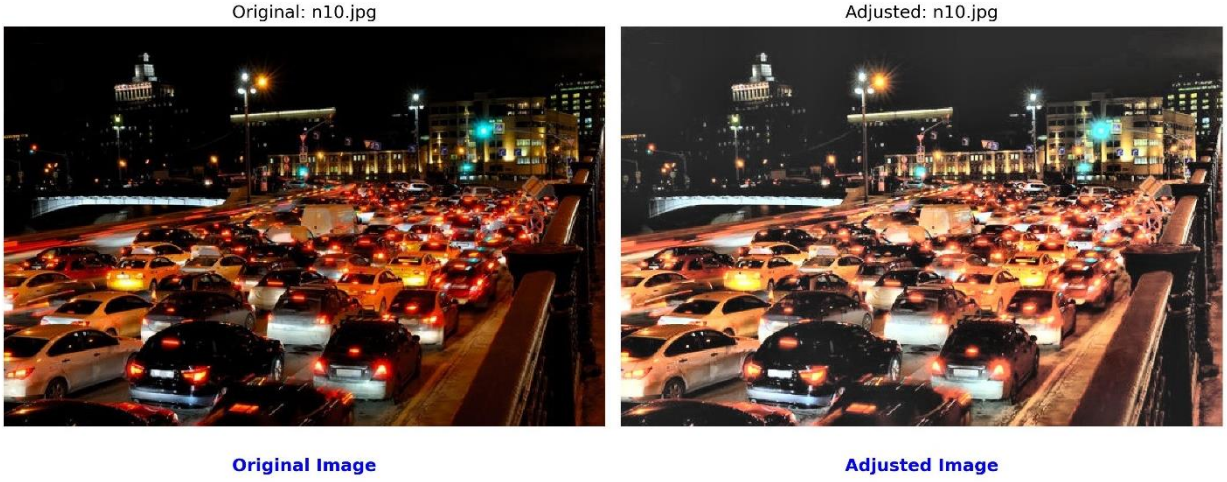
รูปที่ จ. 12 ผลการทดลองการปรับแสงในภาพมืด(2)



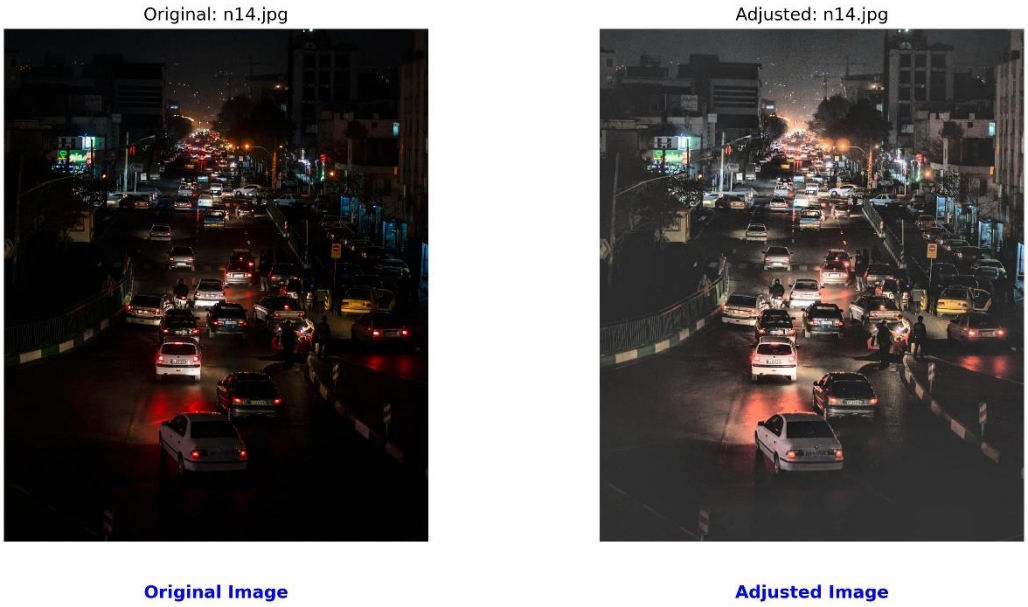
รูปที่ จ. 13 ผลการทดลองการปรับแสงในภาพมืด(3)



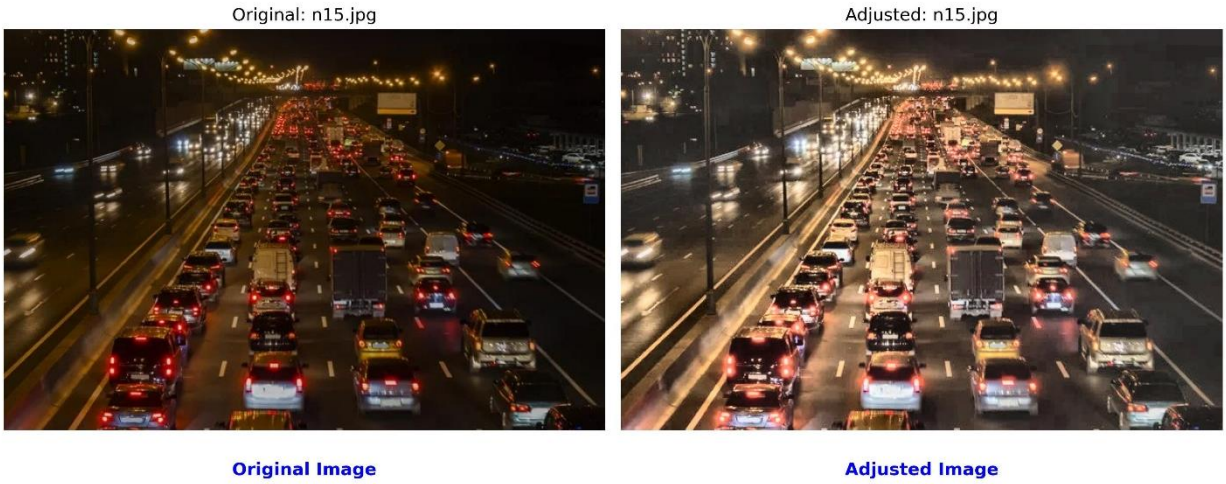
รูปที่ จ. 14 ผลการทดลองการปรับแสงในภาพมืด(4)



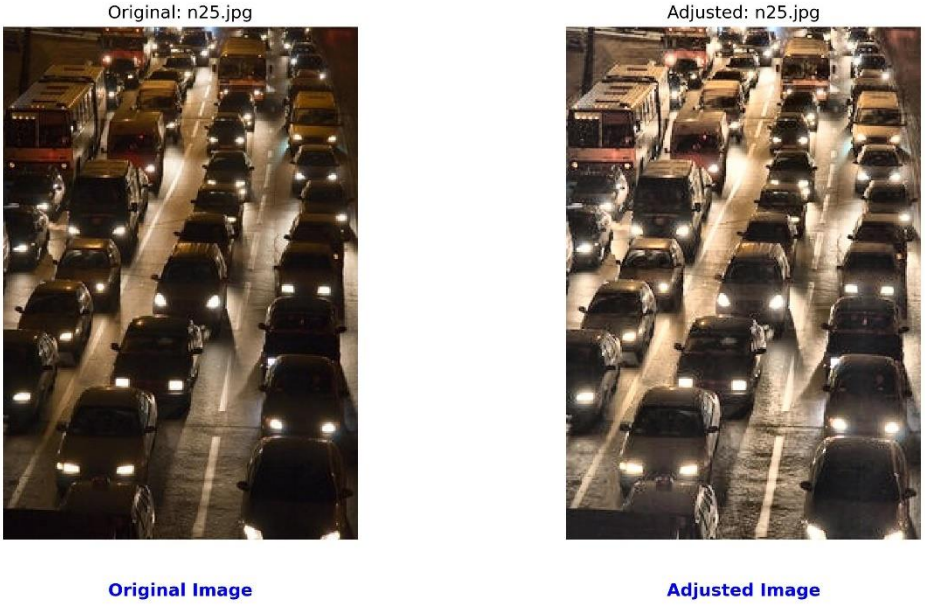
รูปที่ จ. 15 ผลการทดลองการปรับแสงในภาพมืด(5)



รูปที่ จ. 16 ผลการทดลองการปรับแสงในภาพมืด(6)



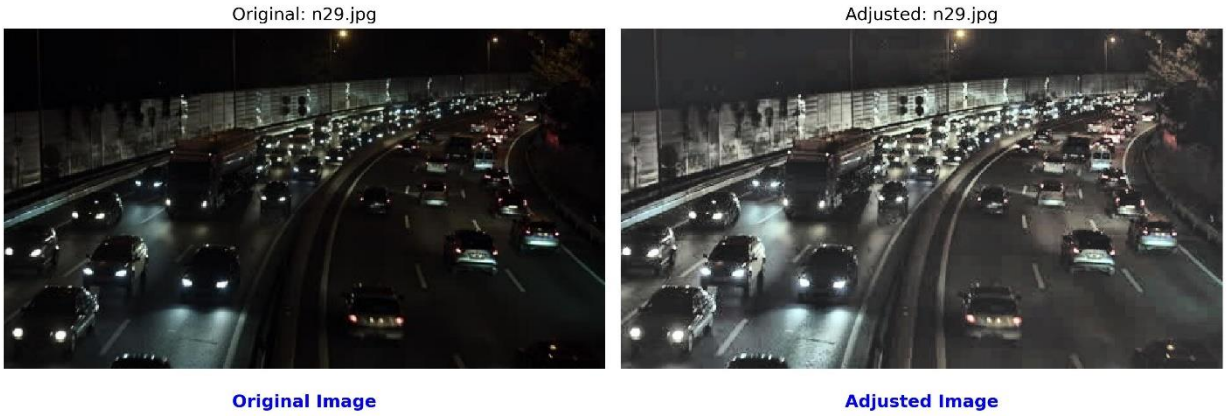
รูปที่ จ. 17 ผลการทดลองการปรับแสงในภาพมืด(7)



รูปที่ จ. 18 ผลการทดลองการปรับแสงในภาพมืด(8)



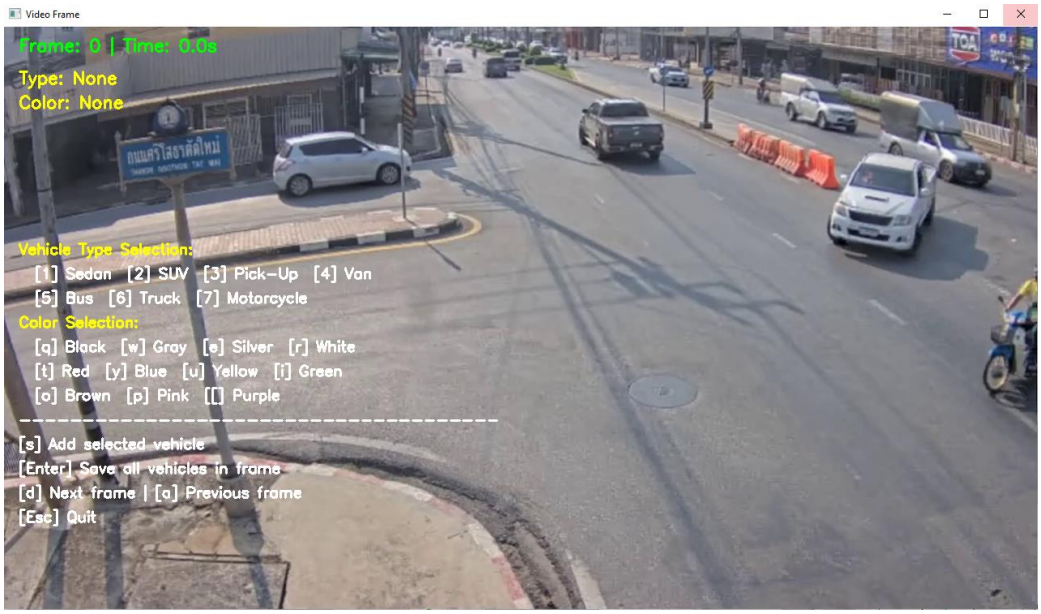
รูปที่ จ. 19 ผลการทดลองการปรับแสงในภาพมืด(9)



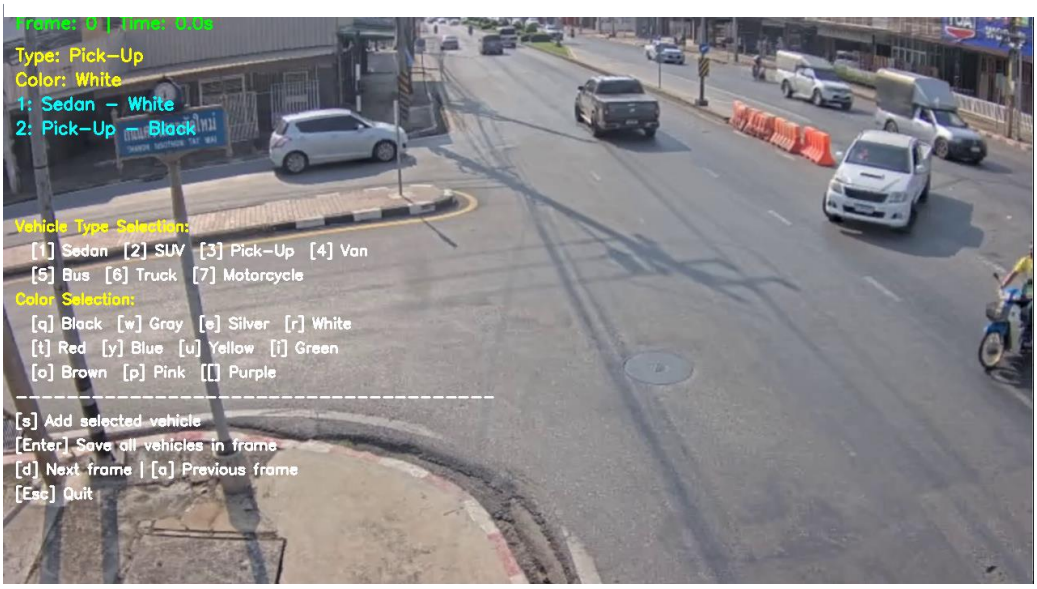
รูปที่ จ. 20 ผลการทดลองการปรับแสงในภาพมืด(10)

ภาคผนวก ช

วิธีการตรวจสอบด้วยมือและตาเปล่า



รูปที่ ช. 1 โปรแกรมสำหรับตรวจสอบวิดีโอด้วยมือและตาเปล่า(1)



รูปที่ ช. 2 โปรแกรมสำหรับตรวจสอบวิดีโอด้วยมือและตาเปล่า(2)